山东大学

新生研讨课程报告

报告题目: 对抗样本与声纹解锁

姓　　名 薛润泽

学　　号 202200130077

学　　院 计算机科学与技术学院

专　　业 计算机科学与技术

年　　级 2022 级

年　　级 5 班

2022 年 12 月 25 日

目录

中文摘要 1

英文摘要 . . . . . .

关键词 . . . . . .

正文 . . . . . .

参考文献 . . . . . .

中 文 摘 要 **将正常的语音调制成超声波载波上的语音命令，当其频率大于 2 万赫兹时，人耳无法听见，但手机的语音助手依然可以接收这样的命令**

英 文 摘 要 **However,by adding small and human-imperceptible perturbations to the original speech,the generated adversarial examplecan make ASR systems produce unpredictable and even aggressive result.**

关 键 词 **对抗样本 海豚音攻击 声纹锁 人工智能**

绪论

1. 主讲教师：吕琳 [1]
   研究方向：计算机图形学、数字几何处理、智能制造
   团队成员：赵海森 孟祥旭 潘荣江 杨义军
2. 主讲教师：栾峻峰[2]
   研究方向：智能算法及软件、可计算性逻辑
   团队成员：朱大铭 姜海涛 张鹏 冯好娣 曲美霞
3. 主讲教师：辛士庆[3]
   研究方向：计算图形学、计算机辅助设计、数字几何处理

---

1 《Nonlinear regression: A possible solution to larger dynamic range for some spectrum-based optical sensors》

2 《高维空间球集覆盖问题的改进 1+ε近似算法》范克磊 栾峻峰;

3 《面向人体动作识别的局部特征融合时间卷积网络》宋震 周元峰 贾金公 辛士庆 刘毅 计算机辅助设计与图形学学报 1003-9775 2020,(3) 418-424

4. 主讲教师：申兆岩[4]
研究方向：大数据存储架构、嵌入式系统、硬件协同设计、IoT 区块链
5. 主讲教师：潘润宇[5]
研究方向：物联网系统、实时操作系统、微内核、区块链
团队成员：成秀珍 肖梦白 于东晓 杨燕妮 张国明
6. 主讲教师：甘甜
7. 主讲教师：张国明[6]
研究方向：物联网安全、AI 安全。包括：智能语音系统安全分析和防护研究，人工智能安全问题研究，窃听&防窃听研究以及基于联邦学习的终端设备安全监测研究等。
团队成员：成秀珍 肖梦白 于东晓 杨燕妮 潘润宇
8. 主讲教师：姜海涛[7]
研究方向：算法与复杂性，算法/计算生物学。主要研究计算生物方面的基因组序列的重组、分析、比较相关问题。
团队成员：朱大铭 栾峻峰 张鹏 冯好娣 曲美霞
9. 主讲教师：杨燕妮[8]
研究方向：普适计算，移动计算，无线感知，智能感知
团队成员：成秀珍 肖梦白 于东晓 潘润宇 张国明
10. 主讲教师：崔学峰[9]
研究方向：深度学习、并行计算、生物信息。近期崔学峰老师研究主要包括：基于冷冻电镜的分子结构检测，基于多肽疫苗的新抗原设计，基于宏基因组大数据的抗生素抗性基因挖掘。
11. 主讲教师：辛鑫[10]
研究方向：推荐系统，信息检索，强化学习
12. 主讲教师：彭朝晖[11]
研究方向：数据库系统、数据挖掘、大数据分析
团队成员：朱大铭 郭炅 冯好娣 姜海涛 时阳光

兴趣

我个人比较喜欢张国明老师的研究方向。张国明老师在授课时与我们讨论了

---

4 《面向冯·诺依曼计算机的指令执行虚拟仿真设计与探讨》蔡晓军; 栾峻峰; 申兆岩; 赵梦莹; 于东晓; 李永明; 贾智平 实验技术与管理 1002-4956 2022,(5) 89-93
5 《eWASM: Practical Software Fault Isolation for Reliable Embedded Devices》
6 《Detecting Android Malware by Trace of Privacy Leakage》
7 《排列短块移动排序距离的新下界》王彤; 姜海涛; 朱大铭 计算机研究与发展 1000-1239 2015,(11) 2622-2627
8 Yanwen Wang, Jiannong Cao, Jinlin Chen, "HearLiquid: Non-intrusive Liquid Fraud Detection Using Commodity Acoustic Devices", IEEE Internet of Things Journal, Jan 2022.
9 Yaosen Min, Shang Liu, and Xuefeng Cui Learning protein structural fingerprints under the label-free supervision of domain knowledge Published on IEEE International Conference on Bioinformatics and Biomedicine (IEEE-BIBM), Madrid, Spain, December 3-6, 2018
10 《Rethinking Reinforcement Learning for Recommendation: A Prompt Perspective》
11 《Dynamic Evolution based Deep Hierarchical Intention Network for Membership Prediction》

IOT 安全问题。物联网安全问题非常贴近我们的生活，这样的问题也非常吸引我的兴趣。张老师在讲解时举了很多新奇且易懂的例子，我印象最深的就是“海豚音攻击”的例子以及对抗样本的例子。当时老师在授课时我就在想：声纹解锁为什么会受到声调的高低的影响？手机语音 AI 的识别为什么不是识别主人的音色，或者是说因为某种原因，海豚音——这种高音调音，高频率音会干扰到识别，从而识别音色出现了偏差？

我搜索了一些关于声纹解锁或者是人工语音 AI 的原理资料：声纹识别技术主要是利用该技术来对语音波纹进行相关的研究以及观察之后将语音波纹里面能够当作说话人身份相关的语音波形部分提取出来，并以此来判断出该说话人所具备的身份。声纹识别技术主要是由 5 个部分组成的。这 5 个部分分别为预处理部分、特征提取部分、模型训练模块部分、模式匹配部分以及逻辑决策部分。[12]如下图，为原理部分示意图：

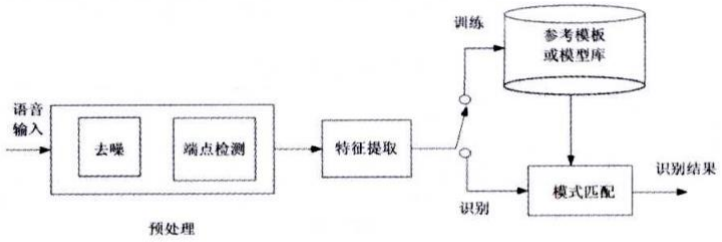


图 5　技术实现原理框图

所以，声纹解锁并不是像之前简单预期的那样，通过检测人的音色来识别身份的，而是通过特征检测。先采集待检测的声音，将待检测的声音样本去噪，然后进行端点检测，提取声纹特征后将声纹特征转化为特征向量序列，再经过特殊训练的 AI 或者是参考模板进行匹配，来观测是否可以解锁声纹锁。

“海豚音破解声纹锁”这一现象张老师做了简单的解释，通过利用人耳不能听到高于人耳极限接受频率的原理，以类似于“穷举”的方法一点一点的模拟物品主人的声音特征。我仍然抱有疑惑：如果是单纯是欺骗了人耳的话，普通频率的声音虽然不具有隐蔽性，也可以做到攻击设备，破解声纹锁。所以我找到了一篇写“海豚音攻击”的文章来进行更详细的探索。

徐文渊介绍，他们之所以把这种攻击命名为“海豚音攻击”，是因为海豚的叫声是一种超声波。“我们设计了一种完全无声的攻击，将正常的语音调制成超声波载波上的语音命令，当其频率大于 2 万赫兹时，人耳无法听见，但手机的语音助手依然可以接收这样的命令。”……但据该团队介绍，目前最先进的超声波发射器可以实现 2 千米范围的传播，这也意味着未来更多的攻击可能性。[13]

这篇由新华社和齐鲁晚报主笔的文章比较清楚的讲明白了浙江大学徐文渊教授的发现。海豚音攻击的确主要是利用了高频率人耳无法听见的特点，同时也兼备远距离攻击的特点。我之前的疑惑是是否以欺骗人耳作为海豚音攻击的

---

[12] ：刘 宁，张晶，郝晓雪 ，等 Android 平台声纹解锁系统的仿真与研究[J]．电声技术 ，2017，41(9／10)：63-66．

[13] 《当心手机遭遇“海豚音攻击”》　据新华社、齐鲁晚报

特点。现在看来的确是的。这项发现的确是一项非常贴近现实的发现，我们的物联网声纹解锁技术的一项大漏洞，与我们非专业领域的人也息息相关。

记得当时授课时，我们还在疑惑为什么计算机专业的新生研讨课会上关于安全问题的课程，现在看来，物联网安全其实与网络安全有许多区别。研究物联网安全（iot 安全）实际上能涉及到许许多多其他的计算机领域。现在我们说我们会逐步走上一种万物互联的时代。那么物联网安全的定义就被非常广泛的扩大了。凡是能接入到物联网中的都存在安全性问题。比如人工智能安全问题（AI 安全）。人工智能安全问题中非常重要需要解决的一个问题是对抗样本问题。首先，什么是对抗样本？我们可以简单理解为能够扰乱 AI 正确识别判断的一些故意性的样本。AI 识别是通过提取特征点，比对特征点来识别判断的。但是我们如果故意的在图片中加入少量的某些特征点，我们就可以引导着 AI 读取出错误的结果，例如下图：

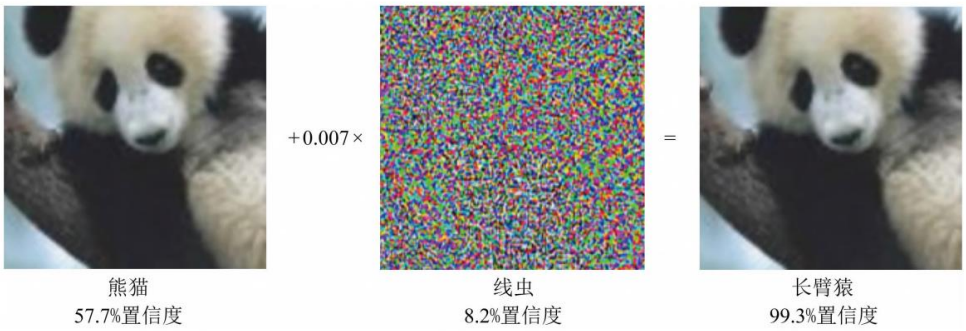


图 1　对抗样本

我们看到，一张 57.7%会被识别为熊猫的照片，在加入了一组线虫的数据点后，我们人眼看到熊猫照片发生了极其微小的变化，或者说甚至没有变化，还是刚才的熊猫。但是 AI 识别却被对抗样本误导，99.3%的置信度识别为长臂猿。以下介绍了另一个例子：

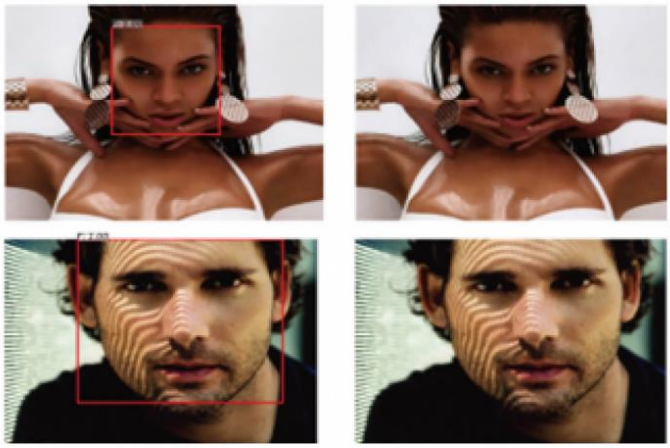
Some malicious fraudsters take advantage of AI to attack internet systems especially in the field of captcha generation.The anti-knowledge map captcha based on the adversarial example technology is proposed,which fused the natural language processing technology and adversarial example generation technology,and thus increase the robustness to attacks and safeguard the security environment of internet.[14]上述 AI 对抗样本被利用在了对抗灰黑产业破解验证码上。随着灰黑产业不断发展，人工智能技术门槛的不断降低，使用人工智能破解验证码已经很常见的违法手段。使用了对抗样本可以很好的扰乱不法分子的人工智能，同时保证真人在进行操作时受到最小的影响，正常进行验证码的输入验证。如图为生成的对抗验证码：

[14] 《AI 安全——对抗样本技术综述与应用》陈岳峰 毛潇峰 李裕宏 何 源 薛 晖-



图 6　对抗验证码

但是对抗样本在打击了不法分子的同时同样揭露了人工智能的短板，对抗样本可以很轻松的“误导”人工智能的判断，如图为人脸识别上的对抗样本：



(a) 原始图像　　(b) 对抗样本

那么，有没有什么办法来对抗“对抗样本”呢？我最先的看法是，对抗样本改变的是输入数据，输入数据的改变是很难纠正的。就像是我们去看一个东西，东西输入到自己的眼睛中，就是以它原来的姿态浮现到大脑中，就算别人告诉你这个样子是被伪装过的，你也很难想出它原来是什么样的模样。但是的确有办法来降低“对抗样本”对 AI 造成的影响。一般可以分成对抗训练，知识迁移和降噪。

对抗训练来“对抗“对抗样本，实际上是让对抗样本也加入了 AI 训练组中，让 AI 主动识别对抗样本。通过对对抗样本的不断辨识不断增加 AI 的数据库，不断提高 AI 的稳定性。但是通过对抗训练获得的 AI 不能辨识出训练对抗样本类型以外的对抗样本。所以，想要让 AI 有强稳定性，能够识别“整个世界”需要经过天文数字次的训练，无论是资源上还是时间上都是巨大的消耗。

知识迁移可以通过训练数据集以外的样本来平滑训练过程中学到的模型，最早运用于“防御蒸馏网络”。“防御蒸馏”是一种防御方法，它将知识从深度神经网络集成到单个神经网络。这种方法很好的弥补了对抗训练中对天文数据的依赖性，提高了泛化能力。知识迁移一般先按照正常的训练法来训练分类网络，然后利用学到的概率向量训练另一个完全架构的蒸馏网络。

再者就是降噪，下文引文讲述了降噪思想。降噪的核心思想是:通过对对抗样本施加变换,破坏添加的噪声，从而消除扰动的影响，提高分类器的准确性．根据神经网络的结构，降噪法可以 2 次细分为输入层降噪和隐藏层降噪 2

类,但无论是哪种降噪方法，都依赖于梯度掩蔽,这也意味着目前基于降噪技术的防御方法对 BPDA 等攻击方式都显示出脆弱性。[15]

因为产生对抗样本是通过在正常信息中加入干扰信息产生的，这是一种非常广泛的信息产物。不只是图片，声音中也可以产生对抗样本。下述文字简单介绍了声音对抗样本：

Automatic speech recognition(ASR)systems convert input speech into corresponding text and their performances have been significantly improved with the development of deep learning techniques.However,by adding small and human-imperceptible perturbations to the original speech,the generated adversarial examplecan make ASR systems produce unpredictable and even aggressive result.Till now,the adversarial example attack has posed many security risks to deep learning-based ASR systems.In this paper,a systematical survey on the adversarialexample attacks and countermeasures has beenprovided[16]

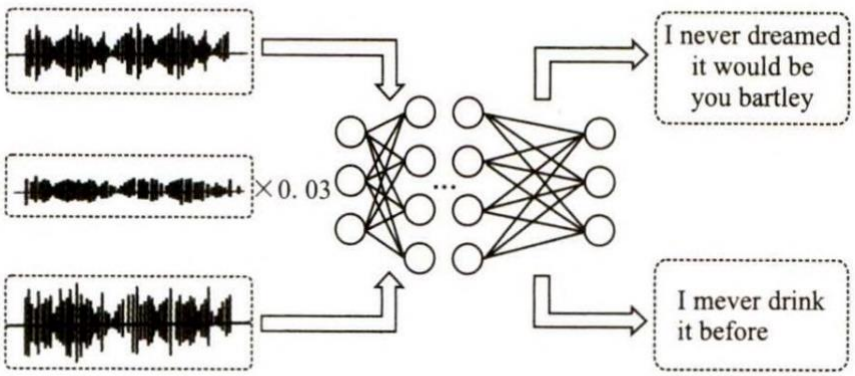


图 1　语音对抗样本示意

刚好与“海豚音”所呼应。“海豚音”问题是张国明老师讲述物联网安全时讲述的一种利用人耳局限性进行声纹解锁的一种物联网设备漏洞。而声音对抗样本不需要“海豚音”的音频高度，也可以解锁受害者的声纹锁。上图所描述的，假设原本正确的声音信息是“I never dreamed it would be you bartley”经过人工添加一些声音特征进行干扰后，AI 识别对抗样本就识别成了“I mever drink it before”。看起来驴唇不对马嘴。但是，在一些特殊的情况下，可能会造成较大生命财产损失。例如我们在路上行车，启用了语音系统，前方有行人我们大喊，“停下”。但是某些黑客在我们的声音中加入了修饰，成为了特殊的对抗样本，汽车电脑可能会识别成，“加速!”。可能我们将手机放在桌旁，或者口袋里，听到了一句奇怪的“下午好”，可能这句“下午好”是犯罪分子精心准备的对抗样本。我们的手机识别起来却是“打开声纹锁”，然后就在我们不知情的情况下，我们的信息被一点点窃取了。

---

[15] 《面向图像数据的对抗样本检测与防御技术综述》 张 田 杨奎武 魏江宏 刘 扬 宁原隆 (战略支援部队信息工程大学 郑州 ４５０００１)

[16] 《面向语音识别系统的对抗样本攻击及防御综述》陈佳豪，白炳松，王冬华，严迪群，王让定
(宁波大学信息科学与工程学院，浙江宁波 315211)

参考文献

1 《Nonlinear regression: A possible solution to larger dynamic range for some spectrum-based optical sensors》RuiYin LingxinCao QingjieHuang HongliangYang WeiJi LinLu XuYang FengyuLiu PengchengLiu ShouzhenJiang

2 《高维空间球集覆盖问题的改进 1+ε 近似算法》范克磊 栾峻峰;

3 《面向人体动作识别的局部特征融合时间卷积网络》宋震 周元峰 贾金公 辛士庆 刘毅计算机辅助设计与图形学学报 1003-9775 2020,(3) 418-4244

4 《面向冯·诺依曼计算机的指令执行虚拟仿真设计与探讨》蔡晓军; 栾峻峰; 申兆岩; 赵梦莹; 于东晓; 李永明; 贾智平 实验技术与管理 1002-4956 2022,(5) 89-93

5 《eWASM: Practical Software Fault Isolation for Reliable Embedded Devices》

6 《Detecting Android Malware by Trace of Privacy Leakage》

7 《排列短块移动排序距离的新下界》王彤; 姜海涛; 朱大铭 计算机研究与发展 1000-1239 2015,(11) 2622-2627

8 Yanwen Wang, Jiannong Cao, Jinlin Chen, "HearLiquid: Non-intrusive Liquid Fraud Detection Using Commodity Acoustic Devices", IEEE Internet of Things Journal, Jan 2022.

9 Yaosen Min, Shang Liu, and Xuefeng Cui Learning protein structural fingerprints under the label-free supervision of domain knowledge Published on IEEE International Conference on Bioinformatics and Biomedicine (IEEE-BIBM), Madrid, Spain, December 3-6, 2018

10 《Rethinking Reinforcement Learning for Recommendation: A Prompt Perspective》

11 《Dynamic Evolution based Deep Hierarchical Intention Network for Membership Prediction》

12 刘 宁，张晶，郝晓雪 ，等 Android 平台声纹解锁系统的仿真与研究[J]. 电声技术 ，2017，41(9／10)：63-66.

13 《当心手机遭遇“海豚音攻击”》 据新华社、齐鲁晚报

14 《AI 安全——对抗样本技术综述与应用》陈岳峰 毛潇峰 李裕宏 何 源 薛 晖-

15《面向图像数据的对抗样本检测与防御技术综述》张 田 杨奎武 魏江宏 刘 扬 宁原隆(战略支援部队信息工程大学 郑州 ４５０００１)

16 《面向语音识别系统的对抗样本攻击及防御综述》陈佳豪，白炳松，王冬华，严迪群，王让定 (宁波大学信息科学与工程学院，浙江宁波 315211)