山东大学 计算机科学与技术 学院

人工智能导论 课程实验报告

学号：202200130077	姓名： 薛润泽	邮箱：
实验题目：六、自然语言处理分词处理实验		

实验过程：

（记录实验过程、遇到的问题和实验结果。可以适当配以关键代码辅助说明，但不要大段贴代码。）

1. 中文分词

（1）使用 jieba 进行分词

相关代码：

```
# encoding=utf-8
import jieba
jieba.load_userdict(r"C:\Users\薛润泽\Desktop\人工智能实验六\newdictionary.txt")
seg_list = jieba.cut("央视315晚会曝光湖北省知名的神丹牌、莲田牌“土鸡蛋”实为普通鸡蛋冒充，同时在商标上玩猫腻，分别注册“鲜土”、注册“好土”商标，让消费者误以为是“土鸡蛋”。")
print("Full Mode: " + "/ ".join(seg_list))  # 全模式
print()

seg_list = jieba.cut("央视315晚会曝光湖北省知名的神丹牌、莲田牌“土鸡蛋”实为普通鸡蛋冒充，同时在商标上玩猫腻，分别注册“鲜土”、注册“好土”商标，让消费者误以为是“土鸡蛋”。")
print("Default Mode: " + "/ ".join(seg_list))  # 精确模式
print()
seg_list = jieba.cut("央视315晚会曝光湖北省知名的神丹牌、莲田牌“土鸡蛋”实为普通鸡蛋冒充，同时在商标上玩猫腻，分别注册“鲜土”、注册“好土”商标，让消费者误以为是“土鸡蛋”。")
print(", ".join(seg_list))
print()
seg_list = jieba.cut_for_search("央视315晚会曝光湖北省知名的神丹牌、莲田牌“土鸡蛋”实为普通鸡蛋冒充，同时在商标上玩猫腻，分别注册“鲜土”、注册“好土”商标，让消费者误以为")
print(", ".join(seg_list))
```

分词结果：

```
Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\薛润泽\AppData\Local\Temp\jieba.cache
Loading model cost 0.430 seconds.
Prefix dict has been built successfully.
Full Mode: 央视/ 315/ 晚会/ 曝光/ 湖北/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲/ 田/ 牌/ “/ 土鸡/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/ 在/ 商标/ 标上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜/ 土/ ”、/ 注册/ “/ 好/ 土/ ”/ 商标/ ，/ 让/ 消费/ 消费者/ 误以为/ 以为/ 是/ “/ 土鸡/ 鸡蛋/ ”。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就此/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 有限公司/ 公司/ 方面/ ，/ 其/ 工作/ 工作人员/ 作人/ 人员/ 表示/ 不知/ 不知情/ 知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂/ 未取/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 有限公司/ 公司/ 为/ 农业/ 农业产业/ 产业/ 产业化/ 国家/ 重点/ 龙头/ 龙头企业/ 企业/ 、/ 高新/ 高新技术/ 技术/ 企业/ ，/ 此前/ 曾/ 因涉嫌/ 涉嫌/ 虚假/ 宣传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。

Default Mode: 央视/ 315/ 晚会/ 曝光/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲田牌/ “/ 土/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/ 在/ 商标/ 上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜土/ ”/ 、/ 注册/ “/ 好土/ ”/ 商标/ ，/ 让/ 消费者/ 误以为/ 是/ “/ 土/ 鸡蛋/ ”/ 。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限公司/ 方面/ ，/ 其/ 工作人员/ 表示/ 不知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂未/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限公司/ 为/ 农业/ 产业化/ 国家/ 重点/ 龙头企业/ 、/ 高新技术/ 企业/ ，/ 此前/ 曾/ 因涉嫌/ 虚假/ 宣传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。

央视，315，晚会，曝光，湖北省，知名，的，神丹，牌，、，莲田牌，“，土，鸡蛋，”，实为，普通，鸡蛋，冒充，，，同时，在，商标，上，玩，猫腻，，，分别，注册，“，鲜土，”，、，注册，“，好土，”，商标，，，让，消费者，误以为，是，“，土，鸡蛋，”，。，3，月，15，日，晚间，，，新，京报，记者，就，此事，致电，湖北，神丹，健康，食品，有限公司，方面，，，其，工作人员，表示，不知情，，，需要，了解，清楚，情况，，，截至，发稿，暂未，取得，最新，回应，。，新，京报，记者，还，查询，发现，，，湖北，神丹，健康，食品，有限公司，为，农业，产业化，国家，重点，龙头企业，、，高新技术，企业，，，此前，曾，因涉嫌，虚假，宣传，“，中国，最大，的，蛋品，企业，”，而，被，罚，6，万元，。

央视，315，晚会，曝光，湖北，湖北省，知名，的，神丹，牌，、，莲田牌，“，土，鸡蛋，”，实为，普通，鸡蛋，冒充，，，同时，在，商标，上，玩，猫腻，，，分别，注册，“，鲜土，”，、，注册，“，好土，”，商标，，，让，消费，消费者，以为，误以为，是，“，土，鸡蛋，”，。，3，月，15，日，晚间，，，新，京报，记者，就，此事，致电，湖北，神丹，健康，食品，有限，公司，有限公司，方面，，，其，工作，作人，人员，工作人员，表示，不知，知情，不知情，，，需要，了解，清楚，情况，，，截至，发稿，暂未，取得，最新，回应，。，新，京报，记者，还，查询，发现，，，湖北，神丹，健康，食品，有限，公司，有限公司，为，农业，产业，产业化，国家，重点，龙头，企业，龙头企业，、，高新，技术，高新技术，企业，，，此前，曾，涉嫌，因涉嫌，虚假，宣传，“，中国，最大，的，蛋品，企业，”，而，被，罚，6，万元，。
PS C:\Users\薛润泽>
```

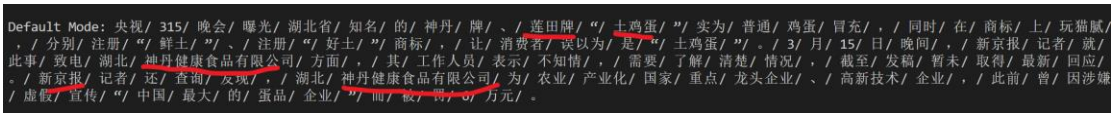
如上图所示第一段为 Full Mode 全模式下的分词结果，例如土鸡蛋被分词为了土鸡\鸡蛋，因为土鸡、鸡蛋都是默认词表中存在的。第二段是 Default Mode 默认模式，这一个模式将原文通过词性词意将逐个划分，没有模糊词的额外释义补充。第三段是新词识别，算法识别出了例如神丹这样不在词典中的词语。第四段是搜索引擎模式，它将一些能够组合的词语例如有限，公司组合成有限公司，工作，作人，人员结合为工作人员。

Jieba 分词加入自定义词典，需要新建立一个 txt 文件，文件中的每一行代表一个新词语，格式为 词语，词频（可省略），词性（可省略） 例如如下

新定义的词语：

莲田牌
土鸡蛋
湖北省
玩猫腻
新京报
神丹健康食品有限公司

使用代码 jieba. load_userdict(file_name)将新词典加入到代码中。



如图得到了识别出新词语的结果。

（2）使用 StanfordCoreNLP 进行中文分词

相关代码：

```
# Simple usage
from stanfordcorenlp import StanfordCoreNLP

nlp = StanfordCoreNLP(r'D:\Microsoft VS Code\Python-stanford-corenlp\stanford-corenlp-4.5.4',lang='zh')
#stanford-corenlp-4.5.4
sentence = "央视315晚会曝光湖北省知名的神丹牌、莲田牌“土鸡蛋”实为普通鸡蛋冒充，同时在商标上玩猫腻，分别注册“鲜土”、注册“好土”商标，让消费者误以为是“土鸡蛋”。3月15日晚间
print ('Tokenize:', nlp.word_tokenize(sentence))
print()
print ('Part of Speech:', nlp.pos_tag(sentence))
print()
print ('Named Entities:', nlp.ner(sentence))
print()
print ('Constituency Parsing:', nlp.parse(sentence))
print()
print ('Dependency Parsing:', nlp.dependency_parse(sentence))
print()
nlp.close() # Do not forget to close! The backend server will consume a lot memery.
```

分词结果：

```
PS C:\Users\薛润泽> python -u "c:\Users\薛润泽\Desktop\人工智能实验六\中文分词stanward.py"
Tokenize: ['央视', '315', '晚会', '曝光', '湖北省', '知名', '的', '神丹牌', '、', '莲田牌', '“', '土', '鸡蛋', '”', '实', '为', '普通', '鸡蛋', '冒充', '，', '同时', '在', '商标', '上', '玩', '猫腻', '，', '分别', '注册', '“', '鲜土', '”', '、', '注册', '“', '好', '土', '”', '商标', '，', '让', '消费者', '误以为', '是', '“', '土', '鸡蛋', '”', '。', '3月', '15日', '晚间', '，', '新京报', '记者', '就', '此', '事', '致电', '湖北', '神丹', '健康', '食品', '有限', '公司', '方面', '，', '其', '工作', '人员', '表示', '不', '知情', '，', '需要', '了解', '清楚', '情况', '，', '截至', '发稿', '暂', '未', '取得', '最新', '回应', '。', '新京报', '记者', '还', '查询', '发现', '，', '湖北', '神丹', '健康', '食品', '有限', '公司', '为', '农业', '产业化', '国家', '重点', '龙头', '企业', '、', '高新', '技术', '企业', '，', '此前', '曾', '因', '涉嫌', '虚假', '宣传', '“', '中国', '最', '大', '的', '蛋品', '企业', '”', '而', '被', '罚', '6万', '元', '。']
```

因版本过于陈旧，使用 StanfordCoreNLP 中文词库分词时，只能进行 Tokenize 文本分割。可以看到，文本按照各个中文词进行了分割。

2. 英文分词

（1）NLTK 英文分词

相关代码：

```
import nltk
text="Trump was born and raised in the New York City borough of Queens an
tokens = nltk.tokenize.word_tokenize(text)
print(tokens)
```

分词结果：

```
PS C:\Users\薛润泽> python -u "c:\Users\薛润泽\Desktop\人工智能实验六\ntlk英文分词.py"
['Trump', 'was', 'born', 'and', 'raised', 'in', 'the', 'New', 'York', 'City',
'borough', 'of', 'Queens', 'and', 'received', 'an', 'economics', 'degree', 'fr
om', 'the', 'Wharton', 'School', '.', 'He', 'was', 'appointed', 'president', '
of', 'his', 'family', "'s", 'real', 'estate', 'business', 'in', '1971', ',', '
renamed', 'it', 'The', 'Trump', 'Organization', ',', 'and', 'expanded', 'it',
'from', 'Queens', 'and', 'Brooklyn', 'into', 'Manhattan', '.', 'The', 'company
', 'built', 'or', 'renovated', 'skyscrapers', ',', 'hotels', ',', 'casinos', '
,', 'and', 'golf', 'courses', '.', 'Trump', 'later', 'started', 'various', 'si
de', 'ventures', ',', 'including', 'licensing', 'his', 'name', 'for', 'real',
'estate', 'and', 'consumer', 'products', '.', 'He', 'managed', 'the', 'company
', 'until', 'his', '2017', 'inauguration', '.', 'He', 'co-authored', 'several'
, 'books', ',', 'including', 'The', 'Art', 'of', 'the', 'Deal', '.', 'He', 'ow
ned', 'the', 'Miss', 'Universe', 'and', 'Miss', 'USA', 'beauty', 'pageants', '
from', '1996', 'to', '2015', ',', 'and', 'he', 'produced', 'and', 'hosted', 'T
he', 'Apprentice', ',', 'a', 'reality', 'television', 'show', ',', 'from', '20
03', 'to', '2015', '.', 'Forbes', 'estimates', 'his', 'net', 'worth', 'to', 'b
e', '$', '3.1', 'billion', '.']
PS C:\Users\薛润泽>
```

英文分词可以按照单词之间的空格进行分词。

（2）Spacy 英文分词

相关代码：

```
import spacy
spacy_en = spacy.load("en_core_web_sm")
def tokenize_en(text):
    return [tok.text for tok in spacy_en.tokenizer(text)]
print(tokenize_en("Trump was born and raised in the New York City borough of Queens and receive
```

分词结果：

```
PS C:\Users\薛润泽> python -u "C:\Users\薛润泽\AppData\Local\Temp\tempCodeRunnerFile.python"
['Trump', 'was', 'born', 'and', 'raised', 'in', 'the', 'New', 'York', 'City', 'borough', 'of', 'Queens', 'and', 'received', 'an', 'economics', 'de
gree', 'from', 'the', 'Wharton', 'School', '.', 'He', 'was', 'appointed', 'president', 'of', 'his', 'family', "'s", 'real', 'estate', 'business',
'in', '1971', ',', 'renamed', 'it', 'The', 'Trump', 'Organization', ',', 'and', 'expanded', 'it', 'from', 'Queens', 'and', 'Brooklyn', 'into', 'Ma
nhattan', '.', 'The', 'company', 'built', 'or', 'renovated', 'skyscrapers', ',', 'hotels', ',', 'casinos', ',', 'and', 'golf', 'courses', '.', 'Tr
ump', 'later', 'started', 'various', 'side', 'ventures', ',', 'including', 'licensing', 'his', 'name', 'for', 'real', 'estate', 'and', 'consumer',
 'products', '.', 'He', 'managed', 'the', 'company', 'until', 'his', '2017', 'inauguration', '.', 'He', 'co', '-', 'authored', 'several', 'books',
 ',', 'including', 'The', 'Art', 'of', 'the', 'Deal', '.', 'He', 'owned', 'the', 'Miss', 'Universe', 'and', 'Miss', 'USA', 'beauty', 'pageants', '
from', '1996', 'to', '2015', ',', 'and', 'he', 'produced', 'and', 'hosted', 'The', 'Apprentice', ',', 'a', 'reality', 'television', 'show', ',', '
from', '2003', 'to', '2015', '.', 'Forbes', 'estimates', 'his', 'net', 'worth', 'to', 'be', '$', '3.1', 'billion', '.']
PS C:\Users\薛润泽>
```

（3）StanfordCoreNLP 英文分词：

相关代码：

```python
# Simple usage
from stanfordcorenlp import StanfordCoreNLP

nlp = StanfordCoreNLP(r'D:\Microsoft VS Code\Python-stanford-corenlp\stanford-corenlp-4.5.4')
#stanford-corenlp-4.5.4
sentence = "Trump was born and raised in the New York City borough of Queens and received an economics degree from th
print ('Tokenize:', nlp.word_tokenize(sentence))
print()
print ('Part of Speech:', nlp.pos_tag(sentence))
print()
print ('Named Entities:', nlp.ner(sentence))
print()
print ('Constituency Parsing:', nlp.parse(sentence))
print()
print ('Dependency Parsing:', nlp.dependency_parse(sentence))
print()
nlp.close() # Do not forget to close! The backend server will consume a lot memery.
```

分词结果：

```
PS C:\Users\薛润祥> python -u "c:\Users\薛润
泽\Desktop\人工智能实验六\英文分词.py"
Tokenize: ['Trump', 'was', 'born', 'and', 'raised', 'in', 'the', 'New', 'York', 'City', 'borough', 'of', 'Queens', 'and', 'received', 'an', 'econo
mics', 'degree', 'from', 'the', 'Wharton', 'School', '.', 'He', 'was', 'appointed', 'president', 'of', 'his', 'family', "'s", 'real', 'estate', 'b
usiness', 'in', '1971', ',', 'renamed', 'it', 'The', 'Trump', 'Organization', ',', 'and', 'expanded', 'it', 'from', 'Queens', 'and', 'Brooklyn', '
into', 'Manhattan', '.', 'The', 'company', 'built', 'or', 'renovated', 'skyscrapers', ',', 'hotels', ',', 'casinos', ',', 'and', 'golf', 'courses'
, '.', 'Trump', 'later', 'started', 'various', 'side', 'ventures', ',', 'including', 'licensing', 'his', 'name', 'for', 'real', 'estate', 'and', '
consumer', 'products', '.', 'He', 'managed', 'the', 'company', 'until', 'his', '2017', 'inauguration', '.', 'He', 'co-authored', 'several', 'books
', ',', 'including', 'The', 'Art', 'of', 'the', 'Deal', '.', 'He', 'owned', 'the', 'Miss', 'Universe', 'and', 'Miss', 'USA', 'beauty', 'pageants',
 'from', '1996', 'to', '2015', ',', 'and', 'he', 'produced', 'and', 'hosted', 'The', 'Apprentice', ',', 'a', 'reality', 'television', 'show', ',',
 'from', '2003', 'to', '2015', '.', 'Forbes', 'estimates', 'his', 'net', 'worth', 'to', 'be', '$', '3.1', 'billion', '.']
```

词性标注：

```
Part of Speech: [('Trump', 'NNP'), ('was', 'VBD'), ('born', 'VBN'), ('and', 'CC'), ('raised', 'VBN'), ('in', 'IN'), ('the', 'DT'), ('New', 'NNP'),
 ('York', 'NNP'), ('City', 'NNP'), ('borough', 'NN'), ('of', 'IN'), ('Queens', 'NNP'), ('and', 'CC'), ('received', 'VBD'), ('an', 'DT'), ('economi
cs', 'NN'), ('degree', 'NN'), ('from', 'IN'), ('the', 'DT'), ('Wharton', 'NNP'), ('School', 'NNP'), ('.', '.'), ('He', 'PRP'), ('was', 'VBD'), ('a
ppointed', 'VBN'), ('president', 'NN'), ('of', 'IN'), ('his', 'PRP$'), ('family', 'NN'), ("'s", 'POS'), ('real', 'JJ'), ('estate', 'NN'), ('busine
ss', 'NN'), ('in', 'IN'), ('1971', 'CD'), (',', ','), ('renamed', 'VBD'), ('it', 'PRP'), ('The', 'DT'), ('Trump', 'NNP'), ('Organization', 'NNP'),
 (',', ','), ('and', 'CC'), ('expanded', 'VBD'), ('it', 'PRP'), ('from', 'IN'), ('Queens', 'NNP'), ('and', 'CC'), ('Brooklyn', 'NNP'), ('into', 'I
N'), ('Manhattan', 'NNP'), ('.', '.'), ('The', 'DT'), ('company', 'NN'), ('built', 'VBD'), ('or', 'CC'), ('renovated', 'VBD'), ('skyscrapers', 'NN
S'), (',', ','), ('hotels', 'NNS'), (',', ','), ('casinos', 'NNS'), (',', ','), ('and', 'CC'), ('golf', 'NN'), ('courses', 'NNS'), ('.', '.'), ('T
rump', 'NNP'), ('later', 'RB'), ('started', 'VBD'), ('various', 'JJ'), ('side', 'NN'), ('ventures', 'NNS'), (',', ','), ('including', 'VBG'), ('li
censing', 'VBG'), ('his', 'PRP$'), ('name', 'NN'), ('for', 'IN'), ('real', 'JJ'), ('estate', 'NN'), ('and', 'CC'), ('consumer', 'NN'), ('products'
, 'NNS'), ('.', '.'), ('He', 'PRP'), ('managed', 'VBD'), ('the', 'DT'), ('company', 'NN'), ('until', 'IN'), ('his', 'PRP$'), ('2017', 'CD'), ('ina
uguration', 'NN'), ('.', '.'), ('He', 'PRP'), ('co-authored', 'VBD'), ('several', 'JJ'), ('books', 'NNS'), (',', ','), ('including', 'VBG'), ('The
', 'DT'), ('Art', 'NN'), ('of', 'IN'), ('the', 'DT'), ('Deal', 'NN'), ('.', '.'), ('He', 'PRP'), ('owned', 'VBD'), ('the', 'DT'), ('Miss', 'NNP'),
 ('Universe', 'NNP'), ('and', 'CC'), ('Miss', 'NNP'), ('USA', 'NNP'), ('beauty', 'NN'), ('pageants', 'NNS'), ('from', 'IN'), ('1996', 'CD'), ('to'
, 'IN'), ('2015', 'CD'), (',', ','), ('and', 'CC'), ('he', 'PRP'), ('produced', 'VBD'), ('and', 'CC'), ('hosted', 'VBD'), ('The', 'DT'), ('Apprent
ice', 'NN'), (',', ','), ('a', 'DT'), ('reality', 'NN'), ('television', 'NN'), ('show', 'NN'), (',', ','), ('from', 'IN'), ('2003', 'CD'), ('to',
 'IN'), ('2015', 'CD'), ('.', '.'), ('Forbes', 'NNP'), ('estimates', 'VBZ'), ('his', 'PRP$'), ('net', 'JJ'), ('worth', 'NN'), ('to', 'TO'), ('be',
 'VB'), ('$', '$'), ('3.1', 'CD'), ('billion', 'CD'), ('.', '.')]
```

命名实体识别：

```
Named Entities: [('Trump', 'PERSON'), ('was', 'O'), ('born', 'O'), ('and', 'O'), ('raised', 'O'), ('in', 'O'), ('the', 'O'), ('New', 'CITY'), ('Yo
rk', 'CITY'), ('City', 'CITY'), ('borough', 'O'), ('of', 'O'), ('Queens', 'LOCATION'), ('and', 'O'), ('received', 'O'), ('an', 'O'), ('economics',
 'O'), ('degree', 'O'), ('from', 'O'), ('the', 'O'), ('Wharton', 'ORGANIZATION'), ('School', 'ORGANIZATION'), ('.', 'O'), ('He', 'O'), ('was', 'O'
), ('appointed', 'O'), ('president', 'TITLE'), ('of', 'O'), ('his', 'O'), ('family', 'O'), ("'s", 'O'), ('real', 'O'), ('estate', 'O'), ('business
', 'O'), ('in', 'O'), ('1971', 'DATE'), (',', 'O'), ('renamed', 'O'), ('it', 'O'), ('The', 'O'), ('Trump', 'ORGANIZATION'), ('Organization', 'ORGA
NIZATION'), (',', 'O'), ('and', 'O'), ('expanded', 'O'), ('it', 'O'), ('from', 'O'), ('Queens', 'LOCATION'), ('and', 'O'), ('Brooklyn', 'CITY'), (
'into', 'O'), ('Manhattan', 'CITY'), ('.', 'O'), ('The', 'O'), ('company', 'O'), ('built', 'O'), ('or', 'O'), ('renovated', 'O'), ('skyscrapers',
 'O'), (',', 'O'), ('hotels', 'O'), (',', 'O'), ('casinos', 'O'), (',', 'O'), ('and', 'O'), ('golf', 'O'), ('courses', 'O'), ('.', 'O'), ('Trump',
 'PERSON'), ('later', 'O'), ('started', 'O'), ('various', 'O'), ('side', 'O'), ('ventures', 'O'), (',', 'O'), ('including', 'O'), ('licensing', 'O'
), ('his', 'O'), ('name', 'O'), ('for', 'O'), ('real', 'O'), ('estate', 'O'), ('and', 'O'), ('consumer', 'O'), ('products', 'O'), ('.', 'O'), ('He
', 'O'), ('managed', 'O'), ('the', 'O'), ('company', 'O'), ('until', 'O'), ('his', 'O'), ('2017', 'DATE'), ('inauguration', 'O'), ('.', 'O'), ('He
', 'O'), ('co-authored', 'O'), ('several', 'O'), ('books', 'O'), (',', 'O'), ('including', 'O'), ('The', 'O'), ('Art', 'O'), ('of', 'O'), ('the',
 'O'), ('Deal', 'O'), ('.', 'O'), ('He', 'O'), ('owned', 'O'), ('the', 'O'), ('Miss', 'STATE_OR_PROVINCE'), ('Universe', 'MISC'), ('and', 'O'), ('M
iss', 'STATE_OR_PROVINCE'), ('USA', 'COUNTRY'), ('beauty', 'O'), ('pageants', 'O'), ('from', 'O'), ('1996', 'DATE'), ('to', 'DATE'), ('2015', 'DAT
E'), (',', 'O'), ('and', 'O'), ('he', 'O'), ('produced', 'O'), ('and', 'O'), ('hosted', 'O'), ('The', 'O'), ('Apprentice', 'O'), (',', 'O'), ('a',
 'O'), ('reality', 'O'), ('television', 'O'), ('show', 'O'), (',', 'O'), ('from', 'O'), ('2003', 'DATE'), ('to', 'DATE'), ('2015', 'DATE'), ('.',
 'O'), ('Forbes', 'ORGANIZATION'), ('estimates', 'O'), ('his', 'O'), ('net', 'O'), ('worth', 'O'), ('to', 'O'), ('be', 'O'), ('$', 'MONEY'), ('3.1'
, 'MONEY'), ('billion', 'MONEY'), ('.', 'O')]
```

句法分析：

```
Constituency Parsing: (ROOT
  (S
    (NP (NNP Trump))
    (VP
      (VP (VBD was)
        (VP (VBN born)
          (CC and)
          (VBN raised)
          (PP (IN in)
            (NP
              (NP (DT the)
                (NML (NNP New) (NNP York) (NNP City))
                (NN borough))
              (PP (IN of)
                (NP (NNP Queens)))))))
      (CC and)
      (VP (VBD received)
        (NP (DT an) (NN economics) (NN degree))
        (PP (IN from)
          (NP (DT the) (NNP Wharton) (NNP School)))))
    (. .)))
```

依存句法分析：

```
Dependency Parsing: [('ROOT', 0, 3), ('nsubj:pass', 3, 1), ('aux:pass', 3, 2), ('cc', 5, 4), ('conj', 3, 5), ('case', 11, 6), ('det', 11, 7), ('co
mpound', 9, 8), ('compound', 10, 9), ('compound', 11, 10), ('obl', 3, 11), ('case', 13, 12), ('nmod', 11, 13), ('cc', 15, 14), ('conj', 3, 15), ('
det', 18, 16), ('compound', 18, 17), ('obj', 15, 18), ('case', 22, 19), ('det', 22, 20), ('compound', 22, 21), ('obl', 15, 22), ('punct', 3, 23),
('ROOT', 0, 3), ('nsubj:pass', 3, 1), ('aux:pass', 3, 2), ('obj', 3, 4), ('case', 11, 5), ('nmod:poss', 7, 6), ('nmod:poss', 11, 7), ('case', 7, 8
), ('amod', 10, 9), ('compound', 11, 10), ('nmod', 4, 11), ('case', 13, 12), ('obl', 3, 13), ('punct', 3, 14), ('conj', 3, 15), ('nsubj', 19, 16),
 ('det', 19, 17), ('compound', 19, 18), ('xcomp', 15, 19), ('punct', 3, 20), ('cc', 22, 21), ('conj', 3, 22), ('obj', 22, 23), ('case', 25, 24), (
'obl', 22, 25), ('cc', 27, 26), ('conj', 25, 27), ('case', 29, 28), ('obl', 25, 29), ('punct', 3, 30), ('ROOT', 0, 3), ('det', 2, 1), ('nsubj', 3,
 2), ('cc', 5, 4), ('conj', 3, 5), ('obj', 3, 6), ('punct', 6, 7), ('conj', 6, 8), ('punct', 6, 9), ('conj', 6, 10), ('punct', 6, 11), ('cc', 14,
12), ('compound', 14, 13), ('conj', 6, 14), ('punct', 3, 15), ('ROOT', 0, 3), ('nsubj', 3, 1), ('advmod', 3, 2), ('amod', 6, 4), ('compound', 6, 5
), ('obj', 3, 6), ('punct', 6, 7), ('aux', 9, 8), ('acl', 6, 9), ('nmod:poss', 11, 10), ('obj', 9, 11), ('case', 14, 12), ('amod', 14, 13), ('obl'
, 9, 14), ('cc', 17, 15), ('compound', 17, 16), ('conj', 14, 17), ('punct', 3, 18), ('ROOT', 0, 2), ('nsubj', 2, 1), ('det', 4, 3), ('obj', 2, 4),
 ('case', 8, 5), ('nmod:poss', 8, 6), ('nummod', 8, 7), ('obl', 2, 8), ('punct', 2, 9), ('ROOT', 0, 2), ('nsubj', 2, 1), ('amod', 4, 3), ('obj', 2
, 4), ('punct', 4, 5), ('case', 8, 6), ('det', 8, 7), ('nmod', 4, 8), ('case', 11, 9), ('det', 11, 10), ('nmod', 8, 11), ('punct', 2, 12), ('ROOT'
, 0, 2), ('nsubj', 2, 1), ('det', 5, 3), ('compound', 5, 4), ('compound', 10, 5), ('cc', 8, 6), ('compound', 8, 7), ('conj', 5, 8), ('compound', 1
0, 9), ('obj', 2, 10), ('case', 12, 11), ('obl', 2, 12), ('case', 14, 13), ('obl', 12, 14), ('punct', 2, 15), ('cc', 18, 16), ('nsubj', 18, 17), (
'conj', 2, 18), ('cc', 20, 19), ('conj', 18, 20), ('det', 22, 21), ('obj', 18, 22), ('punct', 22, 23), ('det', 27, 24), ('compound', 27, 25), ('co
mpound', 27, 26), ('appos', 22, 27), ('punct', 22, 28), ('case', 30, 29), ('obl', 18, 30), ('case', 32, 31), ('obl', 30, 32), ('punct', 2, 33), ('
ROOT', 0, 2), ('nsubj', 2, 1), ('nmod:poss', 5, 3), ('amod', 5, 4), ('obj', 2, 5), ('dep', 2, 6), ('dep', 6, 7), ('dep', 7, 8), ('compound', 10, 9
), ('nummod', 8, 10), ('punct', 8, 11)]
```

结果分析与体会：

使用 jieba 进行分词功能多样，可以使用全模式，默认模式，新词识别，搜索引擎等模式。全模式可以识别不在词典中的模棱两可的词语，例如“土鸡蛋”，会分析出“土鸡”和“鸡蛋”，默认模式会按照原文一一划分词语。新词识别可以使机器自动识别不在词典中的新词。

StanfordCoreNLP 进行分词时，可以进行词性标注和句法分析，可以识别某些词的词性，然后不断进行归结，分析句法等。

NLTK 和 Spacy 进行分词的模式较为简单，但是有很多额外功能。比如 NLTK 可以进行词频统计，词干提取，词性还原等。