计 算 机 科 学 与 技 术 学 院

人 工 智 能 实 践 中 期 报 告

全自动的 3D 人类动作捕捉与动画生成平台

姓　　名：薛润泽

姓　　名：董雷超

姓　　名：许学祥

中期报告日期：2024-11-3

主要研究内容及进度情况：

本项目旨在将深度学习、计算机视觉和计算机图形学等前沿技术进行深度整合，构建一个高效、稳定的全自动 3D 动作捕捉系统。该系统不仅能够精准捕捉人体动作，还能生成自然流畅的 3D 动画，突破了传统方法在灵活性和成本上的限制。

项目整体分为三大模块：动作捕捉、声音合成和唇部驱动。动作捕捉部分主要完成读取视频流，从视频中检测出人体关节点的位置坐标，再根据提取出的位置坐标，驱动火柴人运动。声音合成部分主要完成读取目标音色语音（大约含有有效内容段 15-30s 即可），从语音中提取出声音特征后训练模型，再从文本中生成语音，将生成语音输入经过声音特征训练后的模型后输出目的音色语音。唇部驱动部分基于前两个模块生成的指定人物模型的流畅动画视频和指定音色的连贯声音片段，将动画和声音无缝融合。同时，利用声音驱动视频中人物的唇部动作，使其与语音发音高度同步、自然流畅。

截至中期汇报，项目各个模块均已基本独立完成，并取得了理想的阶段性成果。

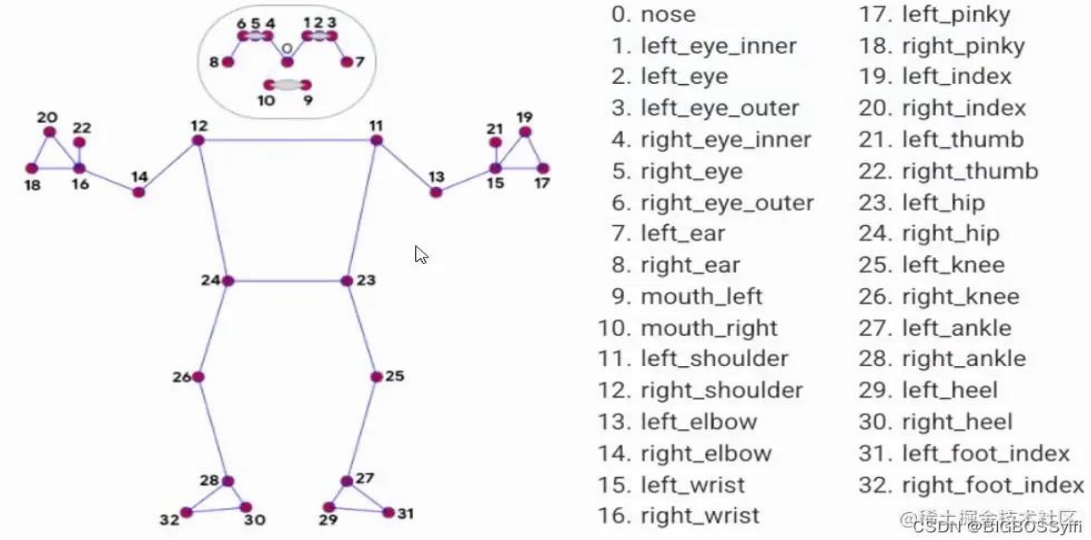
目前已完成的详细工作及结果：

动作捕捉：

动作捕捉主要完成读取视频流，从视频中检测出人体关节点的位置坐标，再根据提取出的位置坐标，驱动火柴人运动。

读取视频流模块采用的是 OpenCV 的 cv2.VedioCapture(“vedio_name”).read()功能。该功能可以逐帧读取出视频的图像。假设读取出的变量为 image。

人体关节的位置坐标检测环节，使用的是 Mediapipe。Mediapipe 是 google 的一个开源项目，可以进行人体 3D 识别，获取人体的 33 个关节点的三维坐标信息。

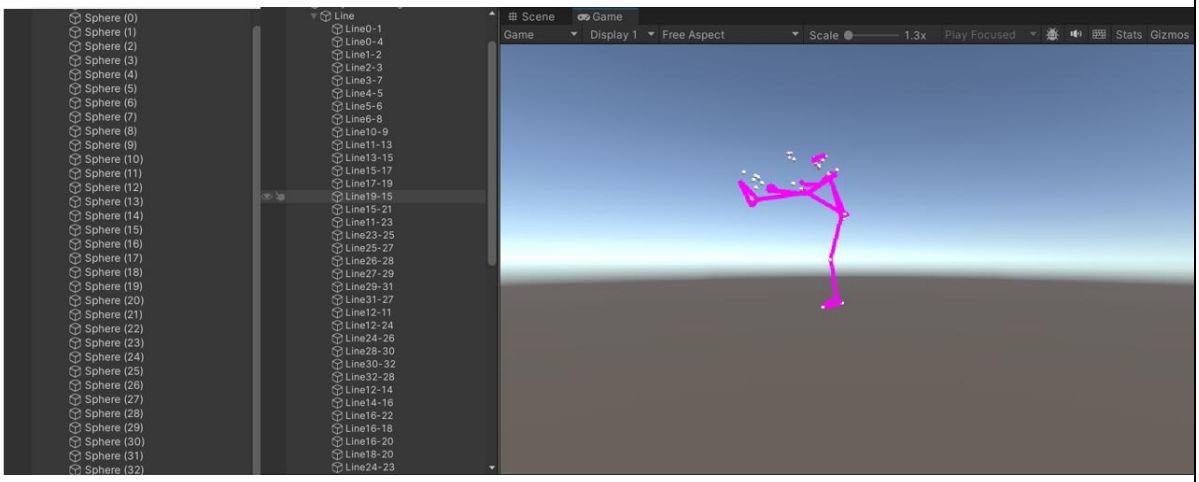


对于读取的每一帧图像 image，利用 Mediapipe.solutions.pose 进行姿势检测，这种方法将会检测出其他关节点以人体臀部为中心的相对坐标。臀部的坐标为（0，0，0），其他关节点的坐标是在$(-1,1)^3$的立方体的空间内。

这种方法存在的问题就是，如果所有关节点的三维坐标均是相对于臀部中心的坐标，那么在人体进行大幅度移动，即臀部中心进行大幅度移动时，这种检测方式无法检测位置的变化。

解决办法就是要检测人体关节的绝对坐标而非相对坐标，利用 cvzone.PoseModule 中的模块 PoseDector 检测出人体的三维坐标，人体的坐标位置是相对于视频左上角的坐标。也就是说，当相机是固定机位的时候，可以检测出人体的位置变化。但是如果

相机是跟随人体进行移动的，人体的位置坐标相对于视频左上角不会发生明显变化，那么就无法检测出人体的位置变化。因此，这个功能实现的前提条件是要固定机位。在读取出人体关节信息后，将关节坐标存储到 Motion.txt 文件中。接着在 Unity 中创建 33 个 Sphere（模拟人体的 33 个关节点）和 33 个 Cube（模拟骨骼）。用 Motion.txt 的关节坐标驱动 Sphere 进行运动，同时用 Cube 连接对应的 Sphere，就可以实现驱动火柴人运动的功能。



声音合成：

声音合成部分主要完成读取目标音色语音（大约含有有效内容段 15-30s 即可），从语音中提取出声音特征后训练模型，再从文本中生成语音，将生成语音输入经过声音特征训练后的模型后输出目的音色语音。整体模型框架源自开源项目 GPT-SoVITS。GPT-SoVITS 主要由两个部分组成：一个是 GPT 部分，另一个是 SoVITS 部分。



GPT 是一种基于 Transformer 架构的预训练语言模型。它通过学习大量文本数据，能够生成与训练数据风格相似的文本。在 GPT-SoVITS 中，GPT 技术被用于文本到语音的合成部分，将输入的文本转换成语音。而 SoVITS 是一种语音转换模型，它能够在少量样本的情况下实现高质量的语音转换。通过训练 SoVITS 模型，系统可以将一种声音转换成另一种声音，同时保持语音的连贯性和自然度。

在运行原理上，用户输入一个声音样本，系统首先使用 SoVITS 模型进行声音特征的提取和转换。接着，系统利用 GPT 技术将输入的文本转换成语音特征，这些特征

经过 SoVITS 模型的微调后，与转换后的声音特征相结合，生成最终的语音输出。

唇部驱动：

唇部驱动技术通过将音频与视频同步，使捕捉到的指定形象的唇部动作与指定音色的声音高度匹配。在本项目的唇部驱动模块中，主要采用 Wav2Lip 模型进行驱动，利用生成对抗网络（GAN）架构，根据输入音频生成对应的唇部动作。Wav2Lip 通过深度学习技术生成与音频同步的唇部动作，模型接受音频信号和动画视频作为输入。

首先，模型分析输入音频的语音特征，提取音素和韵律等信息，为后续唇部动作生成提供依据。接着，模型对包含指定角色的视频进行分析，通过 S3FD 模型提取面部特征并重点关注嘴唇位置，再通过 GAN 实现嘴唇驱动。模型由四个主要部分组成：(1)音频编码器：提取音频特征，使生成器能够理解音频内容并与视频的唇形同步。(2)视频编码器：将视频帧编码为特征向量，帮助生成器识别并保持原始人物的面部特征。(3)融合模块：将音频和视频特征融合，确保生成的唇部动作与音频内容在视觉上同步。(4)生成器与判别器：生成逼真的唇部动作，使嘴唇运动能够与输入音频的节奏和内容高度匹配，并通过对抗学习提高模型生成的真实性和同步性。

为直观展示唇部驱动效果，选取了人物嘴唇始终紧闭的视频作为原始素材。经过指定音频的驱动后，最终生成的视频中，人物嘴唇根据音频内容有规律地上下运动，保持节奏一致。通过截取原始视频与生成视频中相同的一帧进行对比，可以发现二者的差异仅在于目标人物的唇部形状，并且唇部形状与此时的声音完全匹配。





目前存在的困难与问题：

动作捕捉：

（1）骨骼模型过于简陋。目前只能驱动简单的火柴人进行运动，既没法将蒙皮套在火柴人上面，也无法驱动已有的模型（指那些别人已经建立好的模型）。这就造成了动画的效果不好，与后面两个模块难以结合。

（2）自动化效果差。在提取出人体关节点坐标后，需要在 Unity 手动创建 33 个 Sphere 和 33 个 Cube，自动化效果差。

声音合成：

（1）虽然声音合成的架构和代码是开源的，但是我们的目的是将声音合成模块整合到整个项目中，而 GPT-SoVITS 项目没有留出代码接口，所以需要对其功能性代码改写接口。目前遇到了在源项目封闭运行单个功能块成功，但是改写接口转接到命令行运行失败的情况。

（2）改写代码接口要求对代码熟悉。而实际上 GPT-SoVITS 代码量大，理解原理需要花费一定时间，造成了工作量大的困难。

唇部驱动：

在唇部驱动过程中，因为模型根据音频和视频进行逐帧配对处理，所以要求输入的视频与音频在长度和帧率上完全一致。这一要求对视频与音频的格式和条件较为严格，因此，后续可以在模型中增加一个模块，自动捕捉并调整音频片段，使其与视频时长和帧率相匹配，从而降低使用门槛，简化操作流程。

后期拟完成的研究工作及进度安排：

在后期开发中，将进一步完善动作捕捉、声音合成和唇部驱动三个模块，解决当前存在的问题，专注于代码的重构与优化，整合成一个独立、稳定的系统。同时，将设计用户友好的界面，确保界面直观、操作流畅。此外，还将开发功能完善的网页版本，确保在线操作完整、用户体验良好。最终通过全面的查漏补缺，进一步提升系统的稳定性和用户体验。项目完成后，将捕捉团队成员的动作生成动画短片，作为产品效果展示。

进度安排

（ 2024 年 11 月 3 日 至 2024 年 12 月 22 日）

第十周	解决动作捕捉、声音合成和唇部驱动三个模块中存在的各类问题
第十一周	重构和优化代码，提高模块运行效率和可维护性
第十二周	整合三个模块，形成一个独立且稳定的系统
第十三周	
第十四周	设计用户友好的界面，确保界面直观，操作流畅
第十五周	开发功能齐全的网页版本，确保完整的在线操作体验
第十六周	进行全面的查漏补缺，进一步优化系统稳定性