计 算 机 科 学 与 技 术 学 院

人 工 智 能 实 践 终 期 报 告

3D 人类动作捕捉与动画生成平台

姓　　名：薛润泽

姓　　名：董雷超

姓　　名：许学祥

中期报告日期：2024-12-22

完成内容概述：

本项目旨在将深度学习、计算机视觉和计算机图形学等前沿技术进行深度整合，构建一个高效、稳定的全自动 3D 动作捕捉系统。该系统不仅能够精准捕捉人体动作，还能生成自然流畅的 3D 动画，突破了传统方法在灵活性和成本上的限制。

项目整体分为三大模块：动作捕捉、声音合成和唇部驱动。动作捕捉部分。。。。声音合成部分主要完成读取目标语音，从语音中提取出声音特征并训练模型。最后根据文本指示内容，使用训练模型生成目的语音。唇部驱动部分。。。。

项目最终以网页的形式将动作捕捉、声音合成和唇部驱动三个模块整合到一起，实现自动化和高效的动画生成平台，使得任何人都可以在无基础代码知识的情况下进行简单、高效的动画生成。

各模块详细工作及效果：

动作捕捉：

动作捕捉部分原理：

。。。。

动作捕捉主要完成工作：

。。。

动作捕捉效果展示：

。。。

声音合成：

声音合成部分原理：

声音合成部分完成读取目标语音，从语音中提取出声音特征并训练模型。最后根据文本指示内容，使用训练模型生成目的语音。整体模型框架源自开源项目 GPT-SoVITS。GPT-SoVITS 主要由两 GPT 部分与 SoVITS 部分组成。

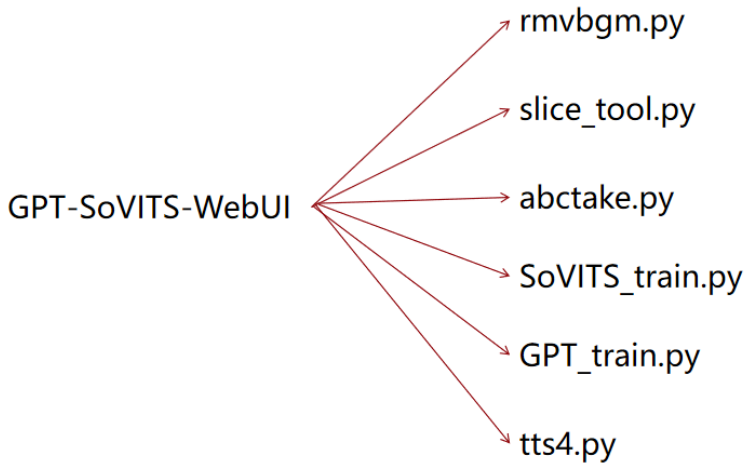


GPT 是一种基于 Transformer 架构的预训练语言模型。它通过学习大量文本数据，能够生成与训练数据风格相似的文本。在 GPT-SoVITS 中，GPT 技术被用于文本到语音的合成部分，将输入的文本转换成语音。而 SoVITS 是一种语音转换模型，它能够在少量样本的情况下实现高质量的语音转换。通过训练 SoVITS 模型，系统可以将一种声音转换成另一种声音，同时保持语音的连贯性和自然度。

在运行原理上，用户输入一个声音样本，系统首先使用 SoVITS 模型进行声音特征的提取和转换。接着，系统利用 GPT 技术将输入的文本转换成语音特征，这些特征经过 SoVITS 模型的微调后，与转换后的声音特征相结合，生成最终的语音输出。

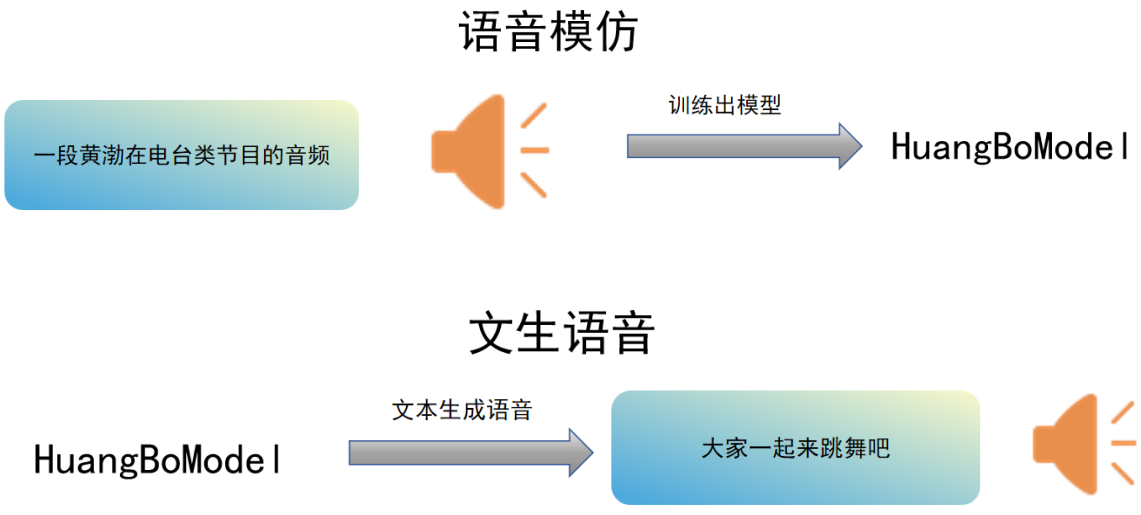
声音合成主要工作：

声音合成部分主要完成接口对接工作。由于项目之间的独立性、完整性，将项目连接整合到一起并不容易。对于声音合成部分的开源项目 GPT-SoVITS-WebUI 来说，项目使用 WebUI 将代码整合到一起，并没有提供其他接口。我们将 WebUI 整合的代码进行模块化拆分，根据各模块功能拆分出六个 python 文件，方便使用命令行进行后续调用操作。



声音合成效果展示：

使用黄渤电台语音完成 HuangboModel 模型训练，并进行语音生成，效果理想。



唇部驱动：

唇部驱动部分原理：

。 。 。

唇部驱动主要完成工作：

。 。 。 。

唇部驱动效果展示：

、 、 、

可以更进一步优化的内容：

动作捕捉：

声音合成：

GPT-SoVITS 项目中使用了预训练模型，而预训练模型中使用了大量非中文语音数据进行训练，所以导致我们进行微调训练后的模型在面对某些特定文本进行文生语音时出现“洋腔洋调”。需要进一步微调模型来优化解决。

唇部驱动：

学期工作进度展示：

（ 2024 年 9 月 15 日至 2024 年 12 月 22 日）

第二至九周	（1）开题调研 （2）动作捕捉、声音合成、唇部驱动三模块初步独立完成
第十周	解决动作捕捉、声音合成和唇部驱动三个模块中存在的各类问题
第十一周	重构和优化代码，提高模块运行效率和可维护性
第十二周	整合三个模块，形成一个独立且稳定的系统
第十三周	
第十四周	设计用户友好的界面，确保界面直观，操作流畅
第十五周	开发功能齐全的网页版本，确保完整的在线操作体验
第十六周	进行全面的查漏补缺，进一步优化系统稳定性