NLP

n-gram

1. 什么是 n-gram 模型

   n-gram 指文本中连续出现的 n 个语词，n-gram 模型是一种基于马尔可夫链的概率语言模型，它通过考虑序列中历史的 $n-1$ 个词来预测当前词的概率。

   - 1-gram（unigram）模型：单个词的概率独立于历史
   - 2-gram（bigram）模型：考虑当前词和前一个词的联合概率
   - 3-gram（trigram）模型：考虑当前词和前两个词的联合概率

2. 写出 “I am in Shandong University” 的 1-gram，2-gram，3-gram（加入 <BOS> 和 <EOS>）：

   - 1-gram (unigram)

     ```
     <BOS>,  I,  am,  in,  Shandong, University, <EOS>
     ```

   - 2-gram (bigram)

     ```
     <BOS> I,  I am,  am in,  in Shandong,  Shandong University,
     University <EOS>
     ```

   - 3-gram (trigram)

     ```
     <BOS> I am,  I am in,  am in Shandong,
     in Shandong University,  Shandong University <EOS>
     ```

3. 用以下四个句子作为训练集，计算第二问句子的2-gram概率

   > <BOS> I am a student. <EOS>
   >
   > <BOS> I am in China. <EOS>
   >
   > <BOS> She is in Shandong University. <EOS>
   >
   > <BOS> We are in the library. <EOS>

   2-gram 概率计算公式：

   $$P(w_n|w_{n-1}) = \frac{Count(w_{n-1}, w_n)}{Count(w_{n-1})}$$

   对于每个 2-gram：

$P(I|<BOS>) = 2/4 = 0.5$

$P(am|I) = 2/2 = 1$

$P(in|am) = 1/2 = 0.5$

$P(Shandong|in) = 1/3 \approx 0.33$

$P(University|Shandong) = 1/1 = 1$

$P(<EOS>|University) = 1/1 = 1$

整个句子的 2-gram 概率是这些概率的乘积：

$$P(s) = 0.5 * 1 * 0.5 * 0.33 * 1 * 1 \approx 0.0825 = 8.25\%$$

分词

1. 常见的中文分词方法
    - 最大匹配法
    - 最少分词法
    - 基于语言模型的分词方法
    - 基于 HMM 的分词方法
    - 由字构词的分词方法
    - 生成式方法与判别式方法的结合
2. 中文使用语言模型分词的过程（举例）

    对于待切分的句子 $S = z_1 z_2 \dots z_m$，列举所有可能的切分方案 $W = w_1 w_2 \dots w_k (1 \leqslant k \leqslant m)$，并转换为词类序列 $C = c_1 c_2 \dots c_m$，目标是找到最优切分 $C^* = \arg\max P(C|S) = \arg\max P(C)P(S|C)$，其中 $P(C)$ 是语言模型，$P(C|W)$ 是生成模型。
    - 待切分句子 S：陈老师捞捞我
    - 考虑两种可能的切分方案

        ```
        W1: 陈老师/捞捞/我
        W2: 陈/老师/捞/捞/我
        ```

    - 将词转换为词类序列

        ```
        C1: PN/捞捞/我
        C2: PN/老师/捞/捞/我
        ```

    - 使用三元语法模型计算 $P(C)$

```
P(C1) = P(PN) * P(捞捞|PN) * P(我|PN,捞捞)
P(C2) = P(PN) * P(老师|PN) * P(捞|PN,老师) * P(捞|老师,捞) * P(我|捞,捞)
```

- 计算生成模型 $P(S|C)$

```
P(S|C1) = P(陈老师|PN) * P(捞捞|捞捞) * P(我|我)
P(S|C2) = P(陈|PN) * P(老师|老师) * P(捞|捞) * P(捞|捞) * P(我|我)
```

- 计算每种切分方案的总概率

$$P(W_1, C_1|S) = P(C_1) * P(S|C_1)$$
$$P(W_2, C_2|S) = P(C_2) * P(S|C_2)$$

- 选择概率最大的切分方案作为最终结果

  假设计算结果为 $P(W_1, C_1|S) > P(W_2, C_2|S)$ ，则最终的分词结果为

$$陈老师/捞捞/我$$

HMM

1. 写出 HMM 算法的组成部分并解释

   对于状态序列 $Q = q_1 q_2 .. q_T$ 和输出序列 $O = o_1 o_2 ... o_T$

   - 模型中的状态数 N
   - 从每一个状态可能输出的不同的符号数 M
   - 状态转移概率矩阵 A：表示从一个状态转移到另一个状态的概率

$$\begin{cases} a_{ij} = p(q_{t+1} = s_j \mid q_t = s_i), \quad 1 \le i, j \le N \\ a_{ij} \ge 0 \\ \sum_{j=1}^{N} a_{ij} = 1 \end{cases}$$

   - 观察符号概率分布矩阵 B：表示在某个状态下观察到特定符号的概率

$$\begin{cases} b_j(k) = p(o_t = v_k \mid q_t = s_j), \quad 1 \le j \le N, \quad 1 \le k \le M \\ b_j(k) \ge 0 \\ \sum_{k=1}^{M} b_j(k) = 1 \end{cases}$$

   - 初始状态的概率分布 π：表示初始时刻各个状态的概率分布

$$\begin{cases} \pi_i = p(q_1 = s_i), \quad 1 \le i \le N \\ \pi_i \ge 0 \\ \sum_{i=1}^{N} \pi_i = 1 \end{cases}$$

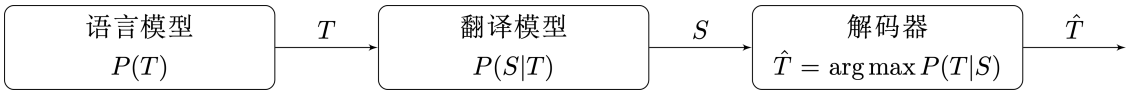
2. 说明 HMM 能够同时实现分词和词性标注的原理

将汉语自动分词结果作为观察序列 $O = O_1O_2 \dots O_T$

- 对于分词任务，目标是求解 $\hat{O} = \arg\max p(O|\mu)$，即对于给定的输入句子，找到所有可能的分词序列 O 中使概率 $p(O|\mu)$ 最大的解（分词）
- 对于词性标注任务，目标是求解 $\hat{Q} = \arg\max p(Q|O,\mu)$，即快速选择“最优”的状态序列 Q（词性序列），使其最好地解释观察序列 $p(Q|O,\mu)$（词性标注）

机器翻译

1. 画出统计机器翻译图示，通过概率公式说明翻译过程



源语言句子：$S = s_1^m = s_1 s_2 \cdots s_m$

目标语言句子：$T = t_1^l = t_1 t_2 \cdots t_l$

由贝叶斯公式得：

$$P(T|S) = \frac{P(T) \times P(S|T)}{P(S)}$$

求上式最大值，即

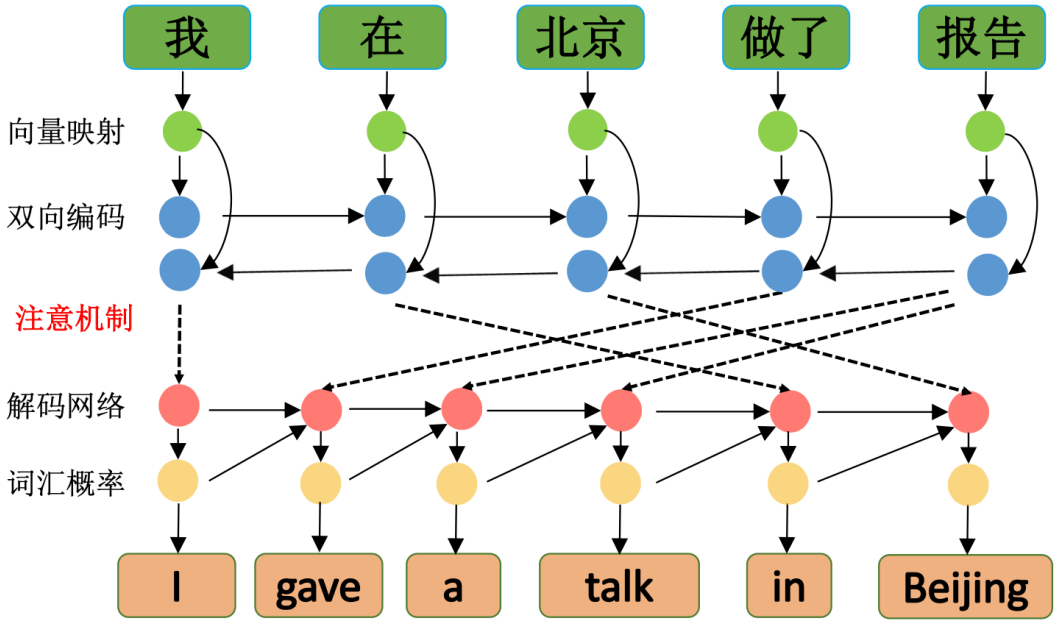
$$T' = \arg\max_T P(T|S) = \arg\max_T \ P(T) \times P(S|T)$$

其中 $P(T)$ 为目标语言的语言模型，$P(S|T)$ 为翻译模型

因此，统计翻译中的三个关键为：

- 估计语言模型概率 $P(T)$
- 估计翻译概率 $P(S|T)$
- 快速有效地搜索 T ，求得使 $P(T) \times P(S|T)$ 最大的 T'

2. 画出神经机器翻译模型，并解释翻译过程



- 将输入的每个词转换为密集的向量表示，这些向量捕捉词的语义信息
- 使用双向循环神经网络处理向量序列，捕捉上下文信息，生成每个词的上下文敏感表示
- 使用另一个循环神经网络，结合编码器的输出和注意力权重来预测下一个词
- 在解码过程中，注意力机制计算输入词与输出词的相关性权重，模型聚焦于最相关的源词
- 使用 softmax 函数将解码器的输出转换为概率分布，选择概率最高的词作为输出

词向量

1. 对比离散和连续表示的优缺点

   离散表示（如one-hot编码）：

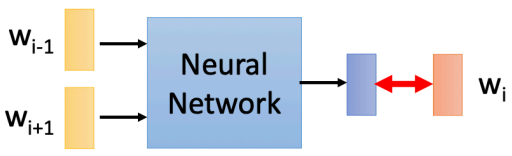
   - 优点：简单直观，容易理解
   - 缺点：维度灾难，无法表示词之间的关系

   连续表示（如词嵌入）：

   - 优点：低维稠密向量，可以捕捉词之间的语义关系
   - 缺点：训练复杂，结果不易解释

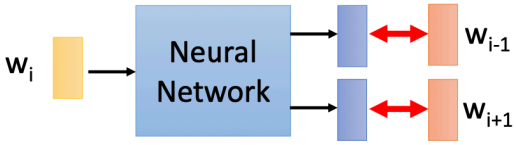
2. 画出 CBOW 和 skip-gram 的网络结构，解释原理

   CBOW：



   模型接收目标词周围的上下文词作为输入，这些上下文词的词向量被平均或求和，然后通过隐藏层映射到输出层，预测中心目标词，通过最小化预测错误来训练模型。

Skip-gram：



模型接收一个目标词作为输入，通过隐藏层，模型尝试预测这个词周围的上下文词。对于每个训练样本，模型都会更新以最大化正确预测上下文词的概率。

预训练模型

1. 三个 mask 的例子，说明预训练模型能够从中学到什么

   略

2. 举出Encoder、Decoder、Encoder-Decoder三个结构的代表模型，比较优缺点，并结合例子说明原理

   Encoder (BERT)：

   - 优点：双向理解，适合多种NLP任务
   - 缺点：不适合生成，计算开销大
   - 原理：利用 MLM 和 NSP 预训练，学习双向上下文

   Decoder (GPT)：

   - 优点：擅长生成任务，文本流畅
   - 缺点：只有单向上下文理解
   - 原理：单向语言模型预训练，预测下一个词

   Encoder-Decoder (T5)：

   - 优点：兼具理解和生成能力，适用广泛
   - 缺点：模型较大，计算成本高
   - 原理：将所有 NLP 任务视为文本到文本转换

情感分析

1. 情感分析的主要技术有哪些？请简单说明
   - 情感分类：对文本进行情感倾向性的分类，如积极、消极或中性
   - 情感元素抽取：提取文本中的情感词、评价对象等关键元素
   - 跨领域情感分析：将一个领域的情感分析模型迁移到另一个领域
   - 个性化情感分析：考虑用户个人特征进行定制化的情感分析
   - 隐式情感分析：分析没有明显情感词的隐含情感表达

- 情感原因发现：探究引发某种情感的原因
- 情感生成：自动生成带有特定情感的文本，如评论或对话

文本摘要

1. 文本自动摘要技术的分类，并简单介绍。

   文档数目：

   - 单文档摘要：对单个文档生成摘要
   - 多文档摘要：对多个相关文档生成摘要

   输入输出语言关系：

   - 单语摘要：输入和输出为同一种语言
   - 跨语言摘要：输入和输出为不同语言
   - 多语言摘要：可处理多种语言的输入并生成相应语言的摘要

   是否有用户输入：

   - 通用摘要：不需要用户输入，直接生成摘要
   - 用户查询摘要：根据用户的查询生成相关摘要

   摘要方法：

   - 抽取式摘要：直接从原文中抽取重要句子组成摘要
   - 压缩式摘要：抽取并简化原文中的重要句子构成摘要
   - 生成式摘要(理解式摘要)：改写或重新组织原文内容形成摘要

   摘要长度：

   - 标题式摘要：非常简短，类似标题
   - 短摘要：相对简短的摘要
   - 长摘要：较长的摘要

迁移学习

1. 通过 源数据/目标数据 有/无 标签，区别四种迁移学习

	Source Data: Labelled	**Source Data: Unlabeled**
Target Data: Labelled	Fine-tuning Multitask Learning	Self-taught learning
Target Data: Unlabeled	Domain-adversarial training Zero-shot learning	Self-taught Clustering

开放题

你知道的最新的NLP技术，你的看法，你对于它的改进，展望和应用