机器翻译

画出统计机器翻译的图示，通过概率公式说明翻译过程

画出基本的神经机器翻译模型图示，介绍翻译流程?

机器翻译概论

机器翻译的困难

- 普遍存在的歧义和未知现象
- 机器翻译不仅是字符串的转换
- 机器翻译的解不唯一，而且始终存在人为的标准

基本翻译方法:

- 直接转换法

  从源句子表层出发，将单词，短语，句子直接换成目标语言。必要时进行简 单的语序调整

- 基于规则的翻译方法

  基于规则的翻译过程分成6个步骤:
  (*a*) 对源语言句子进行词法分析
  (*b*) 对源语言句子进行句法/语义分析
  (*c*) 源语言句子结构到译文结构的转换
  (*d*) 译文句法结构生成
  (*e*) 源语言词汇到译文词汇的转换
  (*f*) 译文词法选择与生成

  执行过程是：独立分析--独立生成--相关转换，又称为基于转换的翻译方法

  优点：可以较好的保持原文的结构，对语言现象已知或句法结构规范的源语 言具有较强的处理能力和较好翻译效果

  缺点：规则由人工编写

- 基于中间语言的翻译方法

  方法：输入语句->中间语言->翻译结果

  优点：可以不考虑具体的翻译语言对，因此适合多语言之间的互译

  缺点：如何设计和定义中间语言的表达方式，如何维度都很难

- 基于语料库的翻译方法 -
  - 基于事例的翻译方法

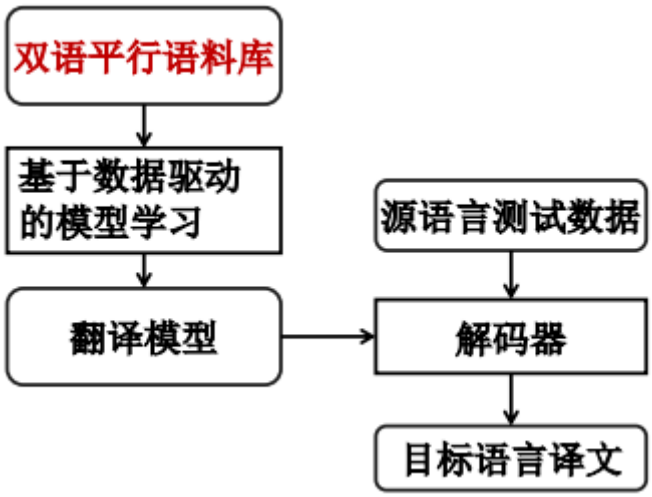
    方法：输入语句->与事例相似度比较->翻译结果

    优点：不要求源语言句子必须符号语法规定，不需要对源语言句子做深 入分析

    缺点：两个不同句子间的相似性难以把握。难

  - 统计翻译方法 -
  - 神经网络机器翻译

统计机器翻译



源语言句子： $S = s_1^m = s_1 s_2 \cdots s_m$

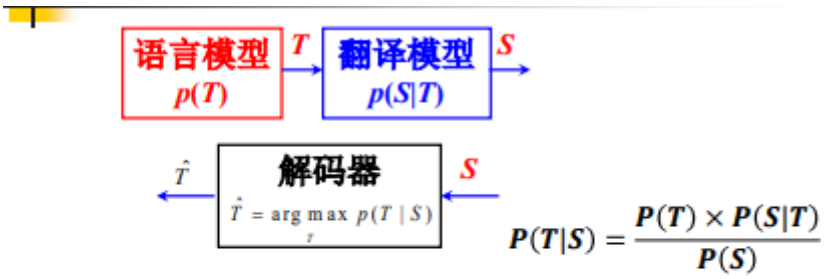
目标语言句子： $T = t_1^l = t_1 t_2 \cdots t_l$

贝叶斯公式： $P(T|S) = \dfrac{P(T) \times P(S|T)}{P(S)}$

$$T' = \arg\max_T P(T) \times P(S|T)$$

语言模型
Language model, LM

翻译模型
Translation model, TM



统计翻译中的三个关键问题：

(1)估计语言模型概率 $p(T)$；

(2)估计翻译概率 $p(S|T)$；

(3)快速有效地搜索T 使得 $p(T) \times p(S \mid T)$ 最大。

神经机器翻译

统计机器翻译

优点：

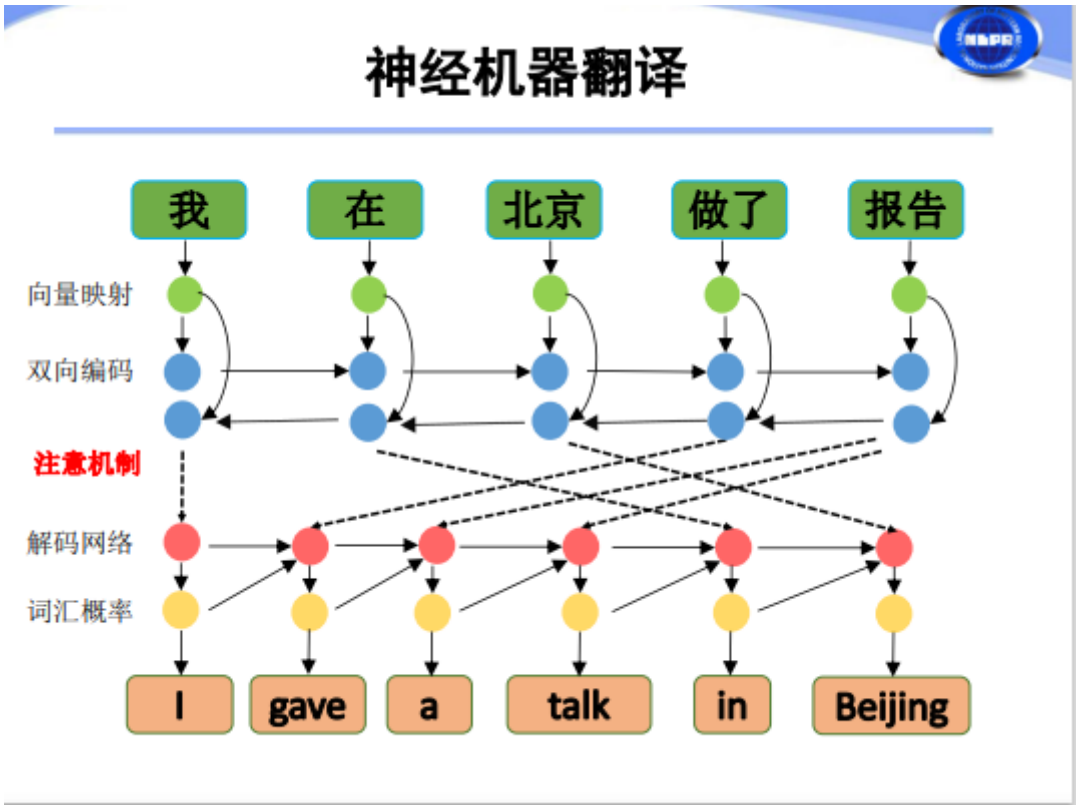
1. 可解释性高
2. 模块随便加
3. 错误易追踪

缺点：

1. 数据系数
2. 复杂结构无能为力
3. 强烈依赖先验知识

统计机器翻译（离散符号表示方法）——>神经机器翻译（连续分布式表示方法）

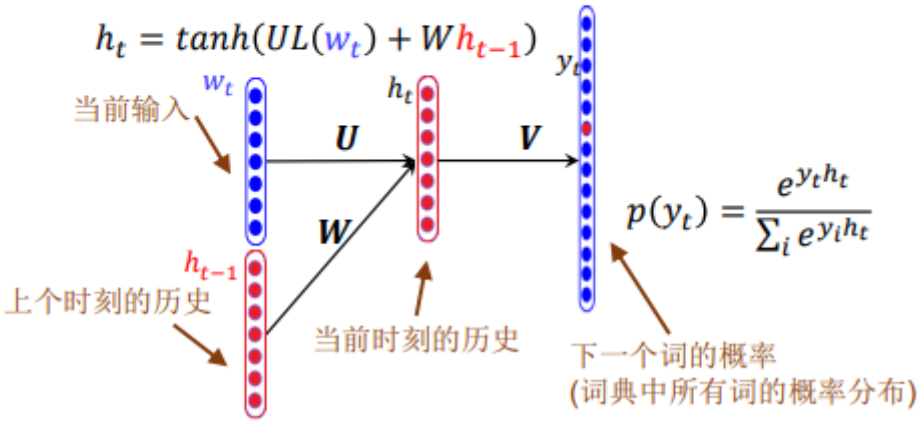
分布式语义表示是核心和基础



循环神经网络

- 输入: $t-1$时刻历史 h_{t-1} 与 t时刻输入 w_t
- 输出: t时刻历史 h_t 与 下个时刻$t+1$输入y_t 的概率

$$h_t = tanh(UL(w_t) + Wh_{t-1})$$



情感分析

重点：观点挖掘和倾向性分析

概念部分：

问题：什么是观点挖掘，倾向性分析?

答：从海量数据中挖掘观点信息，并分析观点信息的倾向性。它的目的在于缺点一个说话者或者作者对于相关话题的情感，观点和态度。

问题：为什么需要观点挖掘和倾向性分析?

答：

1. 文本信息主要包含两类：客观性事实，主观性观点。
2. 随着web兴起，互联网中出现了大量的UGC数据，其中包含了大量的观点信息。
3. 已有文本分析方法主要侧重于客观性文本内容的分析和挖掘。

问题：观点挖掘和倾向性分析有什么用?

答：

1. 企业对观点挖掘和倾向性分析的需求：自动发现用户情感于观点，感知社会发展趋势，获取商业机会，在线名誉管理，目标导向广告。
2. 普通用户对观点挖掘和倾向性分析的需求：有助于购买产品，有利于发现针对政治话题的观点。
3. 政府对观点挖掘和倾向性分析的需求：控制公众整体情绪，检测公共事件。

情感分析发展七项关键技术

1. **情感分类**

情感倾向性分类任务，情绪分类任务

- 基于传统机器学习方法的情感分类
- 基于深度学习方法的情感分类
- 面向评价对象的情感分类

2. **情感元素抽取**

   情感词表示学习：褒义/贬义

   评价对象抽取：评价的实体

   评价搭配抽取：<评价对象，情感词>

3. **跨领域情感分析**

   从源领域到目标领域进行模型的迁移

   目的：标注少量或不标注目标领域的语料，利用源领域的语料在目标领域达到较好的性能。

4. **个性化情感分析**

   在情感分析中既然个性化的元素

   情感分析的展示变得独特，另类，拥有子集特质的需要，别具一格

   - 基于用户用词习惯的方法
   - 基于认知理论的方法
   - 基于网络结构的方法

5. **隐式情感分析**

   社会媒体中文本感情表达方式复杂

   - 事实型隐式情感分析
   - 修辞型隐式情感分析

6. **情感原因发现**

   - 基于文本的情感原因发现
   - 基于个体立场的情感原因发现
   - 基于群体立场的情感原因发现
   - 情感原因通常是由个体，所在群体以及内容共同作用产生的

7. **情感生成**

   - 评论文本生成
   - 情绪对话生成

相关任务

- 观点及倾向性识别：情感识别
- 观点要素抽取：观点属性抽取，观点摘要
- 观点检索

情感识别

- 观点识别
- 极性分类
- 强度识别

各种级别（词，特征，句子，文档）

观点属性抽取

- 观点持有者抽取
- 观点目标抽取

观点摘要

观点检索

根据用户的查询从文档中找到对于主题信息发表了观点的文档

情感分析的典型方法

情感识别

- 词级别：

  任务：　识别词语的情感倾向性，构建词典资源

  方法：　基本思路：利用词之间的相似度进行扩展

  基于词典的方法

  基于语料库的方法

- 句子级别

  任务：识别句子的情感倾向性　“这部电影看得想吐，看了5分钟就看不下去了。”

  关键问题　如何进行特征表示

  分类：　基于语料库的方法　基于词典的方法　融合方法

- 文档级别

  任务：识别篇章整体观点倾向性

  绝大多数方法与句子级别方法类似　特征+分类器

  关键问题　多观点倾向性：一篇商品评论中可能包含对于商品多 方面的观点，每个观点的倾向性也可能不同，如何识 别篇章整体的观点倾向性

- 其他：跨语言观点识别与分析　领域适应性

观点挖掘

任务：抽取观点评价的对象

基本思路(Kim AAAI 2005)

命名实体识别　人名、机构名

句法结构特征　Convolution Kernel

分类或者序列标注　SVM, Naïve Bayes, CRFs

需要指代消解

观点检索

任务：　从海量文本中根据查询找到观点信息

根据主题相关度(topic relevance)与观点倾向性 (opinion relevance)对结果进行重排序　主题相关度: 传统检索　观点倾向性: 观点识别

关键问题　找到主题相关度得分与观点倾向性得分的折中

资源和评测

资源：词典、语料　评测：评测会议

word to vector

神经网络，深度学习

神经网络：特征处理——浅层学习

深度学习：构建有深度的模型，让模型自动学习好的特征表示（从底层特征，中层特征，高层特征）

how represent the meaning of a word?

def:meaning

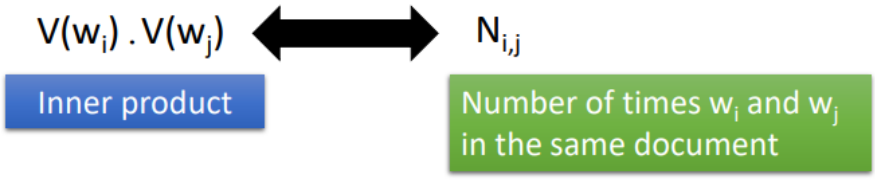
common answer:use a taxonomy like WordNet

word Embedding词嵌入

- machine learns the meaning of words from reading a lot of documents without supervison
  机器从大量文档中无监督地学习单词的含义
- a word can be understood by its context
  单词可以通过其上下文来理解

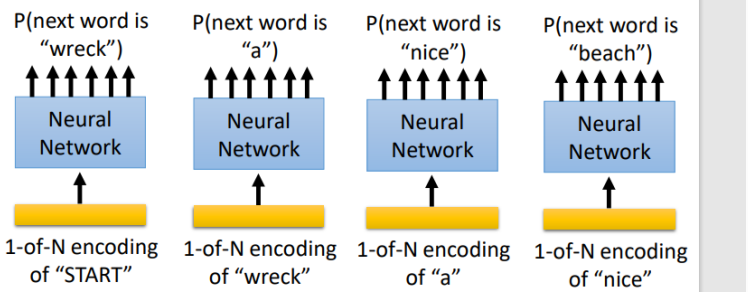
how to exploit the context如何利用上下文

- count base基于计数
  - if twowords wi and wj frequently co-occur ,V(wi)and V(wj) would be close to each other
  - 如果两个词wi和wj经常同时出现，那么V(wi)和V(wj)会接近彼此

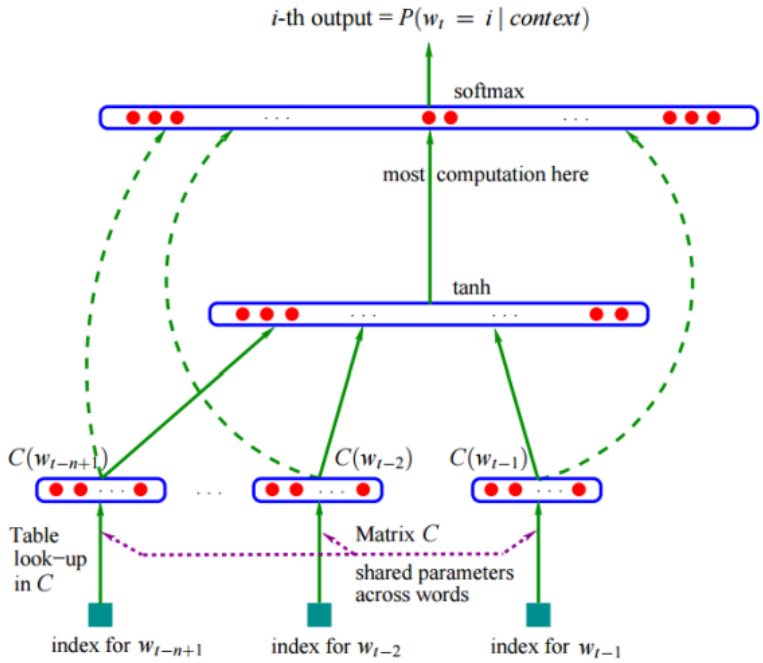


- prediciton based基于预测
  - language modeling语言模型

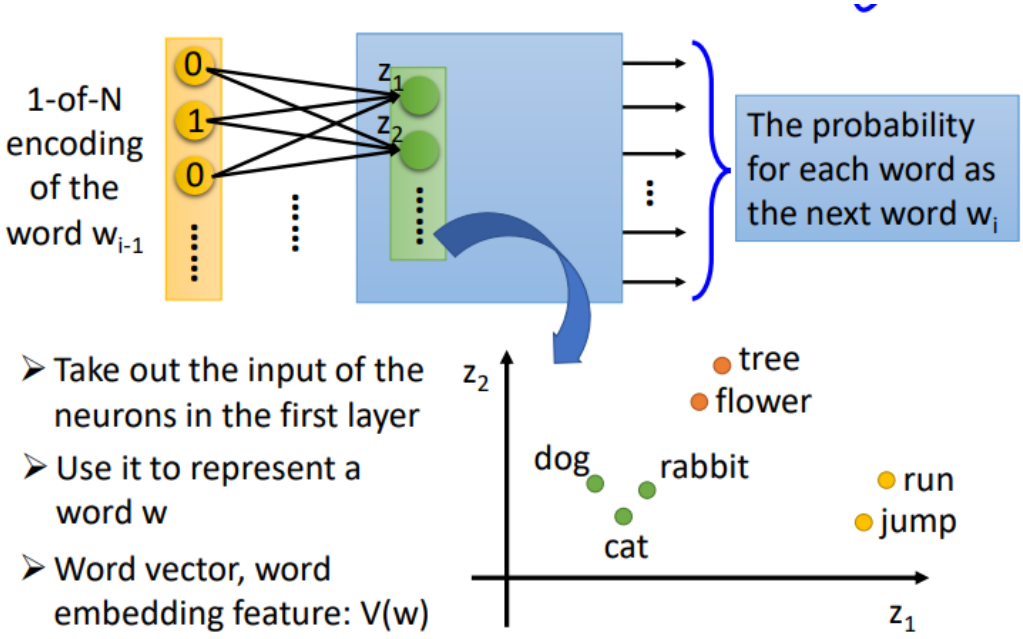
    P(“wreck a nice beach”) =P(wreck|START)P(a|wreck)P(nice|a)P(beach|nice)



这个操作图，（一种神经概率语言模型）——>语言模型



Bengio, Y., Ducharme, R., Vincent, P., & Jauvin, C. (2003). A neural probabilistic language model. *Journal of machine learning research*, *3*(Feb), 1137-1155.

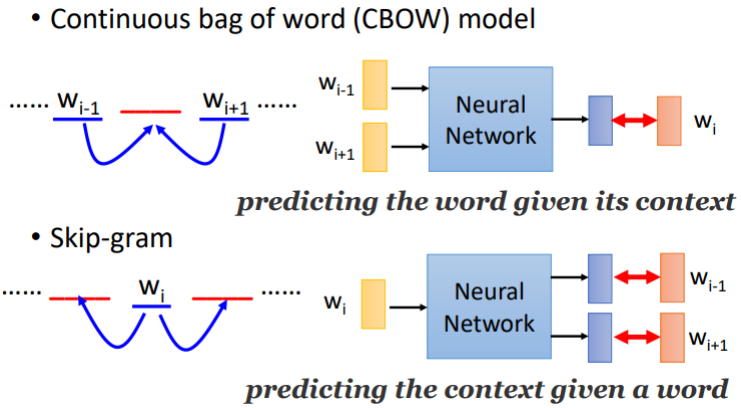


- Continuous bag od word(CBOW) model

  CBOW 模型是一种用于自然语言处理的神经网络模型，用于预测给定上下文中的单词。在 CBOW 模型中，给定一个上下文窗口内的单词，模型试图预测中间单词。CBOW 模型的输入是上下文中的单词的单词向量的平均值，而输出是中间单词的概率分布。

- Skip-gram

  Skip-gram 是一种与 CBOW 相反的模型，它试图根据给定的中间单词预测上下文单词。换句话说，Skip-gram 模型的目标是预测给定单词周围的上下文。 Skip-gram 模型通常用于训练词嵌入，其中每个单词都表示为一个密集的低维向量，以便于计算相似度和在自然语言处理任务中使用。



Word Embedding

- Characteristics特征

  $V\ hotter - V\ hot \approx V\ bigger - V\ big$

  $V\ Rome - V\ Italy \approx V\ Berlin - V\ Germany$

  $V\ king - V\ queen \approx V\ uncle - V\ aun$t

- solving analogies 解决类比问题

  根据给定的类比关系找出缺失的部分

  VBerlin−VRome+VItaly

Multi-lingual Embedding多语言嵌入

（不同语言）
