语言模型

自动分词

统计机器翻译和神经机器翻译

情感分析

深度学习：

- word vector
- 预训练模型
- 大模型， 激发它的能力，训练chatgpt的基本过程等等

深度学习：3-4道大题，一定多写字，题目让干嘛干嘛，写完整（比如让你写过程，画图，解释）

最后一题往往是开放性的题，没有标准答案，尽量多方面写，多写

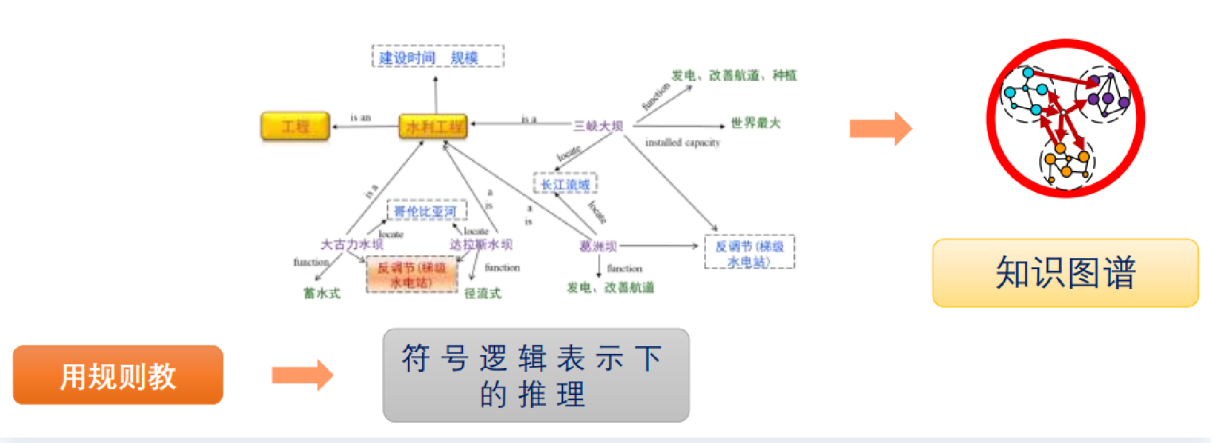
gpt:

从智能角度对人工智能的分类：

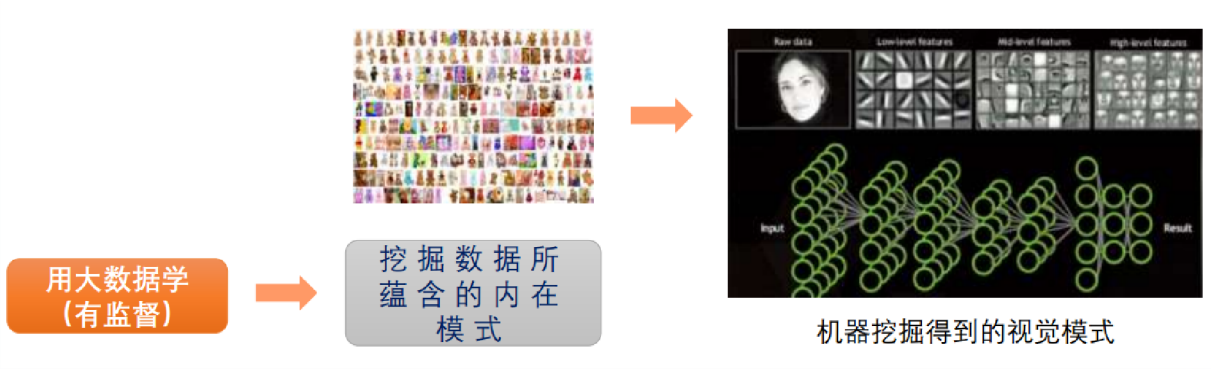
1. 领域人工智能：依葫芦画瓢、任务导向，如Deep Blue和AlphaGo
2. 通用人工智能或跨领域人工智能：通用人工智能或跨领域人工智能
3. 通用人工智能或跨领域人工智能：通用人工智能或跨领域人工智能；外骨骼机器人；人类智能+机器智能：如达芬奇外科手术机器人；人、机、物、网互联：如智慧城市系统

人工智能主流方法：

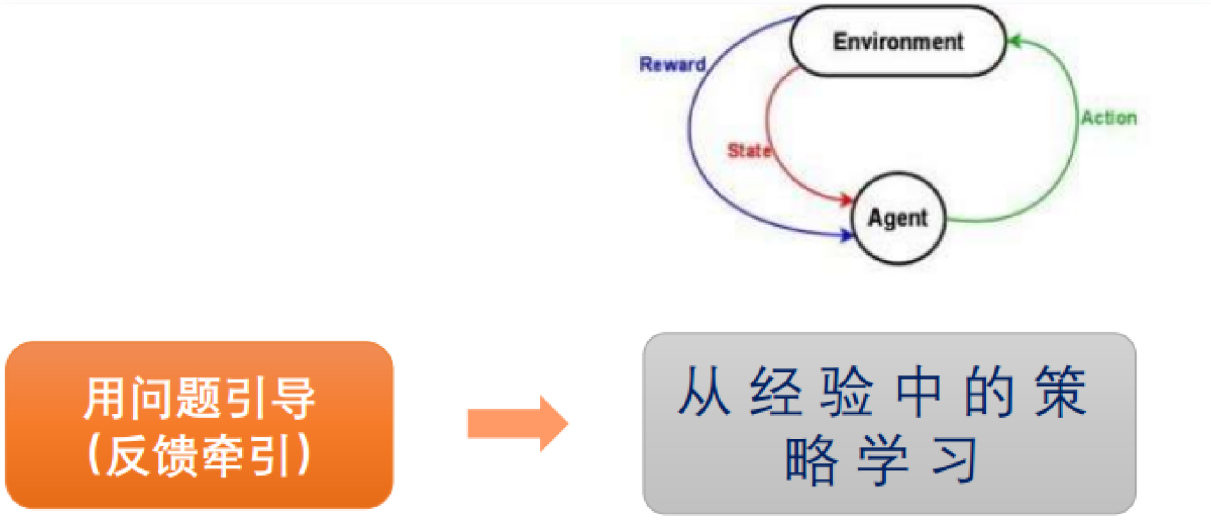
1. 符号主义人工智能



2. 联结主义（数据驱动的机器学习）



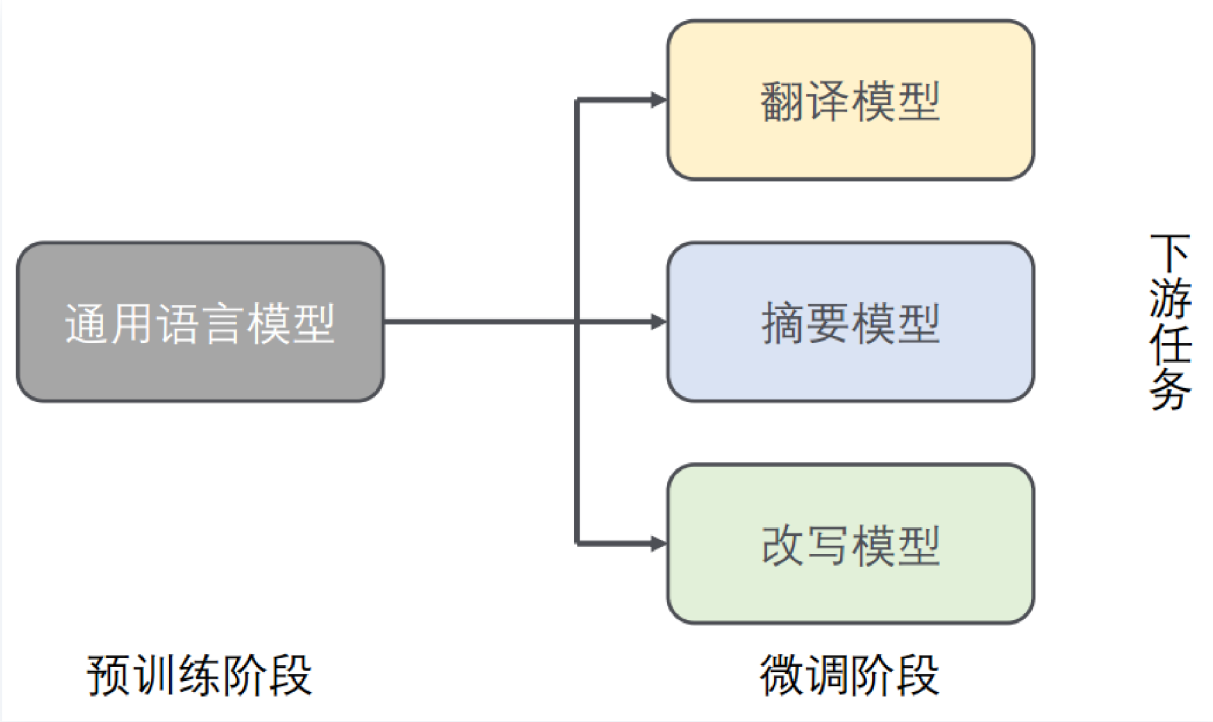
3. 行为主义（从经验中学习）



学习模式	优势	不足
符号主义(用规则教)	与人类逻辑推理相似，解释性强	难以构建完备的知识规则库
联结主义(用数据学)	直接从数据中学	以深度学习为例：依赖于数据、解释性不强
行为主义(用问题引导)	从经验中进行能力的持续学习	非穷举式搜索而需更好策略

1. GPT-1和BERT的区别（模型结构，应用，预训练任务）

共同思路：预训练+有监督微调



	BERT	GPT-1
提出时间	2018年10月11日	2018年6月
模型结构	双向（Encoder）	单项（Decoder）
主要应用	自然语言理解	自然语言生成
预训练任务	“完形填空”	“词汇接龙”
预训练难度	相对易	相对难
模型大小	340M	117M
模型性能	相对优	相对差
代码开源	是	否

2. GPT-1到2

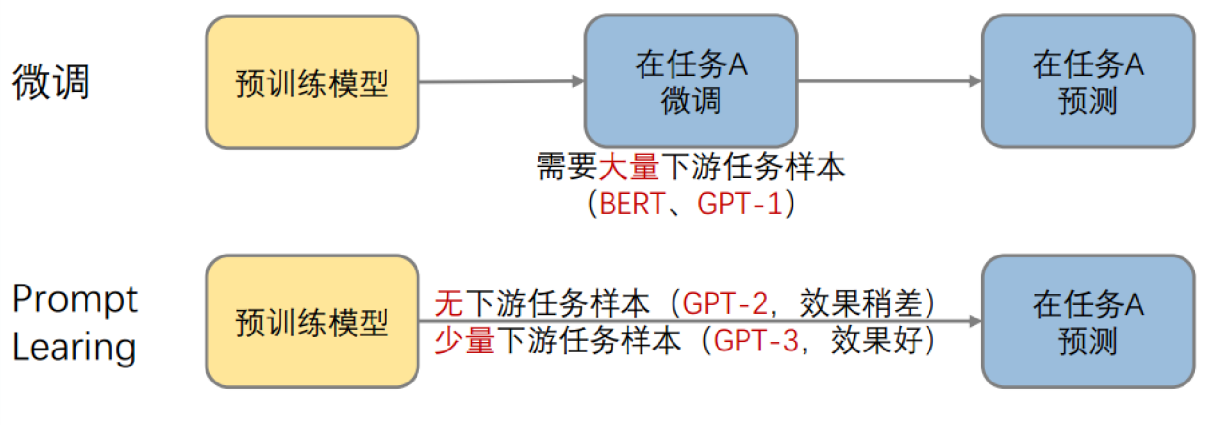
   GPT-2提出了Prompt Learning的雏形

   Prompt Learning（提示学习）：把不同下游任务的输入输出规范到同一形式

   优势：
   可以用来解决各种各样的下游任务， 甚至未经训练的

3. GPT-2到3

In-Context Learning（情景学习）：强化版的prompt，支持在输入中对所需任务进行举例说明



1：单个任务，不是指令方式

2：开始有提示，多种任务，推荐等

3：不仅仅多种任务，还能做没见过的任务（少样本任务，零样本任务），从提示学习变成直接学习，指令学习

4：预训练，有监督微调……三个阶段

基于人类反馈的强化学习：

第一步：这是一个有监督微调（Supervised finetuning, SFT)的过程。对于用户提交的提示词（prompt），由人类提供回答，然后把这些成对的提问和回答数据作为训练数据，对GPT-3模型进行微调训练。需要巨大的人力成本。

第二步：对于一个提示，SFT模型输出几个不同的回答，人类标记员则需要给这些回答打分（从最理想的到最不理想的）。通过这些标注，就可以训练出一个可以捕捉人类偏好的奖励模型（Reword model, RM）。相比于人为写出回答，对模型的回答进行打分要容易的多，这大大降低了人力成本，从而可以获得更加庞大的监督数据。

第三步：将GPT-3模型视为一个策略网络，利用近端策略优化（Proximal policy optimization, PPO）算法生成输出，并使用第二步得到的RM模型对输出打分，从而更新模型。通过迭代步骤2和3，不断优化GPT-3模型，最后实现和人类偏好的对齐。这里，ChatGPT是一个生成器，RM是一个判别器，ChatGPT试图愚弄RM，而RM在人类的帮助下，能学习和分辨符合人类认知的内容。当RM不能再分辨时，模型就会收敛。

word:

1. 离散表示和连续表示的优缺点

离散化的缺点：

1.同义词数量众多，离散化表示不能体现同义词直接的相似性

2.很难计算精确的词间相似度

3.需要人力制作

4.难以添加新词（维度更新！）

5.one-hot每个词都需要一维导致向量长度太长

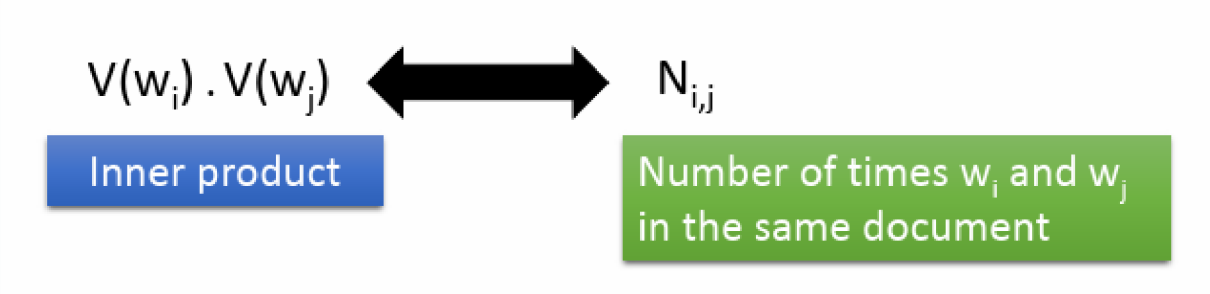
6.是主观的

2. word2vector的几种方式（主要是第二种prediction-base，count-base了解即可）（pb三种方式：1.LM方式，LM方式画出图，2.CBOW方式，画网络示意图配上解释，3.skip gram，画网络示意图配上解释）

方式：

1.Count based

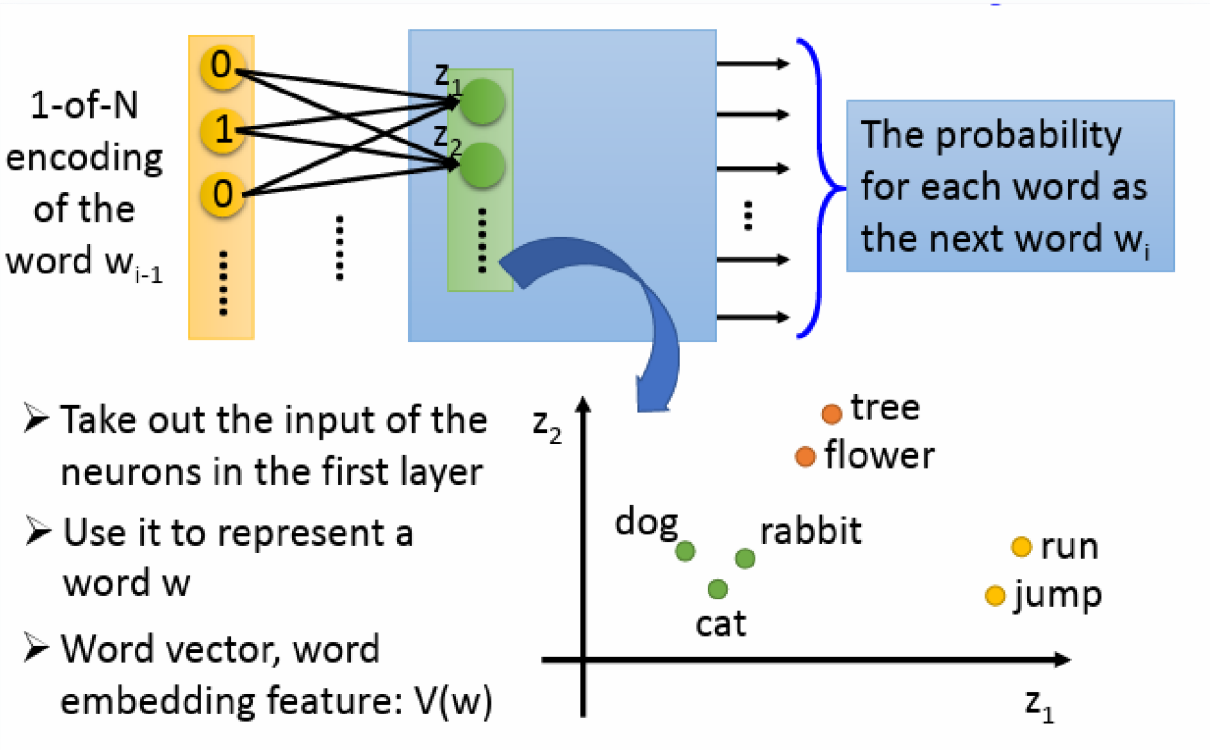
如果两个单词 wi,wj频繁共现，那么两个单词embedding后应该彼此靠近



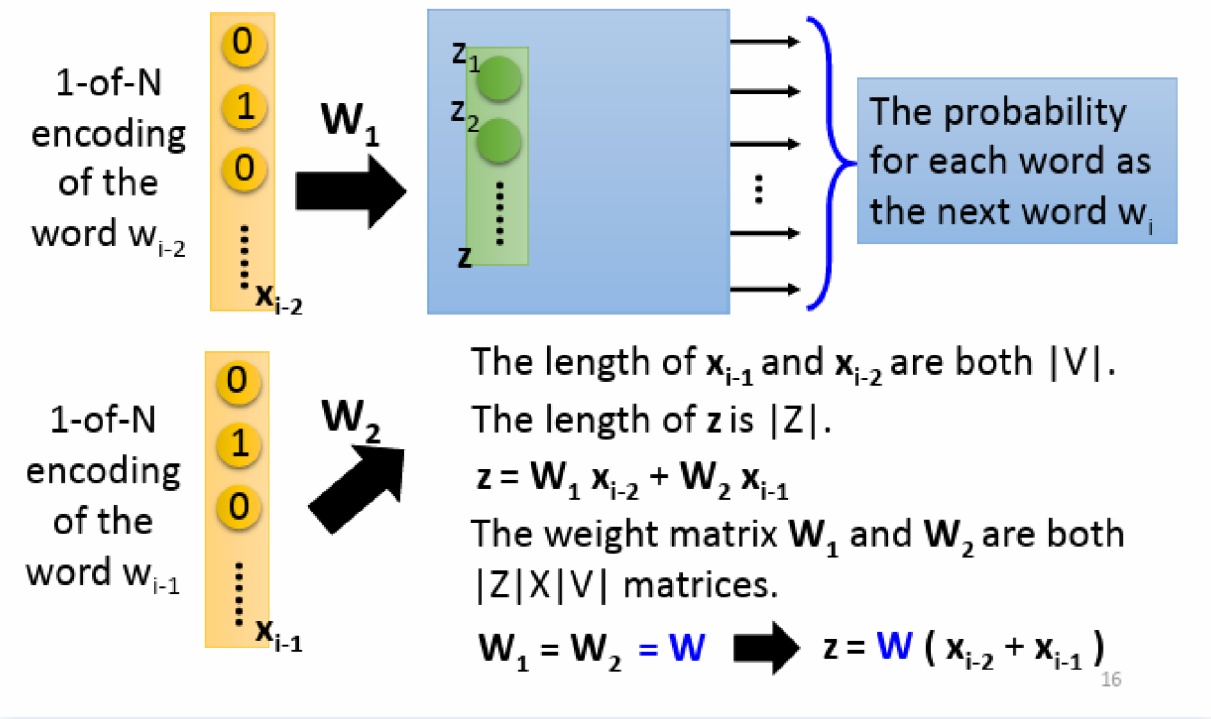
2.Prediction-based

LM方式

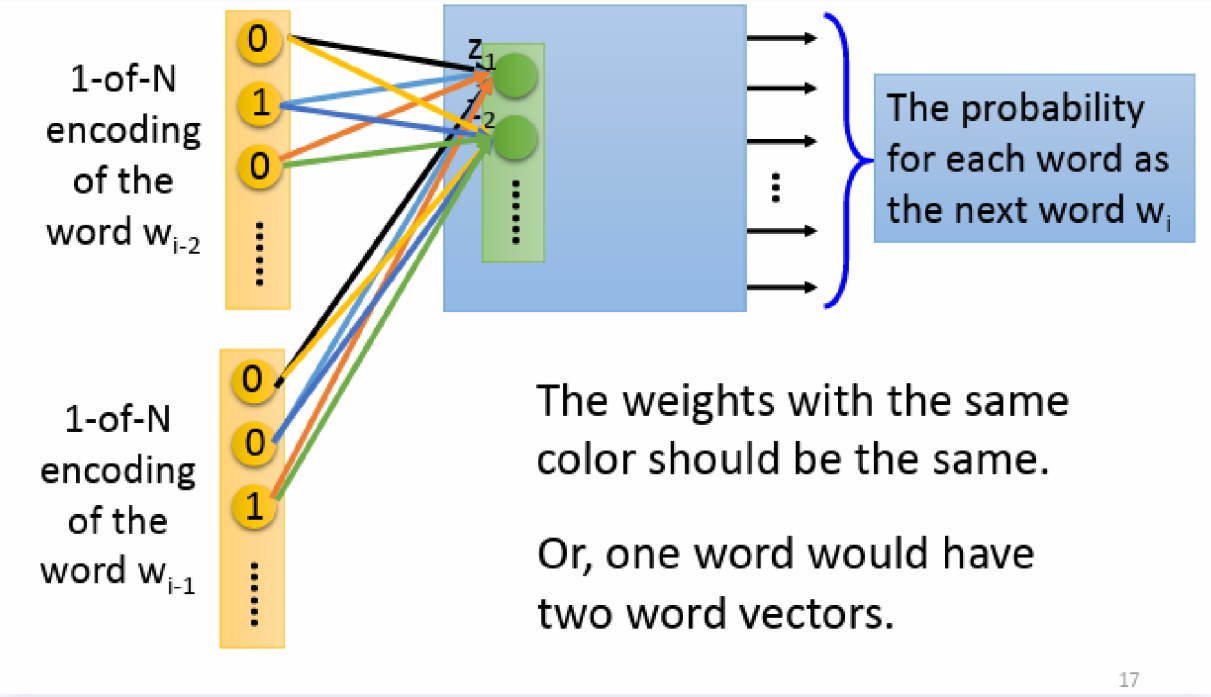
将神经网络的第一次输入拿出，用来表示单词W，单词向量、embedding的向量V(W)



共享参数：W矩阵是一样的

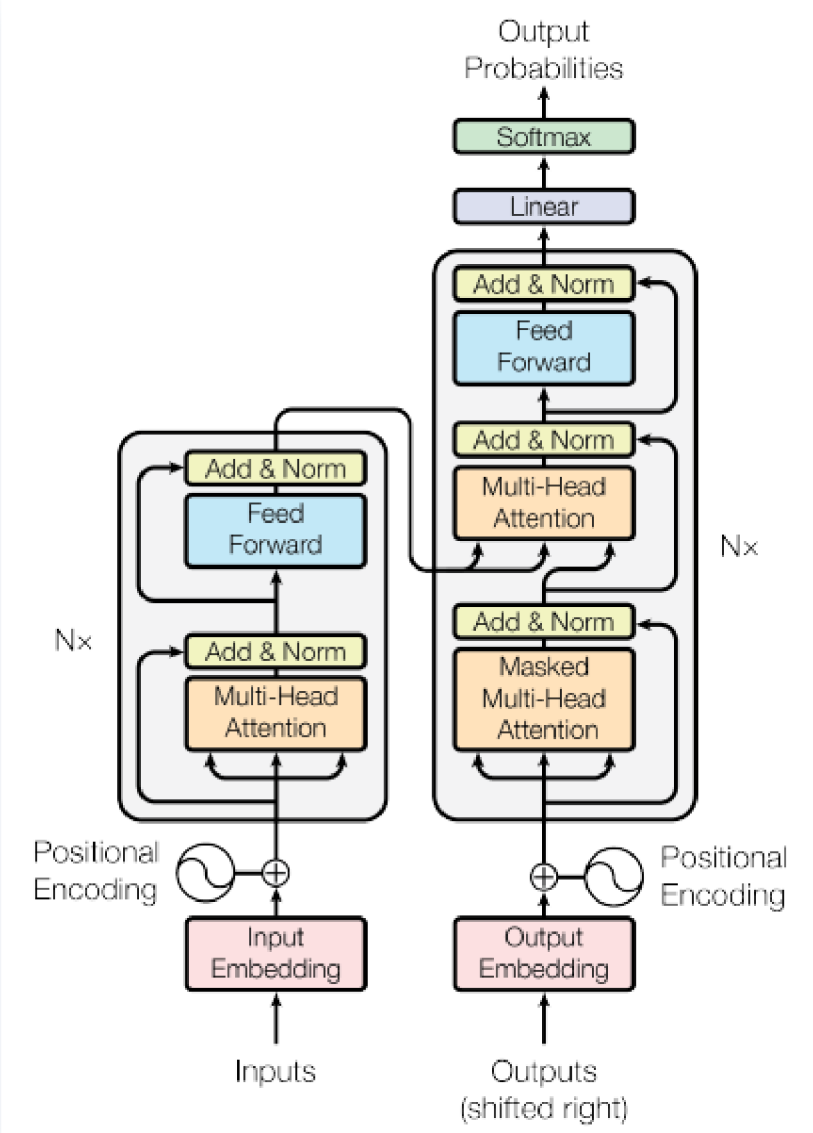


对于不同的xi,xj，i≠j,W矩阵中的元素应该是不变的，不然同一个单词将会有两个word embedding



pretraining：

transformer



1. BPE的整个过程

   [彻底搞懂BPE（Byte Pair Encode）原理（附代码实现） bpe实现-CSDN博客]

   \1. 从只包含字符和“词尾”符号的词汇表开始。

   \2. 使用语料库，找出最常见的相邻字符“a,b”;添加“ab”作为子词(subword)。

   \3. 用新的子词替换字符对的实例;重复，直到所要求的词汇量。

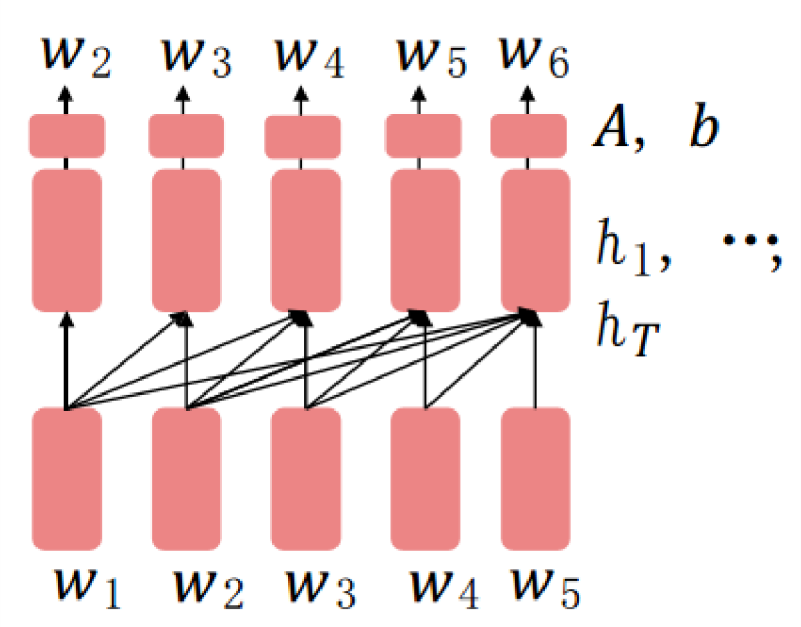
2. 预训练的三个方式及它们代表性的网络模型：encoder，decoder，Encoder-Decoders

   Decoder (GPT)：

   优点：擅长生成任务，文本流畅

   缺点：只有单向上下文理解

   原理：单向语言模型预训练，预测下一个词

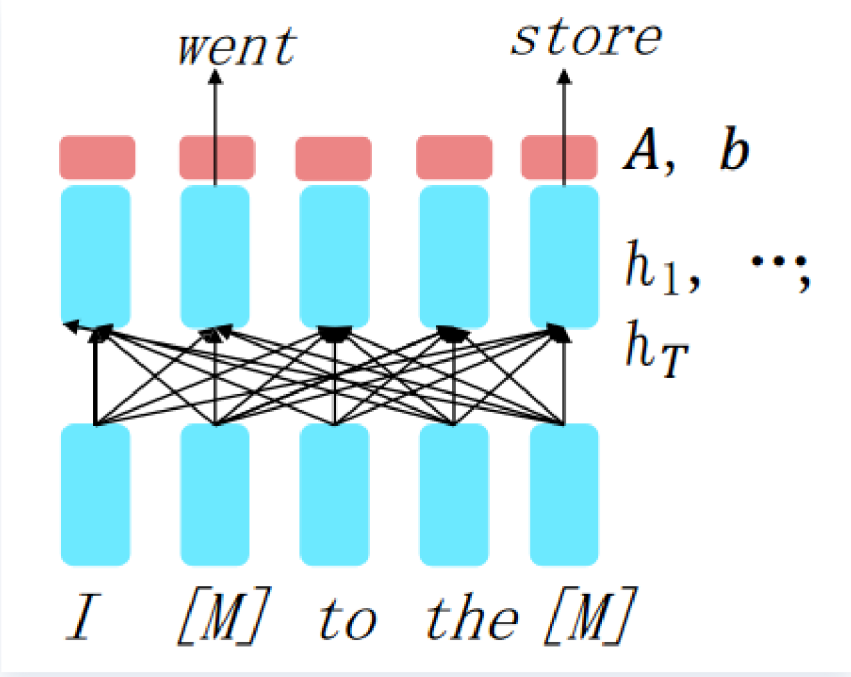


Encoder (BERT)：

优点：双向理解，适合多种NLP任务

缺点：不适合生成，计算开销大

原理：利用 MLM 和 NSP 预训练，学习双向上下文

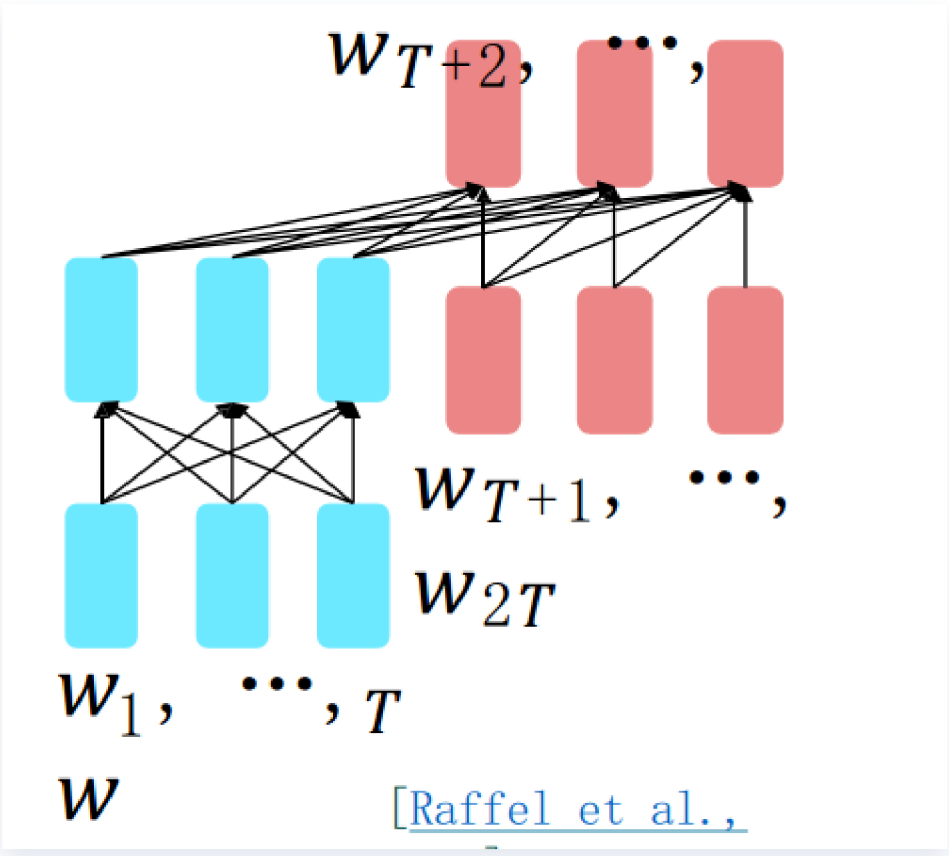


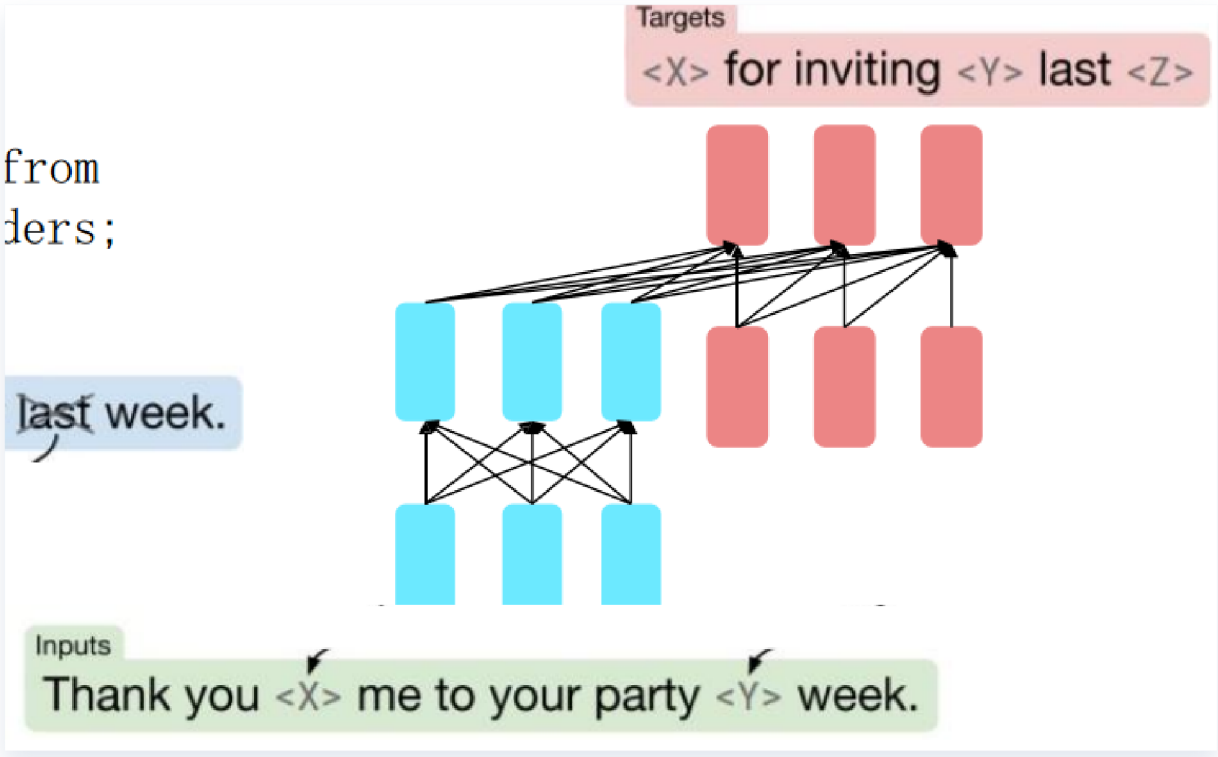
Encoder-Decoder (T5)：（怎么训练的）

优点：兼具理解和生成能力，适用广泛，可以被微调以回答各种各样的问题，检索知识

缺点：模型较大，计算成本高

原理：将所有 NLP 任务视为文本到文本转换

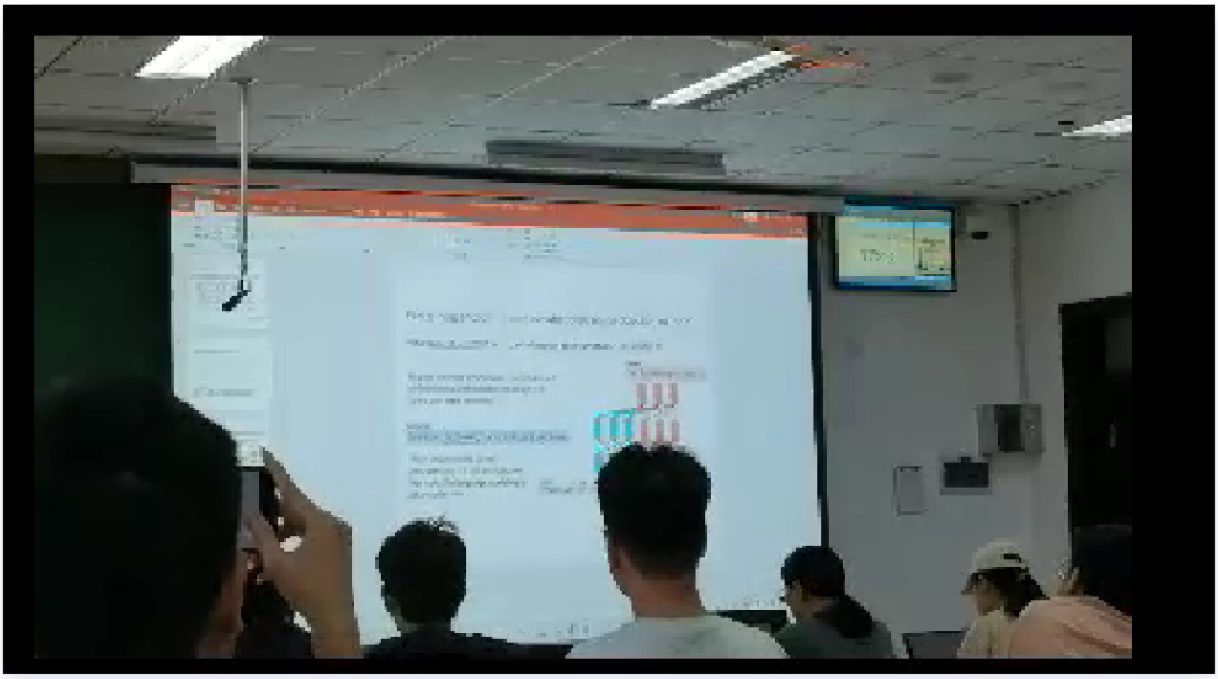




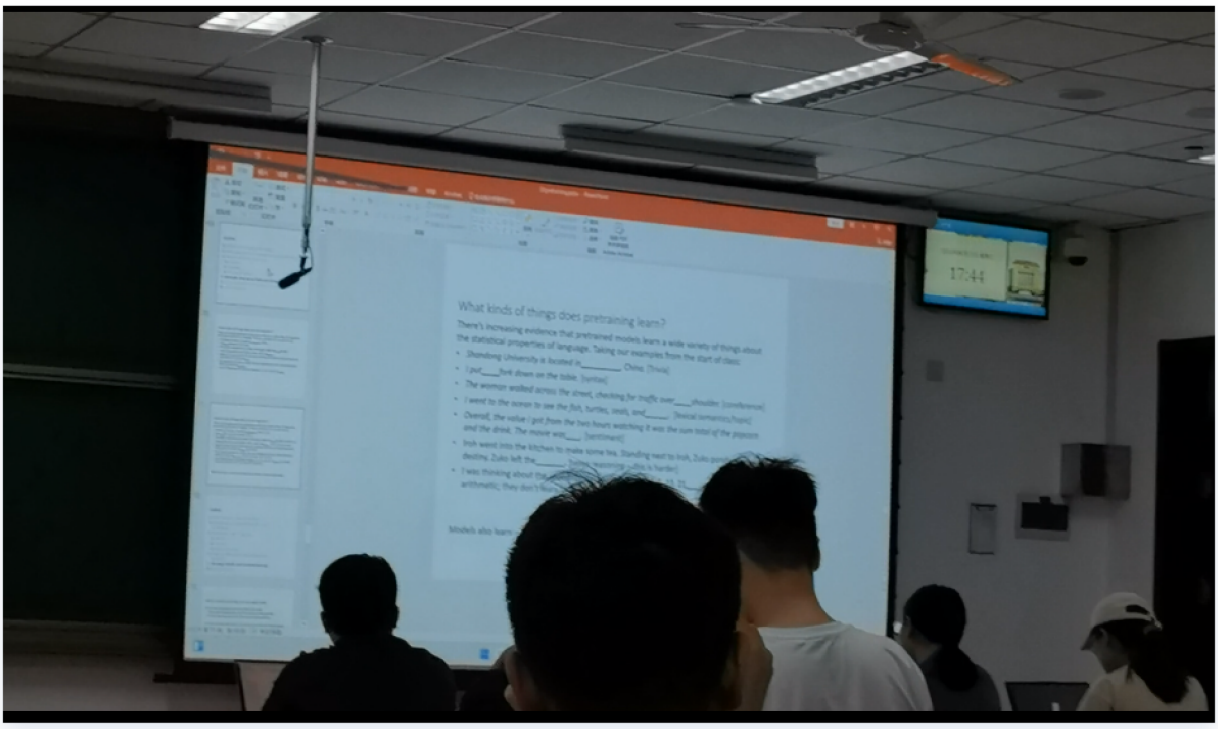
3. 为什么经过Mask Language Model和Language Model能学到世界知识（有例子，关于济南青岛）

   因为能够学习语言的统计特性（？）

4. 要知道（遇到x把xmask掉，遇到y把ymask掉）



通过mask学到了什么东西



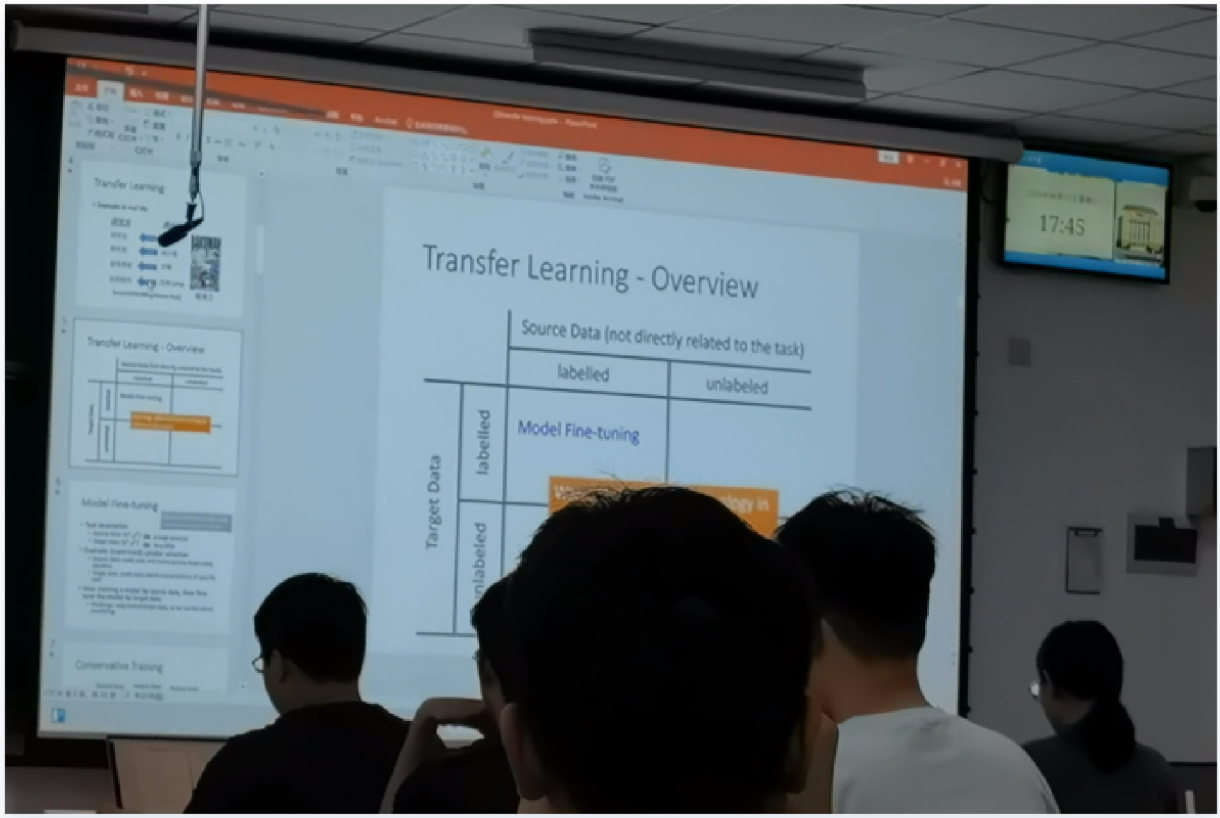
5. in-context learning情景学习

   给任务能完整写一个……（听不清）

transfer learning

1. 这张表要知道

	Source Data: Labelled	Source Data: Unlabeled
Target Data: Labelled	Fine-tuning （模型微调） Multitask Learning（多任务学习）	Self-taught learning（自我学习）
Target Data: Unlabeled	Domain-adversarial training （领域对抗训练） Zero-shot learning（零样本学习）	Self-taught Clustering （自我聚类）



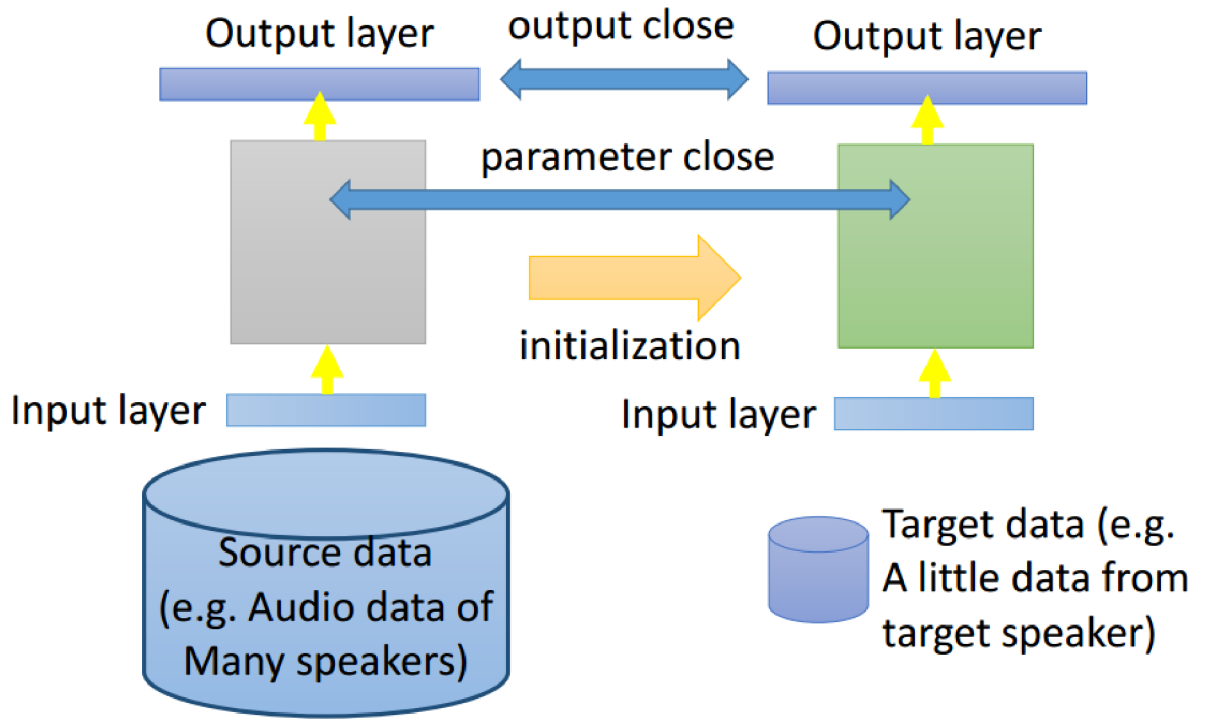
2. model fine-tuning是怎么一种方式，它的任务（？）是什么

   先用源数据训练模型，再用目标数据对模型进行微调

   解决方法：

   ### Conservative Training(保守训练)

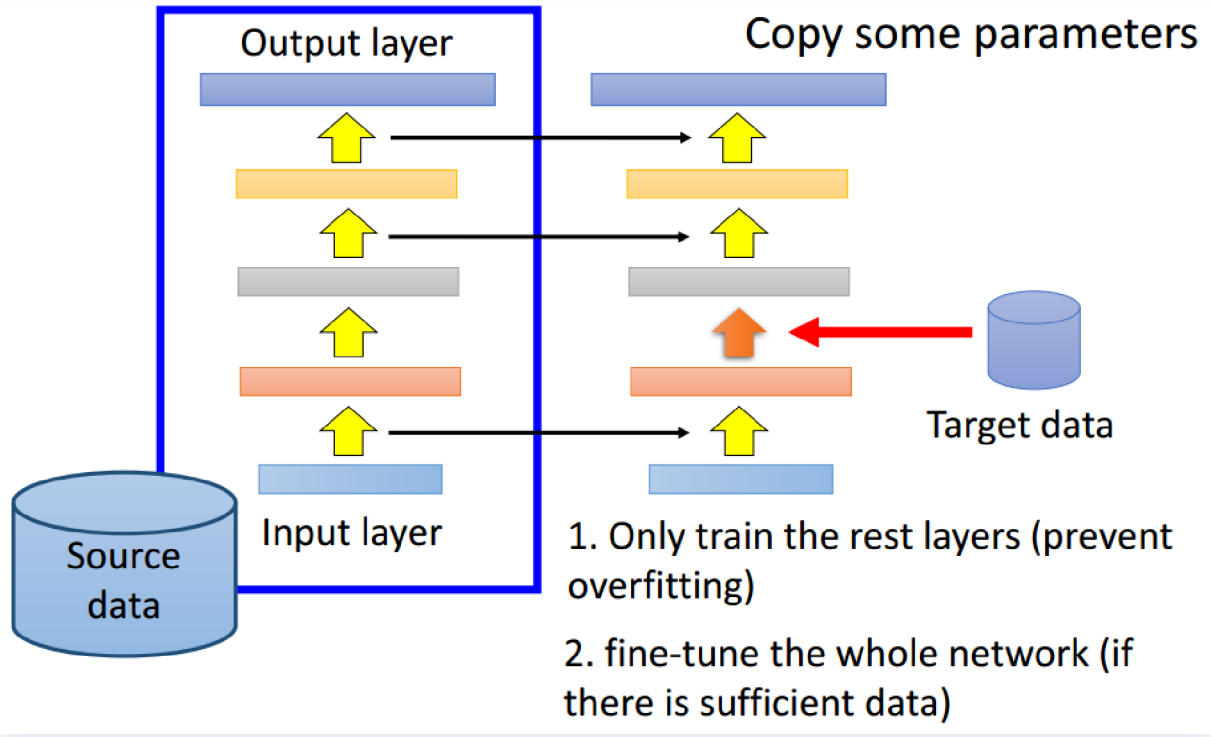
   可以在training的时候加一些正则化约束，让新的model跟旧的model不要差太多（共享参数？）。让新的model的output跟旧的model的output在看同一笔data的时候越接近越好。或者说新的model跟旧的model L2-Norm差距越小越好(防止过拟合的情形)



Layer Transfer(层迁移)

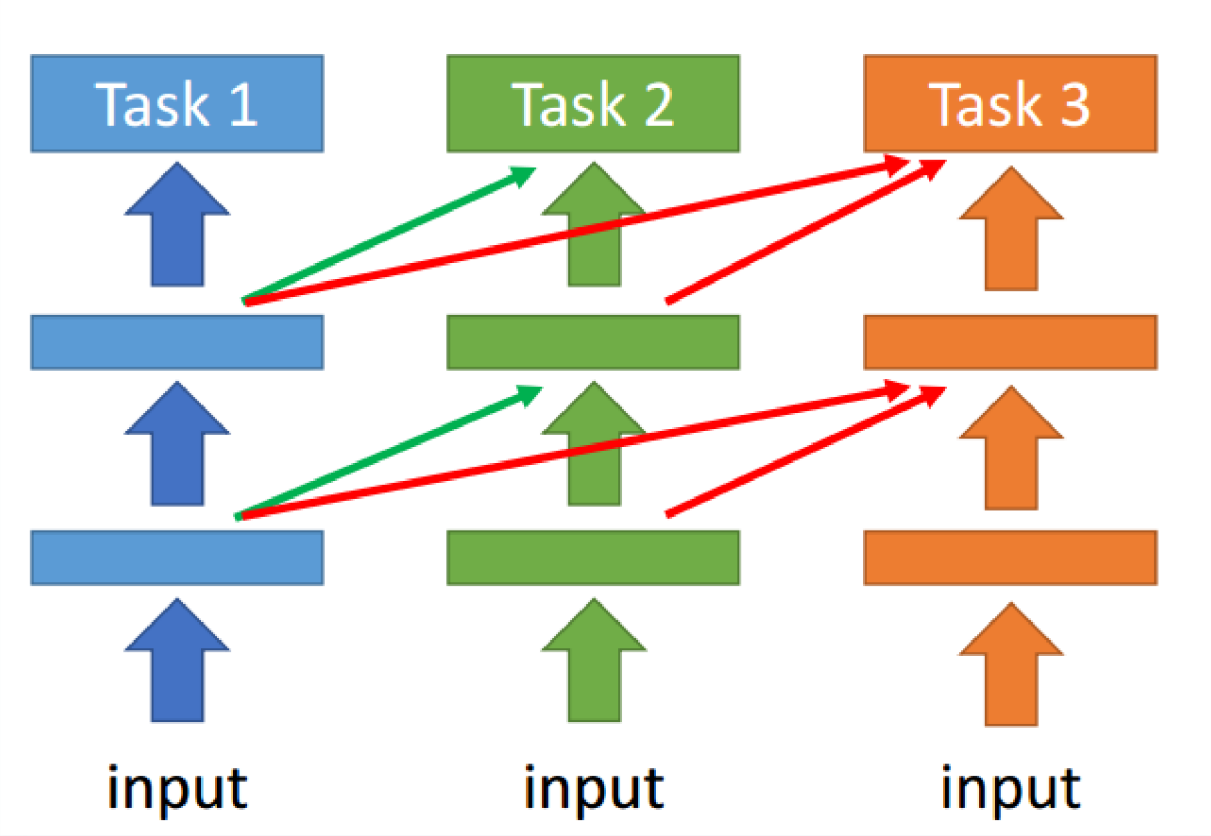
用source data train好了一个model，把这个model的某几个layer拿出来copy到新的model里面。接下来用target data只去train没有copy的layer(可能你只保留一个layer没有copy)，这样的好处就是target data只需要考虑非常少的参数，这样就可以避免过拟合的情形

语音辨识中transfer最后几层（因为人们只有发音方式的区别，辨识出来说的是什么之后提取语义步骤是一样的），图像辨识中transfer前几层（前期特征提取是一样的）



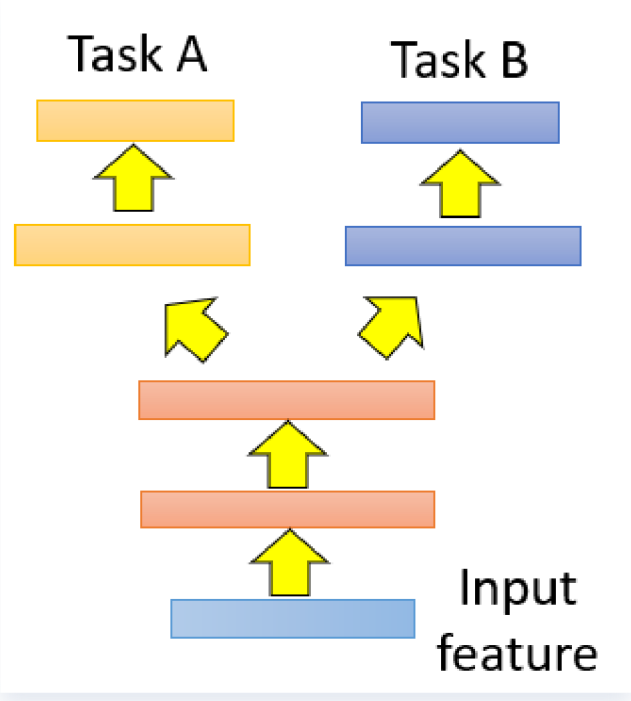
3. 多任务学习

第四种结构要知道

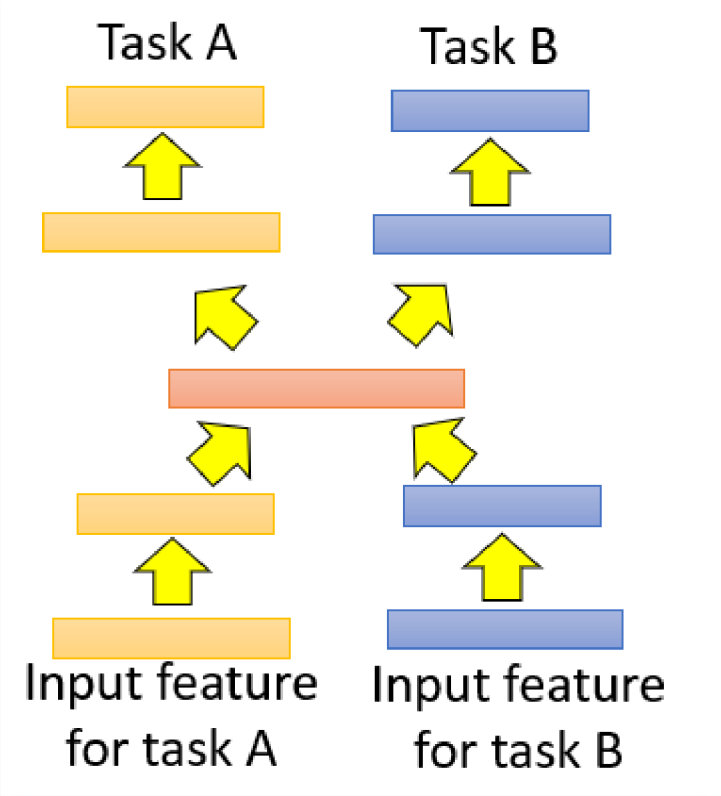


让画三种也要绘画

底层共享：



中层共享：



顶层共享：

比葫芦画瓢

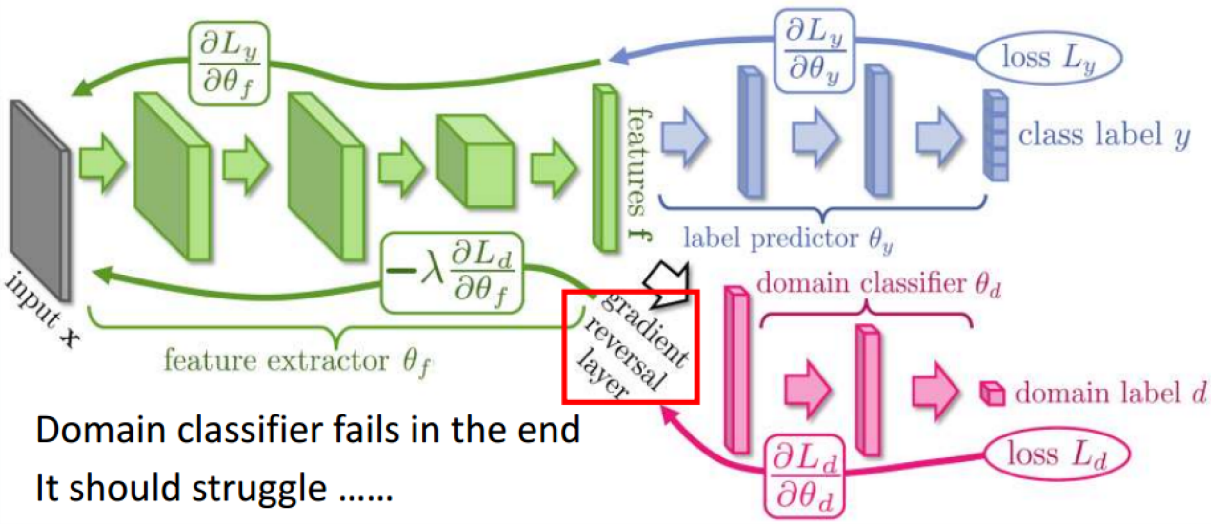
4. 最重要的红框里的

要会画

如何实现共享?

如何停止共享？梯度干扰

Domain-adversarial training(领域对抗训练)



5. zero-shot

任务定义上发生的变化：原来是两三类中预测，现在变成了属性库中属性预测，预测出了属性后看看会不会分出类，举出例子为什么这种方式可以做zero-shot（零样本任务为什么能做）

多语言翻译：模型在训练阶段只学习了少数语言之间的翻译关系，但在测试时可以处理未见过的语言对之间的翻译，因为它能够将不同语言的输入映射到一个通用的语义空间中进行处理。

步骤：

1. 将每个类别都定义为一组属性
2. 设计特征提取器f(x)，将样本投影到一个通用的特征空间中；设计属性分类器g(x)，将输入样本所属的类别属性也映射到特征空间中
3. 使用损失函数来优化模型，使得在特征空间中，源数据和目标数据之间的距离尽可能小，同时使不同目标数据之间的距离尽可能大。

$$f^*, g^* = \arg\min_{f,g} \sum_n \max\left(0, k - f\left(x^n\right) \cdot g\left(y^n\right) + \max_{m \neq n} f\left(x^n\right) \cdot g\left(y^m\right)\right)$$

4. 训练好后向f(x)输入未见过的样本，能够预测到特征空间离它最近的类别g(x)