自然语言处理

> *什么是n-gram？*

n-gram 是自然语言处理中的一种基本方法，用于将文本序列分割成长度为 n 的连续子序列（或 n 元组）。这些 n 元组可以是词语序列（称为词 n-gram）或字符序列（称为字符 n-gram）。n-gram 模型是一种统计语言模型，通过计算 n-gram 的频率和概率，来捕捉文本中的局部上下文信息，常用于语言建模、文本生成、分词等任务。

> *“I am in Shandong University”写出1-gram、2-gram、3-gram（这个要加）*

对于句子 "I am in Shandong University"：

- **1-gram（unigram）**：逐字或逐词：
  - "I", "am", "in", "Shandong", "University"
- **2-gram（bigram）**：逐两个字或逐两个词：
  - "I am", "am in", "in Shandong", "Shandong University"
- **3-gram（trigram）**：逐三个字或逐三个词：
  - "I am in", "am in Shandong", "in Shandong University"

> *给了四个语句，计算（2）中的2-gram概率。*

给了四个语句，计算（2）中的 2-gram 概率（包含 `<BOS>` 和 `<EOS>`）

假设有以下四个句子：

1. "I am in Shandong University"
2. "I am a student"
3. "Shandong University is great"
4. "I am learning NLP"

现在我们要计算第二个句子的 2-gram 概率，并加入 `<BOS>` 和 `<EOS>` 标记。步骤如下：

1. **加入特殊标记：**
   - 句子变为 "<BOS> I am a student <EOS>"
2. **计算频率：**
   - 词频统计：
     - `<BOS>`: 4
     - "I": 3
     - "am": 3
     - "a": 1
     - "student": 1
     - `<EOS>`: 4
   - 2-gram 频率统计：
     - `<BOS> I`: 3
     - "I am": 3
     - "am a": 1
     - "a student": 1
     - "student <EOS>": 1
3. **计算 2-gram 概率：**

$$P(w_i|w_{i-1}) = \frac{C(w_{i-1}, w_i)}{C(w_{i-1})}$$

   计算每个 2-gram 的概率：

   - $P(I| < BOS >) = \frac{C(<BOS>I)}{C(<BOS>)} = \frac{3}{4} = 0.75$
   - $P(am|I) = \frac{C(Iam)}{C(I)} = \frac{3}{3} = 1.0$
   - $P(a|am) = \frac{C(ama)}{C(am)} = \frac{1}{3} \approx 0.333$
   - $P(student|a) = \frac{C(astudent)}{C(a)} = \frac{1}{1} = 1.0$
   - $P(< EOS > |student) = \frac{C(student<EOS>)}{C(student)} = \frac{1}{1} = 1.0$

4. **计算整个句子的 2-gram 概率：**

$$P(sentence) = P(I| < BOS >) \times P(am|I) \times P(a|am) \times P(student|a) \times P(< E($$

$$= 0.75 \times 1.0 \times 0.333 \times 1.0 \times 1.0 \approx 0.25$$

因此，句子 "<BOS> I am a student <EOS>" 的 2-gram 概率约为 0.25。

> *写出常见的中文分词方法。*

正向最大匹配法（Forward Maximum Matching, FMM）：从左到右，以最大长度匹配词典中的词。

逆向最大匹配法（Backward Maximum Matching, BMM）：从右到左，以最大长度匹配词典中的词。

双向最大匹配法（Bidirectional Maximum Matching, BiMM）：同时进行正向和逆向匹配，选择分词结果较少或总长度较短的结果。

优点：

- 程序简单易行，开发周期短；
- 仅需要很少的语言资源（词表），不需要任何词法、句法、语义资源；

弱点：

- 歧义消解的能力差；
- 切分正确率不高，一般在95%左右。

最少分词法(最短路径法)

优点：

- 切分原则符合汉语自身规律；
- 需要的语言资源（词表）也不多。

弱点：

- 对许多歧义字段难以区分，最短路径有多条时，选择最终的输出结果缺乏应有的标准；
- 字串长度较大和选取的最短路径数增大时，长度相同的路径数急剧增加，选择最终正确的结果困难越来越大。

基于n-gram的分词方法

优点：

- 减少了很多手工标注的工作；
- 在训练语料规模足够大和覆盖领域足够多时，可以获得较高的切分正确率。

弱点：

- 训练语料的规模和覆盖领域不好把握；
- 计算量较大。

HMM分词

优点：

- 可以减少很多手工标注的工作量；
- 在训练语料规模足够大和覆盖领域足够多时，可以获得较高的切分正确率。

弱点：

- 训练语料的规模和覆盖领域不好把握；
- 模型实现复杂、计算量较大。

由字构词 (基于字标注)的分词方法

➢**评价：**

该方法的重要优势在于，它能够平衡地看待词表词和未登录词的识别问题，文本中的词表词和未登录词都是用统一的字标注过程来实现的。在学习构架上，既可以不必专门强调词表词信息，也不用专门设计特定的未登录词识别模块，因此，大大地简化了分词系统的设计[黄昌宁，2006]

生成式方法与判别式方法的结合

其他分词方法

- 全切分方法
- 串频统计和词形匹配相结合的分词方法
- 规则方法与统计方法相结合
- 多重扫描法

> *汉语使用语言模型分词的过程（可举例）*

数据预处理-特征提取-模型选择-模型训练-模型预测-后处理



5.5 语言模型应用举例

模型的训练分三步：

(1) 在词表和派生词表的基础上，用一个基本的分词工具切分训练语料，专有名词通过一个专门模块标注，实体名词通过相应的规则和有限状态自动机标注，由此产生一个带词类别标记的初始语料；

(2) 用带词类别标记的初始语料，采用最大似然估计方法估计语言模型的概率参数，公式(5-24)；

(3) 用得到的模型（公式(5-22)、(5-23)、(5-25)）对训练语料重新切分和标注，得到新的训练语料；

(4) 重复(2)(3)步，直到系统的性能不再有明显的变化为止。

3.1最大化概率2-gram分词算法

3.1.1算法描述：

1、将带分词的字符串从左到右切分为w1,w2,…,wi；

2、计算当前词与所有前驱词的概率

3、计算该词的累计概率值，并筛选最大的累计概率则为最好的前驱点；

4、重复步骤3，直到该字符串结束；

5、从wi开始，按照从右到左的顺序，依次将没歌词的最佳前驱词输出，即字符串的分词结束。

> *写出HMM算法的组成部分并解释，说明HMM能够同时实现分词和词性标注的原理。*

隐马尔可夫模型（HMM, Hidden Markov Model）是一种统计模型，常用于时间序列数据的建模。HMM由以下几个部分组成：

1. **状态集合（States）**：HMM的隐状态空间，由有限个状态组成，通常用 $S = \{S_1, S_2, ..., S_N\}$ 表示。
2. **观测集合（Observations）**：每个时间点上可以观测到的输出符号集合，通常用 $O = \{O_1, O_2, ..., O_M\}$ 表示。
3. **初始状态概率分布（Initial State Probabilities）**：表示在初始时刻各个状态的概率分布，通常用向量 $\pi = \{\pi_i\}$ 表示，其中 $\pi_i = P(S_i)$。
4. **状态转移概率矩阵（State Transition Probabilities）**：表示从一个状态转移到另一个状态的概率，通常用矩阵 $A = \{a_{ij}\}$ 表示，其中 $a_{ij} = P(S_j|S_i)$。
5. **观测概率矩阵（Observation Probabilities）**：表示在某个状态下产生某个观测值的概率，通常用矩阵 $B = \{b_j(k)\}$ 表示，其中 $b_j(k) = P(O_k|S_j)$。

HMM同时实现分词和词性标注的原理

在自然语言处理（NLP）任务中，分词和词性标注可以被看作是一个联合任务，HMM可以有效地同时完成这两个任务。其原理如下：

1. **状态定义**：将状态定义为词性标注的组合形式。例如，某种词性标注模型的状态集合可以定义为{B-NN, I-NN, B-VB, I-VB, ...}，其中B表示词的开始，I表示词的内部，NN表示名词，VB表示动词等。
2. **观测序列**：观测序列就是文本的字或词序列。例如，对于输入句子 "我喜欢学习"，观测序列就是 "我 喜欢 学习"。
3. **状态转移概率**：状态转移概率矩阵 A 表示从一个词性状态转移到另一个词性状态的概率。这可以通过标注好的语料库进行训练得到。

4. **观测概率**：观测概率矩阵 B 表示在某个词性状态下观测到某个词的概率。通过计算词性标注语料库中的频率来估计这些概率。

在实际应用中，可以使用维特比算法（Viterbi Algorithm）找到给定观测序列的最可能的状态序列，即最可能的分词和词性标注组合。步骤如下：

1. **初始化**：根据初始状态概率分布 π 初始化第一列的概率。
2. **递推**：通过动态规划的方法，逐步计算每个状态在每个时间点上的最大概率路径。
3. **回溯**：通过回溯指针，找到最优路径，从而得到最终的分词和词性标注结果。

示例

假设我们有一个简单的句子 "我喜欢学习"，我们希望使用HMM进行分词和词性标注。

1. **定义状态**：B-NN, I-NN, B-VB, I-VB
2. **观测序列**：{我, 喜欢, 学习}
3. **训练模型**：从标注好的语料库中学习初始状态概率、状态转移概率和观测概率。
4. **应用维特比算法**：根据模型和观测序列，使用维特比算法找到最可能的状态序列，例如 {B-NN, B-VB, B-VB}。
5. **得到结果**：根据状态序列，得到分词结果 "我 | 喜欢 | 学习" 以及词性标注 "NN | VB | VB"。

通过这种方法，HMM可以同时实现对输入文本的分词和词性标注。

(1)估计HMM模型$\mu=(A, B, \pi)$ 的参数；(Train)

(2)对于任意给定的一个输入句子及其可能的输出序列O，求找所有可能的O中使概率$p(O|\ \mu)$最大的解；(分词)

(3)快速地选择“最优”的状态序列Q(词性序列)，使其最好地解释观察序列$p(Q|\ O,\mu)$ 。(词性标注)

◆问题1：模型参数

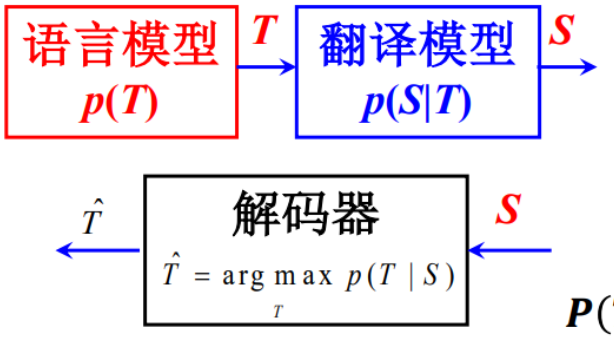
(1) 观察序列：单词序列

(2) 状态序列：词类标记序列

(3) 状态数目N：为词类标记符号的个数，如 Upenn LDC 汉语树库中有33个词类，北大语料库词类标记符号106个等；

(4) 输出符号数M：每个状态可输出的不同词汇个数(和为总的词汇数)，如汉语介词 P 约有60个，连词C约有110个，即状态 P 和 C分别对应的输出符号数为60、110。

> *画出统计机器翻译图示，通过概率公式说明翻译过程。公式介绍*



$$P(T|S) = \frac{P(T) \times P(S|T)}{P(S)}$$

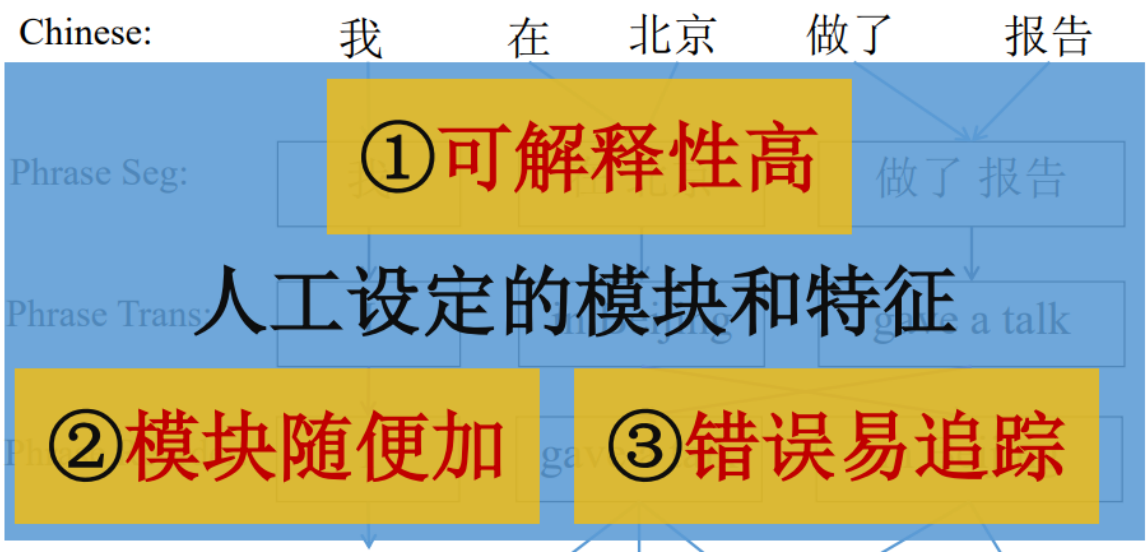
统计翻译中的三个关键问题：

(1)估计语言模型概率 $p(T)$；

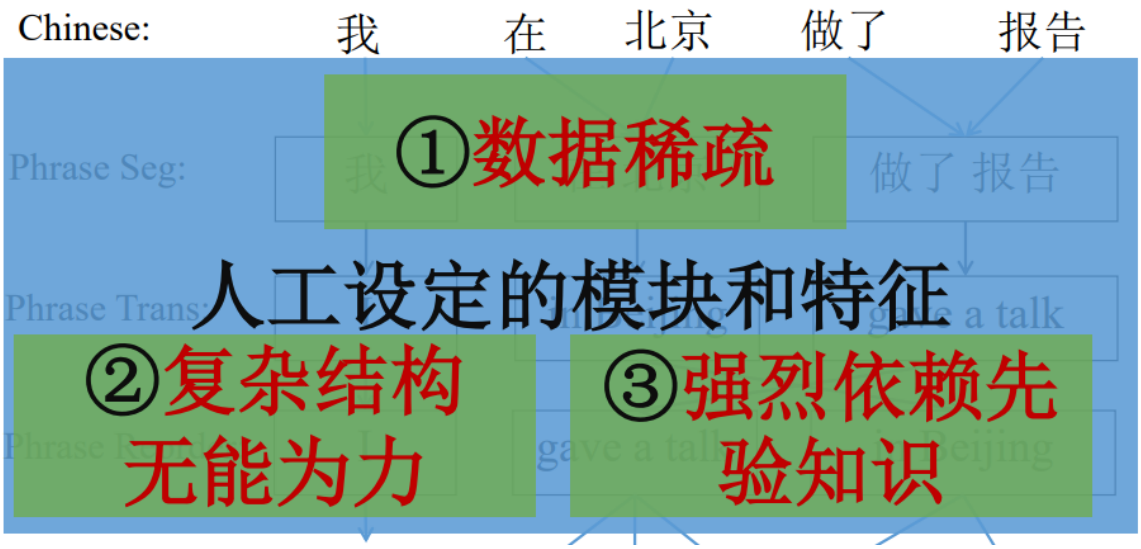
(2)估计翻译概率 $p(S|T)$；

(3)快速有效地搜索T 使得 $p(T)\times p(S \mid T)$ 最大。

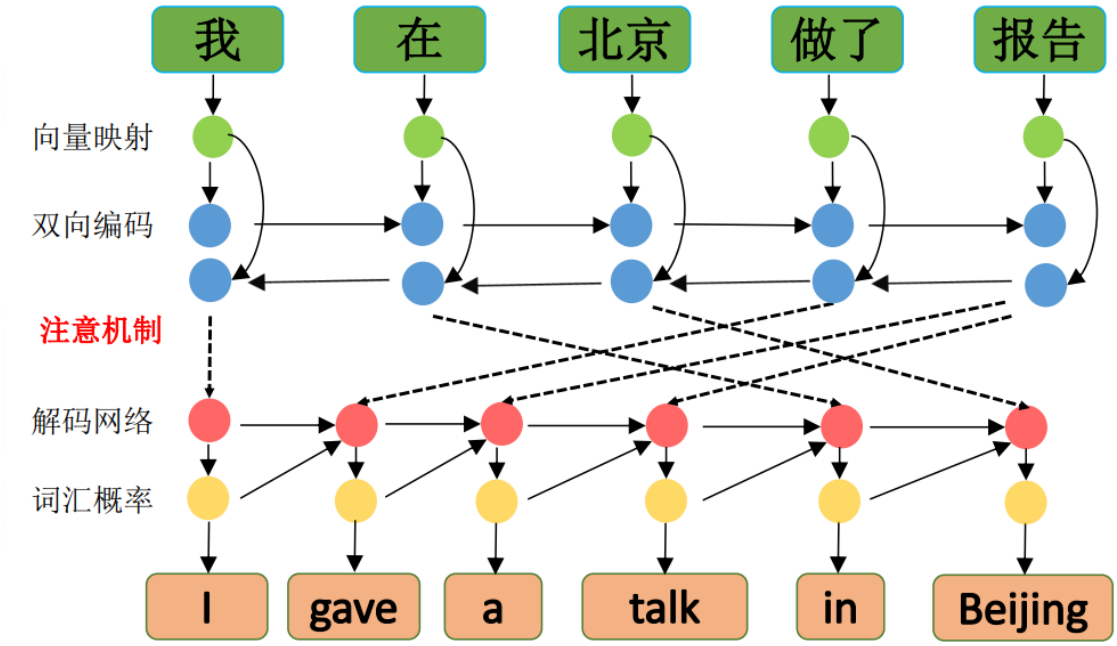
统计机器翻译



统计机器翻译



> *画出神经机器翻译模型，并解释翻译过程，及原理*

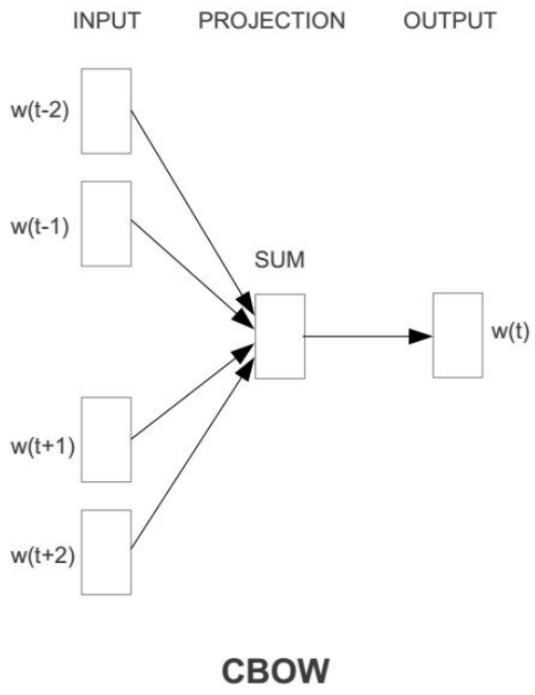


1. 编码器处理源语言句子，生成隐藏状态。 总结句子语义信息
2. 最后一个隐藏状态作为上下文向量传递给解码器。
3. 解码器逐步生成目标语言句子，每个时间步使用注意力机制选择性关注源语言句子的不同部分。
4. 最终生成完整的目标语言句子。

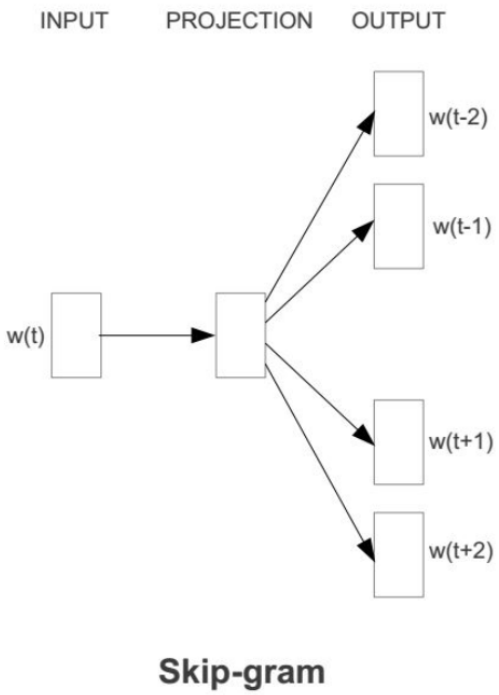
> *写出一个离散化的缺点*

信息损失，数据的细节和精度会丢失

> *画出CBOW和skip-gram的网络结构，解释原理。*



CBOW



Skip-gram

是Word2Vec模型的两种变体，它们通过不同的方法来生成词向量

CBOW:输入上下文词-嵌入层(转化词向量)-平均或加和-预测中心词

数学表示:

假设输入上下文词为 $w_{t-2}, w_{t-1}, w_{t+1}, w_{t+2}$，目标词为 w_t。

- 输入词向量： $v_{w_{t-2}}, v_{w_{t-1}}, v_{w_{t+1}}, v_{w_{t+2}}$
- 上下文向量： $v_c = \frac{1}{2C} \sum_{-C \le j \le C, j \neq 0} v_{w_{t+j}}$
- 输出概率： $P(w_t | w_{t-2}, w_{t-1}, w_{t+1}, w_{t+2}) = \frac{\exp(v_{w_t} \cdot v_c)}{\sum_w \exp(v_w \cdot v_c)}$

通过最大化上述概率，可以训练模型的参数（即词向量）。

Skip-gram：输入中心词-嵌入层(转化词向量)-预测上下文词

数学表示：

假设中心词为 w_t，上下文词为 $w_{t-2}, w_{t-1}, w_{t+1}, w_{t+2}$。

- 输入词向量：v_{w_t}
- 输出概率：$P(w_{t+j}|w_t) = \frac{\exp(v_{w_{t+j}} \cdot v_{w_t})}{\sum_w \exp(v_w \cdot v_{w_t})}$

通过最大化上述概率，可以训练模型的参数（即词向量）。

> *给出三个**mask**的例子，说明预训练模型能够从中学到什么（示例是**mask**了**her**，说明它学到了指代关系）。*

示例 1: 掩码主语

原句: "The cat chased the mouse because [MASK] was hungry."
掩码词: it

模型学到的内容:

- **指代关系**：模型需要理解"it"指的是前面提到的"cat"，并不是"mouse"。
- **上下文关联**：通过句子的上下文（尤其是"chased the mouse"这一动作），模型推断出"hungry"应该指代追逐者"cat"。

示例 2: 掩码谓语

原句: "She decided to [MASK] a new language."
掩码词: learn

模型学到的内容:

- **词汇搭配**：模型需要知道"decide to"后面常跟动词不定式形式，且"learn"是一个合适的动词。
- **语境信息**：理解"她决定"后面通常跟的是某种行为或行动，结合"a new language"，模型推断出"learn"是最适合的词。

示例 3: 掩码宾语

原句: "He bought a [MASK] of bread."
掩码词: loaf

模型学到的内容:

- **词汇语义**：模型需要知道在"a [MASK] of bread"这种搭配中，"loaf"是一个常见且合适的词。
- **搭配常识**：了解"bread"通常以"loaf"这种单位来描述，通过这种常识性的搭配，模型能够正确预测出"loaf"。

示例 4: 掩码形容词

原句: "The [MASK] dog barked loudly."
掩码词: big

模型学到的内容:

- **词汇语义和搭配**：理解“dog”常见的形容词搭配，如“big”、“small”等。
- **描述性语言**：学会在描述性句子中使用适当的形容词来修饰名词。

示例 5: 掩码动词时态

原句: "She [MASK] to the store yesterday."
掩码词: went

模型学到的内容:

- **时态和语法**：根据上下文中的时间标志词“yesterday”，理解动词需要使用过去式。
- **时间表达**：学会识别并使用与时间相关的动词形式。

示例 6: 掩码介词

原句: "The book is on the table [MASK] the lamp."
掩码词: beside

模型学到的内容:

- **空间关系**：理解和预测表示空间关系的介词，如”beside”、”under”、”near”等。
- **句子结构**：掌握介词短语在描述物体位置时的使用。

示例 7: 掩码专有名词

原句: "[MASK] is the capital of France."
掩码词: Paris

模型学到的内容:

- **常识知识**：学习和记住常见的事实和知识，如地理信息。
- **实体识别**：学会识别并填补句子中的专有名词。

示例 8: 掩码连接词

原句: "I wanted to go for a walk, [MASK] it started raining."
掩码词: but

模型学到的内容:

- **句子连接**：理解并正确使用表示对比或转折的连接词，如"but"、"however"等。
- **逻辑关系**：学习句子内部的逻辑关系，连接两个对立的陈述。

示例 9: 掩码数量词

原句: "There are [MASK] apples in the basket."
掩码词: five

模型学到的内容:

- **数量表达**：学习并理解表示数量的词语在句子中的使用。
- **数词与名词搭配**：掌握数量词和名词的搭配规则。

*举出**Encoder**、**Decoder**、**Encoder-Decoder**三个结构的代表模型，并结合例子说明原理。*

1. **Encoder（编码器）**：

   - **代表模型：BERT（Bidirectional Encoder Representations from Transformers）**

   原理说明：
   BERT 是一种预训练语言模型，属于Encoder结构。它采用Transformer作为基础架构，主要由多个Transformer编码层组成。在预训练阶段，BERT通过无监督的方式从大规模文本数据中学习语言表征。在Fine-tuning阶段，BERT可以通过微调适应各种下游任务，如文本分类、命名实体识别等。BERT的Encoder结构通过多头注意力机制和前馈神经网络实现了对输入文本的编码和语义理解，使得模型能够有效捕捉文本中的上下文信息和语义关系。

2. **Decoder（解码器）**：

   - **代表模型：GPT（Generative Pretrained Transformer）**

   原理说明：
   GPT 是一种基于Transformer的语言生成模型，属于Decoder结构。它通过自回归的方式逐步生成文本序列，利用Transformer的解码器部分实现文本的自动创作和生成。GPT在预训练阶段使用了大量的无标签文本数据来学习语言模型，其Decoder结构允许模型在生成过程中逐步考虑上下文信息，生成连贯和合理的文本输出。GPT可以应用于文本生成、对话系统等任务，展示了Decoder结构在自然语言生成领域的强大能力。

3. **Encoder-Decoder（编码器-解码器）**：

   - **代表模型：Transformer**

   原理说明：
   Transformer 是一种结合了编码器和解码器的通用模型架构。在机器翻译等序列到序列任务中，Encoder负责将输入序列编码成一个语义表示，Decoder则将该语义表示解码成目标序列。Transformer使用了多层的编码器和解码器堆叠，其中包括自注意力机制和前馈神经网络层。这种结构使得Transformer能够在处理长距离依赖关系和捕捉全局信息时表现出色。例如，在机器翻译任务中，Encoder-Decoder结构允许模型同时理解源语言句子并生成目标语言句子，实现了高质量的翻译效果。

情感分析的主要技术有哪些？请简单说明

情感分析发展七项关键技术

- 情感分类
- 情感元素抽取
- 跨领域情感分析
- 个性化情感分析
- 隐式情感分析
- 情感原因发现
- 情感生成

情感倾向分类任务，基于传统机器学习or深度学习or面对评价对象

情感元素抽取是学习情感词汇，句子中抽出对象和它的情感词

跨领域情感分析是标注少量或不标注目标领域的语料，利用源领域的语料在目标领域达到较好的性能，实现情感识别分析迁移（图书情感分析和短视频情感分析逻辑肯定不一样）

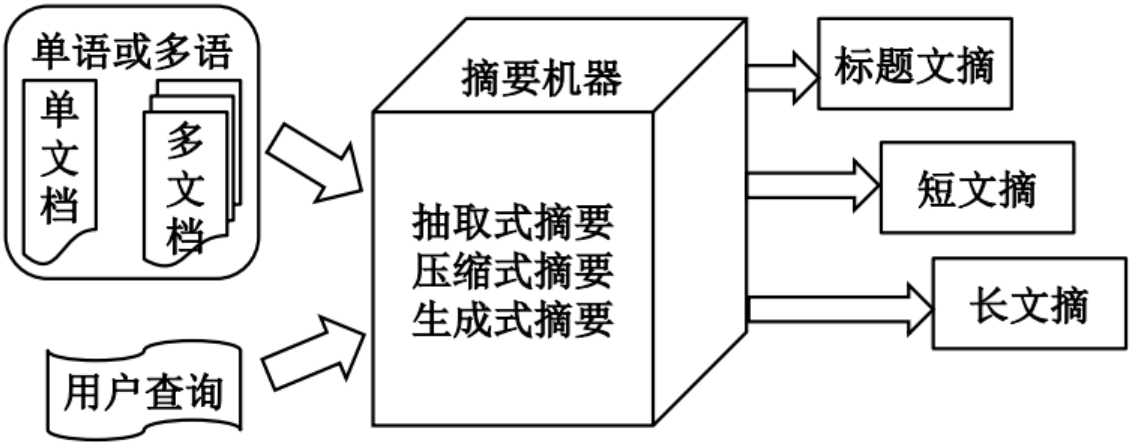
个性化情感分析，结合不同群体用户

隐式情感分析：事实型隐式情感分析 （罗列事实，暗中嘲讽or表扬）修辞型隐式情感分析（反讽、 隐喻、 夸张、对比、排比）

分析情感出现的原因（基于文本、个体、群体）

情感生成（生成带情感的文本or对话）

文本自动摘要技术的分类，并简单介绍。



从不同的需求上出发，有不同的分类

1. 文档数目：单文档摘要、多文档摘要
2. 输入语言与输出语言的关系： 单语摘要、跨语言摘要、多语言摘要
3. 是否有用户输入： 通用摘要、用户查询摘要
4. 摘要方法： 抽取式摘要、压缩式摘要、理解式摘要
5. 摘要长度： 标题式摘要、短摘要、长摘要

*你知道的最新的**NLP**技术，你的感受，你对于它的改进，展望和应用*

GPT-4和BERT的改进版本；T5；mT5和XLM-R

最新的NLP模型在各种基准测试中表现优异；能够处理多种语言和任务，展示了高度的通用性和灵活性；NLP技术的应用领域越来越广泛，改变了许多行业的工作方式

改进，展望和应用自己照着上下改

你对大模型的感受，和大模型的发展与应用前景。

1. 大模型，如GPT-4和BERT，展示了强大的语言理解和生成能力，显著提升了NLP任务的性能。
2. 发展前景：继续扩展，使用更大的数据集和更复杂的训练方法，进一步提高精度和泛化能力；减少计算资源需求，提升训练和推理效率；减轻模型中的偏见，确保公平性和可信性。
3. 应用前景：智能对话系统；多语言翻译；医疗和教育；辅助内容生成