山东大学 计算机科学与技术 学院

自然语言处理 课程实验报告

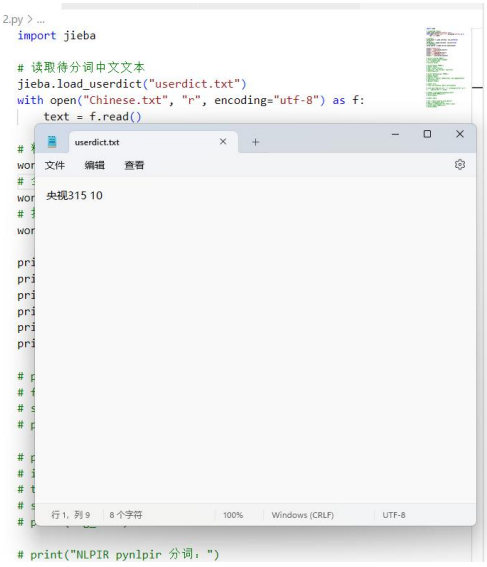
学号：202200130077	姓名： 薛润泽	班级：智能 22
实验题目： 实验 2 分词		
实验内容： 利用给定的中英文文本序列（见 Chinese.txt 和 English.txt），分别利用以下给定的中英文分词工具进行分词并对不同分词工具产生的结果进行简要对比分析。 分词工具为： 中文分词工具： jieba, SnowNLP, THULAC, NLPIR, StanfordCoreNLP 英文分词工具：NLTK， SpaCy，StanfordCoreNLP		
实验过程中遇到和解决的问题： （记录实验过程中遇到的问题，以及解决过程和实验结果。可以适当配以关键代码辅助说明，但不要大段贴代码。） 在使用 NLPIR 时，遇到了 NLPIR.user 证书授权过期的情况，经过查看助教所给博客，成功解决。		
实验步骤： 一、配置必要的 python 环境，从 github 上下载 jieba 项目，使用 pip 配置如 SnowNLP，THULAC 等 python 库 二、编写调试代码，进行分词 三、分词结果 中文分词： 1、使用 jieba 分词，尝试使用精确模式，全模式，搜索引擎模型进行分词，结果如下。		

```
Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\薛润泽\AppData\Local\Temp\jieba.cache
Loading model cost 0.461 seconds.
Prefix dict has been built successfully.
/ 央视/ 315/ 晚会/ 曝光/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲田牌/ “/ 土/ 鸡蛋/ / 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/ 在/ 商
标/ 上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜土/ ”/ 、/ 注册/ “/ 好土/ ”/ 商标/ ，/ 让/ 消费者/ 误以为/ 是/ “/ 土/ 鸡蛋/ ”/ 。/
 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限公司/ 方面/ ，/ 其/ 工作人员/ 表示/
 不知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂未/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北
/ 神丹/ 健康/ 食品/ 有限公司/ 为/ 农业/ 产业化/ 国家/ 重点/ 龙头企业/ 、/ 高新技术/ 企业/ ，/ 此前/ 曾/ 因涉嫌/ 虚假/ 宣
传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。

全模式：
/ 央视/ 315/ 晚会/ 曝光/ 湖北/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲/ 田/ 牌/ “/ 土鸡/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/
同时/ 在/ 商标/ 标上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜/ 土/ ”、/ 注册/ “/ 好/ 土/ ”/ 商标/ ，/ 让/ 消费/ 消费者/ 误以为/
以为/ 是/ “/ 土鸡/ 鸡蛋/ ”。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就此 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 有
限公司/ 公司/ 方面/ ，/ 其/ 工作/ 工作人员/ 作人/ 人员/ 表示/ 不知/ 不知情/ 知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/
发稿/ 暂/ 未取/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 有限公司/ 公司/
为/ 农业/ 农业产业/ 产业/ 产业化/国家/ 重点/ 龙头/ 龙头企业/ 企业/ 、/ 高新/ 高新技术/ 技术/ 企业/ ，/ 此前/ 曾/ 因涉嫌/
涉嫌/ 虚假/ 宣传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。

搜索引擎模式：
/ 央视/ 315/ 晚会/ 曝光/ 湖北/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲田牌/ “/ 土/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/
在/ 商标/ 上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜土/ ”/ 、/ 注册/ “/ 好土/ ”/ 商标/ ，/ 让/ 消费/ 消费者/ 以为/ 误以为/ 是/ “
/ 土/ 鸡蛋/ ”/ 。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 公司/ 有限公司/
 方面/ ，/ 其/ 工作/ 作人/ 人员/ 工作人员/ 表示/ 不知/ 知情/ 不知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂未/
取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 公司/ 有限公司/ 为/ 农业/ 产业/
产业化/ 国家/ 重点/ 龙头/ 企业/ 龙头企业/ 、/ 高新/ 技术/ 高新技术/ 企业/ ，/ 此前/ 曾/ 涉嫌/ 因涉嫌/ 虚假/ 宣传/ “/ 中国
/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。
PS D:\大学\大三下\自然语言处理\实验\exp2>
```

2、使用 jieba 的自定义字典，定义“央视 315”是一个词，出现 10 次，分词结果如下：




```
PS D:\大学\大三下\自然语言处理\实验\exp2> python -u "d:\大学\大三下\自然语言处理\实验\exp2\ex2.py"
Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\薛润泽\AppData\Local\Temp\jieba.cache
Loading model cost 0.461 seconds.
Prefix dict has been built successfully.
精确模式：
/ 央视315/ 晚会/ 曝光/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲田牌/ “/ 土/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/ 在/ 商标/ 上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜土/ ”/ 、/ 注册/ “/ 好土/ ”/ 商标/ ，/ 让/ 消费者/ 误以为/ 是/ “/ 土/ 鸡蛋/ ”/ 。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 公司/ 有限公司/ 方面/ ，/ 其/ 工作人员/ 表示/ 不知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂未/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 公司/ 有限公司/ 为/ 农业/ 产业化/ 国家/ 重点/ 龙头/ 企业/ 龙头企业/ 、/ 高新/ 技术/ 企业/ ，/ 此前/ 曾/ 因涉嫌/ 虚假/ 宣传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。

全模式：
/ 央视/ 央视315/ 晚会/ 曝光/ 湖北/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲/ 田/ 牌/ “/ 土鸡/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/ 在/ 商标/ 标上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜/ 土/ ”、/ 注册/ “/ 好/ 土/ ”/ 商标/ ，/ 让/ 消费/ 消费者/ 误以为/ 以为/ 是/ “/ 土鸡/ 鸡蛋/ ”。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就此/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 有限公司/ 公司/ 方面/ ，/ 其/ 工作/ 工作人员/ 作人/ 人员/ 表示/ 不知/ 不知情/ 知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂/ 未取/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 有限公司/ 公司/ 为/ 农业/ 农业产业/ 产业/ 产业化/ 国家/ 重点/ 龙头/ 龙头企业/ 企业/ 、/ 高新/ 高新技术/ 技术/ 企业/ ，/ 此前/ 曾/ 因涉嫌/ 涉嫌/ 虚假/ 宣传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。

搜索引擎模式：
/ 央视/ 央视315/ 晚会/ 曝光/ 湖北/ 湖北省/ 知名/ 的/ 神丹/ 牌/ 、/ 莲田牌/ “/ 土/ 鸡蛋/ ”/ 实为/ 普通/ 鸡蛋/ 冒充/ ，/ 同时/ 在/ 商标/ 上/ 玩/ 猫腻/ ，/ 分别/ 注册/ “/ 鲜土/ ”/ 、/ 注册/ “/ 好土/ ”/ 商标/ ，/ 让/ 消费/ 消费者/ 以为/ 误以为/ 是/ “/ 土/ 鸡蛋/ ”/ 。/ 3/ 月/ 15/ 日/ 晚间/ ，/ 新/ 京报/ 记者/ 就/ 此事/ 致电/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 公司/ 有限公司/ 方面/ ，/ 其/ 工作/ 工作人员/ 作人/ 人员/ 表示/ 不知/ 不知情/ 知情/ ，/ 需要/ 了解/ 清楚/ 情况/ ，/ 截至/ 发稿/ 暂未/ 取得/ 最新/ 回应/ 。/ 新/ 京报/ 记者/ 还/ 查询/ 发现/ ，/ 湖北/ 神丹/ 健康/ 食品/ 有限/ 公司/ 有限公司/ 为/ 农业/ 产业/ 产业化/ 国家/ 重点/ 龙头/ 企业/ 龙头企业/ 、/ 高新/ 技术/ 高新技术/ 企业/ ，/ 此前/ 曾/ 涉嫌/ 因涉嫌/ 虚假/ 宣传/ “/ 中国/ 最大/ 的/ 蛋品/ 企业/ ”/ 而/ 被/ 罚/ 6/ 万元/ 。
PS D:\大学\大三下\自然语言处理\实验\exp2>
```

3、SnowNLP 分词结果如下：

```
\实验\exp2\ex2.py
snownlp 分词：
['\ufeff', '央视', '315', '晚会', '曝光', '湖北省', '知名', '的', '神丹', '牌',
'、', '莲', '田', '牌', '“', '土', '鸡蛋', '”', '实', '为', '普通', '鸡蛋', '冒
充', '，', '同时', '在', '商标', '上', '玩猫', '腻', '，', '分别', '注册', '“',
'鲜', '土', '”、', '注册', '“', '好', '土', '”', '商标', '，', '让', '消费者', '
误', '以为', '是', '“', '土', '鸡蛋', '”。3', '月', '15', '日', '晚间', '，', '
新京', '报', '记者', '就', '此事', '致电', '湖北', '神', '丹', '健康', '食品', '
有限公司', '方面', '，', '其', '工作', '人员', '表示', '不', '知情', '，', '需要
', '了解', '清楚', '情况', '，', '截至', '发稿', '暂', '未', '取得', '最新', '回
应', '。', '新京', '报', '记者', '还', '查询', '发现', '，', '湖北', '神', '丹',
 '健康', '食品', '有限公司', '为', '农业', '产业化', '国家', '重点', '龙头', '企
业', '、', '高新技术', '企业', '，', '此前', '曾', '因', '涉嫌', '虚假', '宣传',
 '“', '中国', '最', '大', '的', '蛋品', '企业', '”', '而', '被', '罚', '6', '万'
, '元', '。']
```

4、THULAC 分词，分词结果如下：

```
thulac 分词：
Model loaded succeed
_c 央视_v 315_m 晚会_n 曝光_v 湖北省_ns 知名_a 的_u 神丹牌_nz 、_w 莲田牌_nz “_w
 土_a 鸡蛋_n ”_w 实_a 为_v 普通_a 鸡蛋_n 冒充_v ，_w 同时_c 在_p 商标_n 上_f 玩_
v 猫腻_n ，_w 分别_d 注册_v “_w 鲜土_n ”_w 、_w 注册_v “_w 好_a 土_n ”_w 商标_n
，_w 让_v 消费者_n 误_d 以为_v 是_v “_w 土鸡蛋_n ”_w 。_w 3月_t 15日_t 晚间_t
，_w 新京报_nz 记者_n 就_p 此事_r 致电_v 湖北_ns 神丹_nz 健康_a 食品_n 有限公司_
n 方面_n ，_w 其_r 工作_v 人员_n 表示_v 不_d 知情_v ，_w 需要_v 了_u 解_v 清楚_a
 情况_n ，_w 截至_v 发稿_v 暂_d 未_d 取得_v 最新_a 回应_v 。_w 新_a 京报_n 记者_
n 还_d 查询_v 发现_v ，_w 湖北_ns 神丹_nz 健康_a 食品_n 有限公司_n 为_p 农业_n
产业化_v 国_m 家_q 重点_n 龙头_n 企业_n 、_w 高新技术_n 企业_n ，_w 此前_t 曾_d
因_p 涉嫌_v 虚假_a 宣传_v “_w 中国_ns 最_d 大_a 的_u 蛋品_n 企业_n ”_w 而_c 被_p
 罚_v 6万_m 元_q 。_w
PS D:\大学\大三下\自然语言处理\实验\exp2>
```

5、NLPIR 分词，分词结果如下

```
cs18@games101vm:~/Desktop/Natrual_language_process$ python3 ex2.py
NLPIR pynlpir 分词：
['央', '视', '315', '晚会', '曝光', '湖北省', '知名', '的', '神', '丹', '牌', '
、', '莲', '田', '牌', '“', '土', '鸡蛋', '”', '实', '为', '普通', '鸡蛋', '冒充
', ',', '同时', '在', '商标', '上', '玩', '猫腻', ',', '分别', '注册', '“', '
鲜', '土', '”', '、', '注册', '“', '好', '土', '”', '商标', ',', '让', '消费者'
, '误', '以为', '是', '“', '土', '鸡蛋', '”', '。', '3月', '15日', '晚间', ',',
 '新京报', '记者', '就', '此事', '致电', '湖北', '神', '丹', '健康', '食品', '有
限公司', '方面', ',', '其', '工作', '人员', '表示', '不', '知', '情', ',', '需
要', '了解', '清楚', '情况', ',', '截至', '发稿', '暂', '未', '取得', '最新', '
回应', '。', '新京报', '记者', '还', '查询', '发现', ',', '湖北', '神', '丹', '
健康', '食品', '有限公司', '为', '农业', '产业化', '国家', '重点', '龙头', '企业
', '、', '高新技术', '企业', ',', '此前', '曾', '因', '涉嫌', '虚假', '宣传', '
“', '中国', '最', '大', '的', '蛋品', '企业', '”', '而', '被', '罚', '6万', '元'
, '。']
cs18@games101vm:~/Desktop/Natrual_language_process$
```

6、StandwordCoreNLP 分词，结果如下：

```
Tokenize: ['央视', '315', '晚会', '曝光', '湖北省', '知名', '的', '神丹牌', '、', '莲田牌', '“', '土', '鸡蛋', '”', '实', '为', '普通', '鸡蛋', '
冒充', ',', '同时', '在', '商标', '上', '玩', '猫腻', ',', '分别', '注册', '“', '鲜土', '”', '、', '注册', '“', '好', '土', '”', '商标', ',', '
让', '消费者', '误以为', '是', '“', '土', '鸡蛋', '”', '。', '3月', '15日', '晚间', ',', '新京报', '记者', '就', '此', '事', '致电', '湖北', '神
丹', '健康', '食品', '有限', '公司', '方面', ',', '其', '工作', '人员', '表示', '不', '知情', ',', '需要', '了解', '清楚', '情况', ',', '截至',
'发稿', '暂', '未', '取得', '最新', '回应', '。', '新京报', '记者', '还', '查询', '发现', ',', '湖北', '神丹', '健康', '食品', '有限', '公司', '
为', '农业', '产业化', '国家', '重点', '龙头', '企业', '、', '高新', '技术', '企业', '，', '此前', '曾', '因', '涉嫌', '虚假', '宣传', '“', '中国'
, '最', '大', '的', '蛋品', '企业', '”', '而', '被', '罚', '6万', '元', '。']
```

英文分词：

1、NLTK 分词结果如下：

```
NLTK 分词结果：
['Trump', 'was', 'born', 'and', 'raised', 'in', 'the', 'New', 'York', 'City', 'borough', 'of', 'Queens', 'and', 'received', 'an', 'economics
', 'degree', 'from', 'the', 'Wharton', 'School', '.', 'He', 'was', 'appointed', 'president', 'of', 'his', 'family', "'s", 'real', 'estate',
'business', 'in', '1971', ',', 'renamed', 'it', 'The', 'Trump', 'Organization', ',', 'and', 'expanded', 'it', 'from', 'Queens', 'and', 'Broo
klyn', 'into', 'Manhattan', '.', 'The', 'company', 'built', 'or', 'renovated', 'skyscrapers', ',', 'hotels', ',', 'casinos', ',', 'and', 'go
lf', 'courses', '.', 'Trump', 'later', 'started', 'various', 'side', 'ventures', ',', 'including', 'licensing', 'his', 'name', 'for', 'real'
, 'estate', 'and', 'consumer', 'products', '.', 'He', 'managed', 'the', 'company', 'until', 'his', '2017', 'inauguration', '.', 'He', 'co-au
thored', 'several', 'books', ',', 'including', 'The', 'Art', 'of', 'the', 'Deal', '.', 'He', 'owned', 'the', 'Miss', 'Universe', 'and', 'Mis
s', 'USA', 'beauty', 'pageants', 'from', '1996', 'to', '2015', ',', 'and', 'he', 'produced', 'and', 'hosted', 'The', 'Apprentice', ',', 'a',
 'reality', 'television', 'show', ',', 'from', '2003', 'to', '2015', '.', 'Forbes', 'estimates', 'his', 'net', 'worth', 'to', 'be', '$', '3.
1', 'billion', '.']
```

2、Spacy 英文分词

```
['Trump', 'was', 'born', 'and', 'raised', 'in', 'the', 'New', 'York', 'City', 'borough', 'of', 'Queens', 'and', 'received', 'an', 'economics', 'de
gree', 'from', 'the', 'Wharton', 'School', '.', 'He', 'was', 'appointed', 'president', 'of', 'his', 'family', "'s", 'real', 'estate', 'business',
'in', '1971', ',', 'renamed', 'it', 'The', 'Trump', 'Organization', ',', 'and', 'expanded', 'it', 'from', 'Queens', 'and', 'Brooklyn', 'into', 'Ma
nhattan', '.', 'The', 'company', 'built', 'or', 'renovated', 'skyscrapers', ',', 'hotels', ',', 'casinos', ',', 'and', 'golf', 'courses', '.', 'Tr
ump', 'later', 'started', 'various', 'side', 'ventures', ',', 'including', 'licensing', 'his', 'name', 'for', 'real', 'estate', 'and', 'consumer',
 'products', '.', 'He', 'managed', 'the', 'company', 'until', 'his', '2017', 'inauguration', '.', 'He', 'co', '-', 'authored', 'several', 'books',
 ',', 'including', 'The', 'Art', 'of', 'the', 'Deal', '.', 'He', 'owned', 'the', 'Miss', 'Universe', 'and', 'Miss', 'USA', 'beauty', 'pageants', '
from', '1996', 'to', '2015', ',', 'and', 'he', 'produced', 'and', 'hosted', 'The', 'Apprentice', ',', 'a', 'reality', 'television', 'show', ',', '
from', '2003', 'to', '2015', '.', 'Forbes', 'estimates', 'his', 'net', 'worth', 'to', 'be', '$', '3.1', 'billion', '.']
```

3、StandwordCoreNLP 分词，结果如下：

```
Tokenize: ['Trump', 'was', 'born', 'and', 'raised', 'in', 'the', 'New', 'York', 'City', 'borough', 'of', 'Queens', 'and', 'received', 'an', 'econo
mics', 'degree', 'from', 'the', 'Wharton', 'School', '.', 'He', 'was', 'appointed', 'president', 'of', 'his', 'family', "'s", 'real', 'estate', 'b
usiness', 'in', '1971', ',', 'renamed', 'it', 'The', 'Trump', 'Organization', ',', 'and', 'expanded', 'it', 'from', 'Queens', 'and', 'Brooklyn', '
into', 'Manhattan', '.', 'The', 'company', 'built', 'or', 'renovated', 'skyscrapers', ',', 'hotels', ',', 'casinos', ',', 'and', 'golf', 'courses'
, '.', 'Trump', 'later', 'started', 'various', 'side', 'ventures', ',', 'including', 'licensing', 'his', 'name', 'for', 'real', 'estate', 'and', '
consumer', 'products', '.', 'He', 'managed', 'the', 'company', 'until', 'his', '2017', 'inauguration', '.', 'He', 'co-authored', 'several', 'books
', ',', 'including', 'The', 'Art', 'of', 'the', 'Deal', '.', 'He', 'owned', 'the', 'Miss', 'Universe', 'and', 'Miss', 'USA', 'beauty', 'pageants',
'from', '1996', 'to', '2015', ',', 'and', 'he', 'produced', 'and', 'hosted', 'The', 'Apprentice', ',', 'a', 'reality', 'television', 'show', ',',
'from', '2003', 'to', '2015', '.', 'Forbes', 'estimates', 'his', 'net', 'worth', 'to', 'be', '$', '3.1', 'billion', '.']
```

实验结果：

成功完成了如中文分词工具 jieba，SnowNLP，THULAC，NLPIR，StanfordCoreNLP 英文分词工具：NLTK， SpaCy，StanfordCoreNLP 的尝试

实验总结：

自然语言处理中，分词是一项重要的任务，现在已有许多程序工具可以解决分词任务。

附源代码

```
import jieba

# 读取待分词中文文本
jieba.load_userdict("userdict.txt")
with open("Chinese.txt", "r", encoding="utf-8") as f:
    text = f.read()

# 精确模式
words_exact = jieba.cut(text, cut_all=False)
# 全模式
words_full = jieba.cut(text, cut_all=True)
# 搜索引擎模式
words_search = jieba.cut_for_search(text)

print("精确模式：")
print("/ ".join(words_exact))
print("\n 全模式：")
print("/ ".join(words_full))
print("\n 搜索引擎模式：")
print("/ ".join(words_search))

print("snownlp 分词：")
from snownlp import SnowNLP
s = SnowNLP(text)
```

```
print(s.words)

print("thulac 分词：")
import thulac
thu = thulac.thulac()
seg_list = thu.cut(text, text=True)
print(seg_list)

print("NLPIR pynlpir 分词：")
import pynlpir
pynlpir.open()
seg_list = pynlpir.segment(text, pos_tagging=False)
print(seg_list)
pynlpir.close()

import nltk
from nltk.tokenize import word_tokenize

with open("English.txt", "r", encoding="utf-8") as f:
    english_text = f.read()

tokens = word_tokenize(english_text)
print("NLTK 分词结果：")
print(tokens)

import spacy

nlp = spacy.load("en_core_web_sm")
doc = nlp(english_text)
tokens = [token.text for token in doc]
print("SpaCy 分词结果：")
print(tokens)

with open("Chinese.txt", "r", encoding="utf-8") as f:
    text_zh = f.read()

with open("English.txt", "r", encoding="utf-8") as f:
    text_en = f.read()


from stanfordcorenlp import StanfordCoreNLP
corenlp_path = "stanford-corenlp-4.5.6"
nlp_zh = StanfordCoreNLP(r'./stanford-corenlp-4.5.6',lang='zh')
nlp_en = StanfordCoreNLP(r'./stanford-corenlp-4.5.6',lang='en')
```

```
tokens_zh = nlp_zh.word_tokenize(text_zh)
tokens_en = nlp_en.word_tokenize(text_en)
print("stanford 中文分词结果: ", tokens_zh )
print("stanford 英文分词结果: ", tokens_en )

nlp_zh.close()
nlp_en.close()
```